



UNIVERSIDADE ESTADUAL DE SANTA CRUZ

Mestrado em Modelagem Computacional

Lista 4

MÉTODOS NUMÉRICOS I

Professor: Dany S. Dominguez

Alunos: Everaldina Guimarães Barbosa
João Vitor Nascimento Ramos

Ilhéus – BA
Novembro

Sumário

Introdução	2
Ferramentas Computacionais	2
Questão 1	3
(a) Ajuste de uma reta	3
(b) Ajuste pela Equação de Potência	5
(c) Ajuste pela Função Exponencial	7
(d) Modelo de Crescimento com Saturação	9
(e) Ajuste por uma Parábola	11
Comparação dos Modelos Ajustados	13
Questão 2: Regressão Linear Múltipla	14
Construção da Matriz de MQ	14
Solução do Sistema	15
Verificação do Ajuste	15
Questão 3: Regressão Linear Simples	16
a) Funções Base	16
b) Formulação Geral	16
c) Matriz de Mínimos Quadrados	17
d) Vetor Independente	17

Introdução

O método dos mínimos quadrados é uma ferramenta fundamental para ajustar modelos a dados observados. Ele permite identificar a função que melhor representa a tendência do conjunto de pontos, minimizando os desvios entre valores experimentais e valores previstos. Nesta lista, exploramos diferentes tipos de regressão: linear, não linear e modelos que exigem linearização, aplicando o método para determinar coeficientes, avaliar a qualidade do ajuste e comparar o desempenho entre funções propostas.

Ferramentas Computacionais

Para auxiliar nos cálculos numéricos, na construção dos gráficos e na verificação dos resultados, foi desenvolvido um conjunto de códigos em **Python**. Esses scripts foram utilizados para calcular os somatórios envolvidos nos métodos de mínimos quadrados, ajustar os modelos solicitados e gerar as figuras apresentadas ao longo deste relatório. Todas as expressões matemáticas, contudo, foram deduzidas de forma analítica e apresentadas explicitamente nas soluções.

Questão 1

Considere os seguintes dados:

x	5	10	15	20	25	30	35	40	45	50
y	17	24	31	33	37	37	40	40	42	41

Utilize as técnicas de regressão por mínimos quadrados para ajustar os dados a uma reta.

(a) Ajuste de Uma Reta

O modelo linear é ajustado pelo método dos mínimos quadrados minimizando

$$S(a, b) = \sum_{i=1}^n (y_i - (ax_i + b))^2.$$

As fórmulas clássicas são:

$$a = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}, \quad b = \frac{\sum y - a \sum x}{n}.$$

Cálculo dos somatórios

Para os dados fornecidos, obtemos:

$$\begin{aligned} n &= 10, \\ \sum x &= 5 + 10 + 15 + \cdots + 50 = 275, \\ \sum y &= 17 + 24 + 31 + \cdots + 41 = 342, \\ \sum x^2 &= 5^2 + 10^2 + \cdots + 50^2 = 9625, \\ \sum xy &= 5 \cdot 17 + 10 \cdot 24 + \cdots + 50 \cdot 41 = 10425. \end{aligned}$$

Cálculo dos coeficientes

$$a = \frac{10(10425) - (275)(342)}{10(9625) - 275^2} = \frac{104250 - 94050}{96250 - 75625} = \frac{10200}{20625} \approx 0.494.$$

$$b = \frac{342 - a(275)}{10} = \frac{342 - 0.494(275)}{10} = \frac{342 - 135.85}{10} \approx 20.62.$$

Equação da reta ajustada

$$y = 0.494x + 20.62$$

Coefficiente de correlação

Utilizando os valores corrigidos, obtém-se

$$R^2 = 0.839$$

indicando que o modelo linear explica cerca de 83.9% da variabilidade dos dados — um ajuste bom, com tendência crescente bem representada pela reta obtida.

Gráfico do ajuste

A Figura 1 apresenta o conjunto de dados juntamente com a reta ajustada pelo método dos mínimos quadrados. Nota-se que o modelo captura de forma satisfatória o comportamento crescente dos valores de y ao longo de x , com pequenas oscilações naturais dos dados em torno da linha estimada.




Figura 1: Ajuste linear por mínimos quadrados para os dados fornecidos.

(b) Ajuste pela Equação de Potência $y = \alpha x^\beta$

Para ajustar o modelo de potência

$$y = \alpha x^\beta,$$

utiliza-se a linearização por logaritmos na base 10:

$$\log_{10} y = \log_{10} \alpha + \beta \log_{10} x.$$

Definindo

$$X = \log_{10} x, \quad Y = \log_{10} y, \quad A = \log_{10} \alpha,$$

o modelo torna-se linear:

$$Y = A + \beta X.$$

Cálculo dos somatórios no plano transformado

$$n = 10$$

$$\sum X = 13.549$$

$$\sum Y = 15.197$$

$$\sum X^2 = 19.271$$

$$\sum XY = 20.942.$$

Cálculo dos coeficientes

$$\beta = \frac{10(20.942) - (13.549)(15.197)}{10(19.271) - (13.549)^2} \approx 0.397,$$

$$A = \frac{15.197 - 0.397(13.549)}{10} \approx 0.982,$$

$$\alpha = 10^A = 10^{0.982} \approx 9.59.$$

Equação Ajustada

$$y = 9.59 x^{0.397}$$

Coeficiente de Correlação

$$R^2 = 0.9377$$

indicando um ajuste superior ao modelo linear simples.

Gráfico do Ajuste

A Figura 2 apresenta o conjunto de dados original e a curva ajustada pelo modelo de potência. Visualmente, observa-se que a curva acompanha bem a tendência de crescimento dos pontos experimentais em todo o intervalo de x , com pequenos desvios locais, o que é compatível com o valor elevado de $R^2 = 0,938$.




Figura 2: Ajuste por mínimos quadrados utilizando o modelo de potência $y = \alpha x^\beta$.

(c) Ajuste pela Função Exponencial $y = \alpha e^{\beta x}$

Para ajustar o modelo exponencial

$$y = \alpha e^{\beta x},$$

utiliza-se a linearização em base 10:

$$\log_{10} y = \log_{10} \alpha + \beta x.$$

Definindo

$$Y = \log_{10} y, \quad A = \log_{10} \alpha,$$

o modelo linearizado fica

$$Y = A + \beta x.$$

Cálculo dos somatórios no plano transformado

$$n = 10,$$

$$\sum x = 275,$$

$$\sum Y = 15.197,$$

$$\sum x^2 = 9625,$$

$$\sum xY = 432.786.$$

Cálculo dos coeficientes

$$\beta = \frac{10(432.786) - 275(15.197)}{10(9625) - 275^2} \approx 0.00721,$$

$$A = \frac{15.197 - 0.00721(275)}{10} \approx 1.321,$$

$$\alpha = 10^A \approx 10^{1.321} \approx 20.97.$$

Equação Ajustada

Em base 10:

$$y = 20.97 \cdot 10^{0.00721x}$$

Em base e :

$$10^{0.00721x} = e^{(0.00721 \ln 10)x} = e^{0.0166x},$$

$$y = 20.97 e^{0.0166x}$$

Coeficiente de Correlação

$$R^2 = 0.7325,$$

indicando um ajuste inferior ao modelo de potência.

Gráfico do Ajuste

A Figura 3 apresenta o ajuste exponencial. Observa-se que a curva cresce mais lentamente que os dados, capturando a tendência geral, porém com menor aderência quando comparada ao modelo de potência.




Figura 3: Ajuste por mínimos quadrados utilizando o modelo exponencial.

(d) Ajuste pelo Modelo de Crescimento com Saturação

O modelo de saturação é dado por

$$y = \frac{\alpha x}{\beta + x},$$

o qual representa um crescimento rápido no início seguido de estabilização para valores grandes de x .

Para ajustar os parâmetros α e β , linearizamos o modelo invertendo a expressão:

$$y = \frac{\alpha x}{\beta + x} \implies \frac{1}{y} = \frac{\beta + x}{\alpha x} = \frac{\beta}{\alpha} \frac{1}{x} + \frac{1}{\alpha}.$$

Definindo

$$U = \frac{1}{y}, \quad V = \frac{1}{x},$$

obtemos o modelo linear:

$$U = AV + B,$$

onde

$$A = \frac{\beta}{\alpha}, \quad B = \frac{1}{\alpha}.$$

Cálculo dos somatórios no plano transformado

A partir dos valores transformados:

$$\begin{aligned} n &= 10, \\ \sum V &= 0.7367, \\ \sum U &= 0.2878, \\ \sum V^2 &= 0.07509, \\ \sum UV &= 0.02017. \end{aligned}$$

Cálculo dos coeficientes

$$A = \frac{n \sum UV - (\sum V)(\sum U)}{n \sum V^2 - (\sum V)^2} = \frac{10(0.02017) - (0.7367)(0.2878)}{10(0.07509) - (0.7367)^2} \approx 0.00955,$$

$$B = \frac{\sum U - A \sum V}{n} = \frac{0.2878 - 0.00955(0.7367)}{10} \approx 0.02705.$$

Voltando aos parâmetros originais:

$$\alpha = \frac{1}{B} \approx 36.95, \quad \beta = \frac{A}{B} \approx 0.353.$$

Equação Ajustada

$$y = \frac{36.95 x}{0.353 + x}$$

Coeficiente de Correlação

O coeficiente obtido numericamente foi

$$R^2 = 0.9892,$$

o maior dentre todos os modelos avaliados, indicando que o modelo de saturação é o que melhor descreve os dados.

Gráfico do Ajuste

A Figura 4 mostra que o modelo acompanha muito bem o comportamento dos dados, especialmente a tendência à estabilização para valores altos de x , o que explica o elevado valor de R^2 .




Figura 4: Ajuste por mínimos quadrados utilizando o modelo de saturação $y = \frac{\alpha x}{\beta + x}$.

(e) Ajuste por uma Parábola $y = ax^2 + bx + c$

O modelo quadrático é dado por

$$y = ax^2 + bx + c,$$

e seus coeficientes são determinados pelo método dos mínimos quadrados aplicando o sistema normal:

$$\begin{cases} \sum y = a \sum x^2 + b \sum x + c n, \\ \sum xy = a \sum x^3 + b \sum x^2 + c \sum x, \\ \sum x^2 y = a \sum x^4 + b \sum x^3 + c \sum x^2. \end{cases}$$

Cálculo dos somatórios

Para os dados fornecidos:

$$\begin{aligned} n &= 10, \\ \sum x &= 275, \\ \sum y &= 342, \\ \sum x^2 &= 9625, \\ \sum x^3 &= 371875, \\ \sum x^4 &= 15546875, \\ \sum xy &= 10245, \\ \sum x^2 y &= 396875. \end{aligned}$$

Sistema Normal

$$\begin{cases} 342 = 9625a + 275b + 10c, \\ 10245 = 371875a + 9625b + 275c, \\ 396875 = 15546875a + 371875b + 9625c. \end{cases}$$

Cálculo dos coeficientes

A solução do sistema é:

$$a \approx -0.01202, \quad b \approx 1.323, \quad c \approx 13.58.$$

Equação Ajustada

$$y = -0.01202x^2 + 1.323x + 13.58$$

Coeficiente de Correlação

$$R^2 = 0.9800,$$

valor bastante elevado e próximo ao obtido pelo modelo de saturação, indicando bom poder descritivo.

Gráfico do Ajuste

A Figura 5 mostra que a parábola se ajusta bem ao conjunto de dados em todo o intervalo, acompanhando tanto o crescimento inicial quanto a leve tendência de estabilização, com boa aderência também nas extremidades.




Figura 5: Ajuste por mínimos quadrados utilizando o modelo quadrático $y = ax^2 + bx + c$.

Comparação dos Modelos Ajustados

A Tabela 1 resume os valores de R^2 obtidos para cada ajuste.

Modelo	R^2
Reta (linear)	0.8385
Potência $y = \alpha x^\beta$	0.9377
Exponencial $y = \alpha e^{\beta x}$	0.7325
Saturação $y = \frac{\alpha x}{\beta + x}$	0.9892
Parábola $y = ax^2 + bx + c$	0.9800

Tabela 1: Comparação dos coeficientes de determinação dos modelos ajustados.

A Figura 6 mostra todos os ajustes traçados sobre o mesmo conjunto de dados. Esse gráfico ajuda a visualizar não só a qualidade numérica do ajuste, mas também como cada modelo se comporta ao longo do intervalo.




Figura 6: Comparação visual entre os diferentes modelos ajustados aos dados.

De modo geral, o modelo de saturação foi o que melhor representou o comportamento dos dados, tanto pelo maior valor de R^2 quanto pela forma da curva, que acompanha bem a tendência de crescimento e posterior estabilização. A parábola também apresentou bom desempenho. Os demais modelos ficaram um pouco mais afastados dos pontos em alguma região do intervalo.

Questão 2: Regressão Linear Múltipla

Considere os seguintes dados em um domínio bidimensional:

x_1	0	2	2.5	1	4	7
x_2	0	1	2	3	6	2
y	5	10	9	0	3	27

O objetivo é ajustar um modelo de regressão linear múltipla utilizando a formulação geral dos mínimos quadrados. Para isso, identifica-se a estrutura linear:

$$y = a_0 + a_1x_1 + a_2x_2.$$

Construção da Matriz de MQ

Para a formulação matricial dos mínimos quadrados, define-se:

$$X = \begin{bmatrix} 1 & x_{1,1} & x_{2,1} \\ 1 & x_{1,2} & x_{2,2} \\ \vdots & \vdots & \vdots \\ 1 & x_{1,n} & x_{2,n} \end{bmatrix}, \quad a = \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}.$$

Com os valores da tabela, a matriz X é:

$$X = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 2 & 1 \\ 1 & 2.5 & 2 \\ 1 & 1 & 3 \\ 1 & 4 & 6 \\ 1 & 7 & 2 \end{bmatrix}, \quad y = \begin{bmatrix} 5 \\ 10 \\ 9 \\ 0 \\ 3 \\ 27 \end{bmatrix}.$$

$$X^T X = \begin{bmatrix} 6 & 16.5 & 14 \\ 16.5 & 73.25 & 47 \\ 14 & 47 & 54 \end{bmatrix}.$$

$$X^T y = \begin{bmatrix} 54 \\ 160 \\ 81 \end{bmatrix}.$$

Assim, o sistema normal é:

$$\begin{bmatrix} 6 & 16.5 & 14 \\ 16.5 & 73.25 & 47 \\ 14 & 47 & 54 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 54 \\ 160 \\ 81 \end{bmatrix}.$$

Solução do Sistema

Resolvendo o sistema normal, obtém-se:

$$a_0 = 5, \quad a_1 = 4, \quad a_2 = -3.$$

Portanto, a função ajustada é:

$$\hat{y}(x_1, x_2) = 5 + 4x_1 - 3x_2.$$

Verificação do Ajuste

A seguir, comparamos o valor previsto para cada ponto com o valor real:

(x_1, x_2)	$\hat{y} = 5 + 4x_1 - 3x_2$	y_{real}
(0, 0)	5	5
(2, 1)	10	10
(2.5, 2)	9	9
(1, 3)	0	0
(4, 6)	3	3
(7, 2)	27	27

Dessa forma, temos que :

$$R^2 = 1.$$

Isto indica que o modelo ajusta perfeitamente os dados, o que é esperado, pois com duas variáveis explicativas e seis pontos, o conjunto é exatamente representado por uma combinação linear dessas variáveis.

Questão 3: Derivação da Regressão Linear Simples

Considere um conjunto de n pontos $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$. O modelo de regressão linear simples é dado por

$$y = a_0 + a_1x + e.$$

O objetivo é mostrar que o sistema de equações normais

$$\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}$$

pode ser obtido diretamente da formulação geral de mínimos quadrados.

a) Funções Base

O modelo linear simples utiliza duas funções base:

$$z_0(x) = 1, \quad z_1(x) = x.$$

Assim, para cada ponto (x_i, y_i) , a linha correspondente na matriz de funções base será:

$$[z_0(x_i) \ z_1(x_i)] = [1 \ x_i].$$

b) Formulação Geral: Matrizes Y , Z e A

A forma matricial geral dos mínimos quadrados é

$$Y = ZA + E,$$

onde:

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad A = \begin{bmatrix} a_0 \\ a_1 \end{bmatrix}, \quad Z = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix}.$$

c) Matriz de Mínimos Quadrados $Z^T Z$

A transposta é:

$$Z^T = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \end{bmatrix}.$$

Multiplicando:

$$Z^T Z = \begin{bmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} = \begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix}.$$

d) Vetor Independente $Z^T Y$

$$Z^T Y = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}.$$

Equações Normais

Da formulação dos mínimos quadrados, obtemos:

$$(Z^T Z)A = Z^T Y,$$

o que resulta explicitamente em:

$$\boxed{\begin{bmatrix} n & \sum x_i \\ \sum x_i & \sum x_i^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_i y_i \end{bmatrix}}$$