



UNIVERSIDADE ESTADUAL DE SANTA CRUZ

Mestrado em Modelagem Computacional

LISTA 01 DE EXERCÍCIOS

MÉTODOS NUMÉRICOS I

Professor: Dany Sanchez Dominguez

Alunos: Everaldina Guimarães Barbosa
João Vitor Nascimento Ramos

Ilhéus - BA
2025.2

Lista de Exercícios

Exercício 1

Considere um computador onde a palavra de memória é de 16 bits. Nessa representação utiliza-se um bit para o sinal, 5 bits para o expoente (o primeiro para o sinal do expoente e os 4 restantes para o valor do expoente) e 10 para a mantissa do número.

Dado o número de máquina representado abaixo:

0	1	0	0	1	1	1	0	1	0	1	1	0	0	0	1
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

- a) Qual é o número decimal representado?
- b) Qual é o número de máquina imediato inferior? Informe seu valor decimal.
- c) Qual é o número de máquina imediato superior? Informe seu valor decimal.
- d) Qual o intervalo de números reais que podem ser representados na notação de 16 bits?
- e) Utilize os resultados anteriores para explicar porque apenas um subconjunto dos números reais pode ser representado pelo computador.

Solução

a) Número decimal representado

Bit de sinal: $S = 0$, logo o número é positivo:

$$(-1)^S = +1. \quad (1)$$

Expoente: primeiro bit indica sinal negativo e os quatro seguintes valem $0011_2 = 3$, então:

$$E = -3. \quad (2)$$

Mantissa:

$$M = (2^{-1} + 2^{-3} + 2^{-5} + 2^{-6} + 2^{-10}) = 0.6728515625. \quad (3)$$

Portanto, o valor é

$$x = (+1) \cdot M \cdot 2^{-3} = 0.6728515625 \cdot \frac{1}{8} \approx 0.0841064453125 \Rightarrow \boxed{0.0841064453125}. \quad (4)$$

b) Número de máquina imediato inferior

O espaçamento entre representações (ULP) depende do expoente:

$$ULP(E) = 2^{E-10} = 2^{-13} = \frac{1}{8192} \approx 0.0001220703125.$$

Subtraindo esse valor da representação atual:

$$x_- = 0.0841064453125 - 0.0001220703125 = 0.083984375 \Rightarrow \boxed{0.083984375}.$$

c) Número de máquina imediato superior

Somando o ULP ao valor atual:

$$x_+ = 0.0841064453125 + 0.0001220703125 = 0.084228515625 \Rightarrow \boxed{0.084228515625}.$$

d) Intervalo de números reais representáveis

Com 5 bits para o expoente (1 para sinal e 4 para magnitude):

$$E_{\min} = -15, \quad E_{\max} = +15.$$

Dessa forma:

$$M_{\min} = 0.0, \quad M_{\max} = 1 - 2^{-10}.$$

$$x_{\max} = (1 - 2^{-10}) \cdot 2^{15} = 32752 \Rightarrow \boxed{32752}.$$

Logo, intervalo total: $\boxed{-32752 \text{ até } +32752}$.

A representação binária dos campos no formato de 16 bits pode ser ilustrada como:

$$\underbrace{0}_{\text{sinal}} \quad \underbrace{01111}_{\text{expoente}} \quad \underbrace{1111111111}_{\text{mantissa}}$$

Exercício 2

Considere a equação de segundo grau

$$ax^2 + bx + c = 0, \quad a \neq 0. \quad (5)$$

Se $a = 1$, $b = 62,10$ e $c = 1$, obtemos as raízes aproximadas $x_1 \approx -0,01610723$ e $x_2 \approx -62,08390$. Determine $f(x_1)$ e $f(x_2)$ com **4 dígitos arredondados** usando as fórmulas:

$$(a) \quad f(x_1) = \frac{-b + \sqrt{b^2 - 4ac}}{2a}$$

$$(b) \quad f(x_2) = \frac{-b - \sqrt{b^2 - 4ac}}{2a}$$

$$(c) \quad f(x_1) = \frac{-2c}{b + \sqrt{b^2 - 4ac}}$$

$$(d) \quad f(x_2) = \frac{-2c}{b - \sqrt{b^2 - 4ac}}$$

Em seguida responda:

- (a) Calcule os **erros absolutos** para cada estimativa.
- (b) Calcule os **erros relativos** para cada estimativa.
- (c) Considerando os resultados de (a) e (b), **qual definição de erro é mais apropriada?** Justifique.
- (d) Compare os resultados de (i) e (ii) com os de (iii) e (iv). **Por que são diferentes?** Qual alternativa devemos preferir em cada raiz?

Solução

(i) Forma $\frac{-b + \sqrt{\Delta}}{2a}$ (para x_1).

$$\begin{aligned} fl(x_1) &= \frac{-fl(b) + \sqrt{fl(b)^2 - fl(4) \cdot fl(a) \cdot fl(c)}}{fl(2) \cdot fl(a)} \\ &= \frac{-0.6210 \cdot 10^2 + \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1 \cdot 0.1000 \cdot 10^1}}{0.2000 \cdot 10^1 \cdot 0.1000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 + \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 + \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 + \sqrt{0.6210 \cdot 10^2 \cdot 0.6210 \cdot 10^2 - 0.4000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 + \sqrt{0.3856 \cdot 10^4 - 0.4000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 + \sqrt{0.3852 \cdot 10^4}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 + 0.6206 \cdot 10^2}{0.2000 \cdot 10^1} \\ &= \frac{-0.4000 \cdot 10^{-1}}{0.2000 \cdot 10^1} \\ &= -0.2000 \cdot 10^{-1} \end{aligned}$$

(ii) Forma $\frac{-b - \sqrt{\Delta}}{2a}$ (para x_2).

$$\begin{aligned} fl(x_2) &= \frac{-fl(b) - \sqrt{fl(b)^2 - fl(4) \cdot fl(a) \cdot fl(c)}}{fl(2) \cdot fl(a)} \\ &= \frac{-0.6210 \cdot 10^2 - \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1 \cdot 0.1000 \cdot 10^1}}{0.2000 \cdot 10^1 \cdot 0.1000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 - \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 - \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 - \sqrt{0.6210 \cdot 10^2 \cdot 0.6210 \cdot 10^2 - 0.4000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 - \sqrt{0.3856 \cdot 10^4 - 0.4000 \cdot 10^1}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 - \sqrt{0.3852 \cdot 10^4}}{0.2000 \cdot 10^1} \\ &= \frac{-0.6210 \cdot 10^2 - 0.6206 \cdot 10^2}{0.2000 \cdot 10^1} \\ &= \frac{-0.1242 \cdot 10^3}{0.2000 \cdot 10^1} \\ &= -0.6210 \cdot 10^2 \end{aligned}$$

(iii) Forma $\frac{-2c}{b + \sqrt{\Delta}}$

$$\begin{aligned}
fl(x_1) &= \frac{-fl(2) \cdot fl(c)}{fl(b) + \sqrt{fl(b)^2 - (fl(4) \cdot fl(a) \cdot fl(c))}} \\
&= \frac{-0.2000 \cdot 10^1 \cdot 0.1000 \cdot 10^1}{0.6210 \cdot 10^2 + \sqrt{(0.6210 \cdot 10^2)^2 - (0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1 \cdot 0.1000 \cdot 10^1)}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 + \sqrt{(0.6210 \cdot 10^2)^2 - (0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1)}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 + \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 + \sqrt{0.6210 \cdot 10^2 \cdot 0.6210 \cdot 10^2 - 0.4000 \cdot 10^1}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 + \sqrt{0.3856 \cdot 10^4 - 0.4000 \cdot 10^1}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 + \sqrt{0.3852 \cdot 10^4}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 + 0.6206 \cdot 10^2} \\
&= \frac{-0.2000 \cdot 10^1}{0.1242 \cdot 10^3} \\
&= -0.1610 \cdot 10^{-1}
\end{aligned}$$

(iv) Forma $\frac{-2c}{b - \sqrt{\Delta}}$

$$\begin{aligned}
fl(x_2) &= \frac{-fl(2) \cdot fl(c)}{fl(b) - \sqrt{fl(b)^2 - (fl(4) \cdot fl(a) \cdot fl(c))}} \\
&= \frac{-0.2000 \cdot 10^1 \cdot 0.1000 \cdot 10^1}{0.6210 \cdot 10^2 - \sqrt{(0.6210 \cdot 10^2)^2 - (0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1 \cdot 0.1000 \cdot 10^1)}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 - \sqrt{(0.6210 \cdot 10^2)^2 - (0.4000 \cdot 10^1 \cdot 0.1000 \cdot 10^1)}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 - \sqrt{(0.6210 \cdot 10^2)^2 - 0.4000 \cdot 10^1}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 - \sqrt{0.6210 \cdot 10^2 \cdot 0.6210 \cdot 10^2 - 0.4000 \cdot 10^1}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 - \sqrt{0.3856 \cdot 10^4 - 0.4000 \cdot 10^1}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 - \sqrt{0.3852 \cdot 10^4}} \\
&= \frac{-0.2000 \cdot 10^1}{0.6210 \cdot 10^2 - 0.6206 \cdot 10^2} \\
&= \frac{-0.2000 \cdot 10^1}{0.4000 \cdot 10^{-1}} \\
&= -0.5000 \cdot 10^2
\end{aligned}$$

Valores de referência (dados). Para avaliar erros, utilizamos as aproximações fornecidas no enunciado:

$$x_1 \approx \boxed{-0,01610723}, \quad x_2 \approx \boxed{-62,08390}. \quad (6)$$

(a) Erros absolutos.

$$E_{\text{abs}} = |x_{\text{exato}} - x_{\text{aprox}}|. \quad (7)$$

$$E_{\text{abs}}(f_1) = |-0.01610723 - (-0.02000)| \approx \boxed{3.89 \times 10^{-3}} \quad (8)$$

$$E_{\text{abs}}(f_2) = |-62.08390 - (-62.10)| \approx \boxed{1.61 \times 10^{-2}} \quad (9)$$

$$E_{\text{abs}}(f_3) = |-0.01610723 - (-0.01610)| \approx \boxed{7.2 \times 10^{-6}} \quad (10)$$

$$E_{\text{abs}}(f_4) = |-62.08390 - (-50.00)| \approx \boxed{12.08} \quad (11)$$

(b) Erros relativos.

$$E_{\text{rel}} = \frac{|x_{\text{exato}} - x_{\text{aprox}}|}{|x_{\text{exato}}|}. \quad (12)$$

$$E_{\text{rel}}(f_1) = \frac{3.89 \times 10^{-3}}{0.01610723} \approx \boxed{2.4 \times 10^{-1}} \text{ (24\%)} \quad (13)$$

$$E_{\text{rel}}(f_2) = \frac{1.61 \times 10^{-2}}{62.08390} \approx \boxed{2.6 \times 10^{-4}} \text{ (0.026\%)} \quad (14)$$

$$E_{\text{rel}}(f_3) = \frac{7.2 \times 10^{-6}}{0.01610723} \approx \boxed{4.5 \times 10^{-4}} \text{ (0.045\%)} \quad (15)$$

$$E_{\text{rel}}(f_4) = \frac{12.08}{62.08390} \approx \boxed{1.9 \times 10^{-1}} \text{ (19\%)} \quad (16)$$

(c) Qual erro é mais apropriado? Para comparar métodos aplicados a quantidades com *ordens de grandeza distintas*, o **erro relativo** é o mais adequado, pois normaliza pelo tamanho do valor verdadeiro. O erro absoluto pode parecer “grande” ou “pequeno” apenas por causa da escala da variável.

(d) Por que os resultados diferem? Qual usar? As fórmulas (i) e (iv) envolvem subtrações de números muito próximos, o que causa perda de precisão (cada dígito que se cancela diminui a quantidade de informação útil que sobra). Já as fórmulas (iii) e (ii) não têm esse problema, porque usam apenas somas ou divisões por valores grandes, e por isso mantêm os dígitos mais confiáveis. Na prática, é melhor calcular x_1 pela forma (iii) e x_2 pela forma (ii), pois assim os arredondamentos não prejudicam tanto o resultado.

$$\boxed{\text{(iii) para } x_1, \quad \text{e (ii) para } x_2.}$$

Exercício 3

A constante de Euler é definida por

$$e = \lim_{x \rightarrow \infty} \left(1 + \frac{1}{x}\right)^x. \quad (17)$$

- (a) Usando a definição acima, calcule estimativas de e para $x \in \{10^0, 10^1, 10^2, 10^3, \dots, 10^{32}\}$.
- (b) Para cada estimativa, calcule o desvio relativo tomando $e_{\text{exato}} = 2,718281828459$.
- (c) Descreva o comportamento do erro quando x cresce.

Solução

Para resolver este exercício, foram comparados três tipos de resultados:

- 1. O valor **teórico** de $\left(1 + \frac{1}{x}\right)^x$, calculado com alta precisão (12 algarismos significativos).
- 2. O valor obtido em **C na forma direta**, usando `pow(1 + 1/x, x)`. Para x muito grandes, essa forma sofre com arredondamento e devolve 1.
- 3. O valor obtido em **C pela reescrita estável**, usando

$$\left(1 + \frac{1}{x}\right)^x = \exp\left(x \ln\left(1 + \frac{1}{x}\right)\right),$$

Avaliando o logaritmo de modo numericamente estável (sem somar $1 + 1/x$ explicitamente). Essa forma preserva o valor correto mesmo para x enormes.

a) Estimativas de e para $x \in \{10^0, 10^1, 10^2, 10^3, \dots, 10^{32}\}$.

Em `double` (64 bits), diferenças menores que $2^{-52} \approx 2,2 \times 10^{-16}$ não são representáveis. Para $x \gtrsim 10^{16}$, temos $1/x$ menor que essa precisão, e o termo $1 + \frac{1}{x}$ é arredondado para 1. Assim, o cálculo direto devolve $1^x = 1$, enquanto a forma reescrita estável preserva o valor correto de e .

$$\left(1 + \frac{1}{x}\right)^x \rightarrow (1 + 0)^x = 1^x = 1 \quad (18)$$

x	Teórico	C (direto, pow)	C (reescrita, estável)
10^0	2.000000000000000	2.000000000000000	2.000000000000000
10^1	2.593742460100002	2.593742460100002	2.593742460100000
10^2	2.704813829421528	2.704813829421529	2.704813829421526
10^3	2.716923932235894	2.716923932235594	2.716923932235893
10^4	2.718145926825225	2.718145926824926	2.718145926825225
10^5	2.718268237174490	2.718268237192298	2.718268237174490
10^6	2.718280469319377	2.718280469095753	2.718280469319377
10^7	2.718281692544966	2.718281694132082	2.718281692544966
10^8	2.718281814867637	2.718281798347358	2.718281814867637
10^9	2.718281827099904	2.718282052011560	2.718281827099904
10^{10}	2.718281828323132	2.718282053234788	2.718281828323132
10^{11}	2.718281828445454	2.718282053357110	2.718281828445454
10^{12}	2.718281828457686	2.718523496037238	2.718281828457686
10^{13}	2.718281828458910	2.716110034086901	2.718281828458910
10^{14}	2.718281828459032	2.716110034087023	2.718281828459032
10^{15}	2.718281828459044	3.035035206549262	2.718281828459044
10^{16}	2.718281828459045	1.000000000000000	2.718281828459045
10^{32}	2.718281828459045	1.000000000000000	2.718281828459045

b) **Desvio relativo** em relação a e :

$$\delta = \frac{|e - \text{valor}|}{e}.$$

x	$E_{\text{rel}}(\text{pow})$	$E_{\text{rel}}(\text{estável})$
10^0	$2.642 \cdot 10^{-1}$	$2.642 \cdot 10^{-1}$
10^1	$4.582 \cdot 10^{-2}$	$4.582 \cdot 10^{-2}$
10^2	$4.955 \cdot 10^{-3}$	$4.955 \cdot 10^{-3}$
10^3	$4.995 \cdot 10^{-4}$	$4.995 \cdot 10^{-4}$
10^4	$5.000 \cdot 10^{-5}$	$5.000 \cdot 10^{-5}$
10^5	$5.000 \cdot 10^{-6}$	$5.000 \cdot 10^{-6}$
10^6	$5.001 \cdot 10^{-7}$	$5.000 \cdot 10^{-7}$
10^7	$4.942 \cdot 10^{-8}$	$5.000 \cdot 10^{-8}$
10^8	$1.108 \cdot 10^{-8}$	$5.000 \cdot 10^{-9}$
10^9	$8.224 \cdot 10^{-8}$	$5.000 \cdot 10^{-10}$
10^{10}	$8.269 \cdot 10^{-8}$	$5.000 \cdot 10^{-11}$
10^{11}	$8.274 \cdot 10^{-8}$	$5.000 \cdot 10^{-12}$
10^{12}	$8.890 \cdot 10^{-5}$	$4.999 \cdot 10^{-13}$
10^{13}	$7.990 \cdot 10^{-4}$	$4.983 \cdot 10^{-14}$
10^{14}	$7.990 \cdot 10^{-4}$	$4.901 \cdot 10^{-15}$
10^{15}	$1.165 \cdot 10^{-1}$	$4.901 \cdot 10^{-16}$
10^{16}	$6.321 \cdot 10^{-1}$	$0.000 \cdot 10^0$
10^{32}	$6.321 \cdot 10^{-1}$	$0.000 \cdot 10^0$

c) **Comportamento do erro.** No caso **teórico**, o erro relativo decresce aproxi-

madamente como $\frac{1}{2x}$, o que significa que a cada aumento de uma potência de 10 em x , o erro cai por um fator de ≈ 10 .

No **C direto (pow)**, quando $x \gtrsim 10^{16}$ a soma $1 + \frac{1}{x}$ é arredondada para 1, de modo que o resultado passa a ser $1^x = 1$, com erro relativo $\approx 0,632$.

Já na **reescrita estável** $\exp(x \ln(1 + \frac{1}{x}))$, esse arredondamento não ocorre, e o erro mantém a mesma ordem de grandeza do caso teórico, permanecendo próximo de zero mesmo para expoentes enormes.




Figura 1: Erro relativo do cálculo em C em função de $x = 10^k$.

Como se observa na Figura 1, o erro relativo do cálculo em C pela expressão direta $(1 + 1/x)^x$ acompanha inicialmente o comportamento teórico, decrescendo aproximadamente como $\frac{1}{2x}$ à medida que x cresce. Contudo, para valores $x \gtrsim 10^{16}$, a soma $1 + 1/x$ passa a ser arredondada para 1 pela limitação da precisão em ponto flutuante, de forma que a expressão resulta em $1^x = 1$. A partir desse ponto, o erro relativo deixa de decrescer e se estabiliza em torno de 0,632, revelando a perda de acurácia numérica no cálculo direto.