

Metodos Numericos

João Vitor Nascimento Ramos

1 de dezembro de 2025

Sumário

1	Aproximações e Erros de Arredondamento	4
1.1	Introdução	4
1.2	Algarismos Significativos	4
1.2.1	Zeros e notação científica	4
1.3	Erros em Métodos Numéricos	5
1.4	Acurácia e Precisão	5
1.5	Erros Absoluto, Relativo e Percentual	7
1.5.1	Erro Relativo Verdadeiro	7
1.5.2	Dificuldade prática	7
1.5.3	Erro Aproximado	7
1.5.4	Sinal do erro e tolerância	8
1.5.5	Erro e Algarismos Significativos	8
1.6	Erros de Arredondamento	9
1.6.1	Representação dos Números no Computador	9
1.6.2	Representação Inteira	10
1.6.3	Representação em Ponto Flutuante	12
1.6.4	Épsilon da Máquina	16
1.6.5	Aritmética Computacional	16
2	Erros de Truncamento e Séries de Taylor	18
2.1	Introdução	18
2.2	A Série de Taylor	18
2.2.1	Teorema de Taylor	18
2.2.2	Interpretação	19
2.2.3	Primeiro Teorema do Valor Médio para Integrais	19
2.2.4	Segundo Teorema do Valor Médio para Integrais	19
2.2.5	Exemplo simples	19
2.3	Aproximação de um Polinômio por Série de Taylor	20
2.3.1	Enunciado do Problema	20
2.3.2	Solução	20
2.4	Erro de Truncamento e Ordem de Aproximação	21
2.4.1	O papel do termo de resto	21
2.4.2	Ordem de Grandeza do Erro	22
2.4.3	Conclusões práticas	22
2.4.4	O Resto na Expansão em Série de Taylor	22
2.4.5	Usando a Série de Taylor para Fazer uma Estimativa do Erro de Truncamento	24
2.5	Propagação de Erros	25

2.5.1	Funções de uma Única Variável	25
2.5.2	Funções de Mais de Uma Variável	25
2.6	Erro Numérico Total	26
2.6.1	Controle dos Erros Numéricos	26
2.6.2	Estimativas e Estratégias	27
3	Raízes da Equação	28
3.1	Introdução	28
3.1.1	Métodos sem o uso do Computador	28
3.1.2	Fundamentos Matemáticos	29
3.1.3	Raízes de Equações e a Prática da Engenharia	30
3.1.4	Classificação dos Problemas de Raízes	30
3.2	Métodos Gráficos	31
3.2.1	Considerações sobre a Identificação Gráfica de Raízes	31
3.2.2	Uso de Gráficos Computacionais para Localizar Raízes	33
3.3	O Método da Bissecção	34
3.3.1	Descrição do Método	34
3.3.2	Critério de Parada e Estimativa do Erro	35
3.3.3	Exemplo	37
3.3.4	Vantagens e Desvantagens do Método da Bissecção	38
3.4	O Método da Falsa Posição	39
3.4.1	Comparação com o Método da Bissecção	39
3.4.2	Exemplo	40
3.4.3	Vantagens e Desvantagens	41
3.5	Métodos Abertos	42
3.6	Método do Ponto Fixo	43
3.6.1	Convergência	44
3.6.2	Escolha da Função $g(x)$ no Método do Ponto Fixo	45
3.6.3	Exemplo	46
3.6.4	Vantagens e Desvantagens	47
3.7	Método de Newton–Raphson	48
3.7.1	Exemplo	49
3.7.2	Problemas do Método de Newton–Raphson	50
3.7.3	Vantagens e Desvantagens	51
3.8	Método da Secante	52
3.8.1	Derivação da fórmula	52
3.8.2	Características do método	52
3.8.3	Interpretação geométrica	52
3.8.4	Exemplo	53
4	Equações Algébricas Lineares	55
4.1	Introdução	55
4.1.1	Famílias de métodos numéricos para SELAs	56
4.1.2	Representação de SELAs	57
4.2	Tipos de SELAs	57
4.2.1	Independência e Dependência Linear	57
4.2.2	Classificação dos Sistemas Lineares	58
4.3	Método de Eliminação de Gauss	59
4.3.1	Pivotamento parcial	64

4.3.2	Pivotamento Parcial com Escala	66
4.3.3	Pivotamento Total	68
4.3.4	Pivotamento Total	69
4.4	Inversão de Matrizes	71
4.5	Fatoração LU	73
4.6	Método de Jacobi	78
4.7	Método de Gauss–Seidel	82
4.8	Métodos de Relaxamento	84
5	Interpolação Polinomial	87
5.1	Polinômios de Taylor	88
5.2	Polinômio de Lagrange	91
6	Regressão por Mínimos Quadrados	94
6.1	Problema da interpolação em dados ruidosos	94
6.2	Ideia da Regressão por Mínimos Quadrados	95
6.3	Modelo de regressão linear	95
6.4	Critérios para um Melhor Ajuste	96
6.5	Ajuste por Mínimos Quadrados por uma Reta	98
6.5.1	Exemplo Numérico: Ajuste por Mínimos Quadrados por uma Reta	99
6.6	Linearização de Relações Não-Lineares	101
6.7	Regressão Polinomial	105
6.8	Regressão Linear Múltipla	107
6.9	Formulação Matricial Geral dos Mínimos Quadrados Linear	110

Capítulo 1

Aproximações e Erros de Arredondamento

1.1 Introdução

Muitos métodos numéricos são fáceis de aplicar, mas é fundamental compreender os erros associados a eles. Sempre que utilizamos aproximações, surge uma diferença em relação à solução exata. Em muitos problemas de engenharia e ciências aplicadas, não existe fórmula fechada que forneça o valor exato, e por isso precisamos trabalhar com aproximações e estimativas.

O número π não pode ser representado exatamente em forma decimal. Se utilizarmos $\pi \approx 3,14$, temos um valor útil em cálculos práticos, mas com um erro em relação ao valor mais preciso $\pi \approx 3,14159\dots$. Essa diferença é o que chamamos de **erro**.

Assim, é importante saber identificar, quantificar e minimizar os erros. Este capítulo aborda principalmente o **erro de arredondamento**, decorrente da limitação dos computadores em representar números com infinitas casas decimais. No capítulo seguinte será estudado o **erro de truncamento**, ligado ao uso de aproximações em expressões matemáticas exatas.

1.2 Algarismos Significativos

Antes de tratar diretamente dos erros numéricos, é importante revisar como os números são representados. Os **algarismos significativos** de um número indicam o grau de confiança em sua medida ou cálculo. Eles correspondem a todos os algarismos corretos mais um estimado.

No velocímetro da Figura 1.1, a leitura situa-se entre 48 e 49 km/h. O ponteiro está ligeiramente acima da metade, logo a medida confiável é de aproximadamente 48,5 km/h, ou seja, **três algarismos significativos**. Já o hodômetro indica 87.324,5 km, correspondendo a **sete algarismos significativos**.

1.2.1 Zeros e notação científica

Alguns casos podem gerar dúvida:

- Números como 0,00001845 possuem quatro algarismos significativos — os zeros iniciais não contam.




Figura 1.1: Exemplo de medidas: velocímetro (três algarismos significativos) e hodômetro (sete algarismos significativos).

- Valores grandes como 45.300 podem ter três, quatro ou cinco algarismos significativos, dependendo da confiabilidade dos zeros finais.

Para evitar ambiguidades, usa-se a **notação científica**:

$$4,53 \times 10^4, \quad 4,530 \times 10^4, \quad 4,5300 \times 10^4$$

representam, respectivamente, três, quatro e cinco algarismos significativos.

1.3 Erros em Métodos Numéricos

Dois tipos principais de erro são estudados:

1. **Erro de arredondamento**: surge porque computadores só armazenam um número finito de dígitos.
2. **Erro de truncamento**: aparece quando métodos numéricos usam aproximações para expressar operações matemáticas exatas.

Além desses, existem erros não relacionados ao método, como enganos de cálculo, falhas no modelo matemático ou incertezas nos dados experimentais.

1.4 Acurácia e Precisão

Os erros associados tanto aos cálculos quanto às medidas podem ser caracterizados com relação à sua **acurácia** e **precisão**:

- **Acurácia**: indica o quão próximo um valor calculado ou medido está do valor verdadeiro.
- **Precisão**: indica o quão próximos os valores individuais calculados ou medidos estão uns dos outros.




Figura 1.2: Relação entre acurácia e precisão ilustrada pela analogia de tiro ao alvo.

Esses conceitos podem ser ilustrados pela prática de tiro ao alvo. Na Figura 1.2, os buracos de bala representam predições de uma técnica numérica, enquanto o centro do alvo (mosca) representa o valor verdadeiro.

- **Inacurácia (ou viés):** ocorre quando há um desvio sistemático em relação à verdade. Por exemplo, nas Figuras (a) e (c), os disparos estão concentrados fora do centro, mesmo que em (c) haja maior agrupamento.
- **Imprecisão (ou incerteza):** refere-se ao espalhamento dos resultados. Nas Figuras (b) e (d), os disparos estão centrados na mosca, mas em (b) o agrupamento é mais espalhado, enquanto em (d) os tiros são muito próximos entre si.

Portanto, podemos resumir:

- Caso (a): baixa acurácia e baixa precisão;
- Caso (b): alta acurácia e baixa precisão;
- Caso (c): baixa acurácia e alta precisão;
- Caso (d): alta acurácia e alta precisão.

Em métodos numéricos, é desejável alcançar resultados suficientemente acurados (sem viés) e suficientemente precisos (com baixa dispersão), de modo a atender às necessidades práticas de engenharia.

Neste documento, será usado o termo coletivo **erro** para designar tanto a inacurácia quanto a imprecisão presentes nas predições numéricas.

1.5 Erros Absoluto, Relativo e Percentual

Os erros numéricos decorrem do uso de aproximações para representar operações e quantidades matemáticas exatas. Eles podem ser classificados em:

- **Erros de truncamento:** resultam de aproximações usadas para representar procedimentos matemáticos exatos (por exemplo, substituir uma série infinita por um número finito de termos).
- **Erros de arredondamento:** surgem quando números com quantidade limitada de algarismos significativos são usados para representar valores exatos em computadores.

Em ambos os casos, a relação entre o valor verdadeiro e a aproximação pode ser escrita como:

$$\text{valor verdadeiro} = \text{aproximação} + \text{erro}$$

Rearranjando:

$$E_t = \text{valor verdadeiro} - \text{aproximação}$$

onde E_t é o **erro verdadeiro**. O subscrito t (de *true*) indica que se trata do erro em relação ao valor real, em contraste com estimativas aproximadas.

1.5.1 Erro Relativo Verdadeiro

Um defeito do erro absoluto é que ele não leva em conta a ordem de grandeza da quantidade. Por exemplo, um erro de 1 cm é irrelevante para medir uma ponte, mas crítico para medir um rebite. Para considerar a escala, define-se o **erro relativo fracionário verdadeiro**:

$$\varepsilon_t = \frac{E_t}{\text{valor verdadeiro}}$$

e o **erro relativo percentual verdadeiro**:

$$\varepsilon_t(\%) = \frac{E_t}{\text{valor verdadeiro}} \times 100\%$$

1.5.2 Dificuldade prática

Nas aplicações reais, raramente conhecemos o valor verdadeiro. Assim, o erro absoluto verdadeiro E_t e o erro relativo verdadeiro ε_t só podem ser calculados quando existe solução analítica de referência.

1.5.3 Erro Aproximado

Na ausência do valor verdadeiro, podemos normalizar o erro usando a melhor estimativa disponível, a própria aproximação corrente. Nesse caso, define-se o **erro relativo aproximado**:

$$\varepsilon_a = \frac{\text{aproximação atual} - \text{aproximação prévia}}{\text{aproximação atual}} \times 100\%$$

Esse procedimento é especialmente útil em métodos iterativos, onde uma solução corrente é obtida a partir da anterior. O erro é então estimado pela diferença entre as duas aproximações sucessivas:

$$\varepsilon_a = \frac{\hat{x}_i - \hat{x}_{i-1}}{\hat{x}_i} \times 100\%$$

1.5.4 Sinal do erro e tolerância

Os erros podem ser positivos ou negativos, dependendo se a aproximação é maior ou menor que o valor verdadeiro (ou que a aproximação anterior). Na prática, interessa mais o **valor absoluto do erro**, de forma que:

$$|\varepsilon_a| < \varepsilon_s$$

indica que o resultado está dentro da tolerância percentual pré-estabelecida ε_s .

1.5.5 Erro e Algarismos Significativos

Existe uma relação direta entre erro relativo e o número de algarismos significativos confiáveis. Segundo Scarborough (1966), se a condição

$$\varepsilon_s < 0,5 \times 10^{2-n} (\%)$$

é satisfeita, podemos ter certeza de que o resultado é correto até pelo menos n algarismos significativos.

1.6 Erros de Arredondamento

Como mencionado anteriormente, os erros de arredondamento surgem do fato de que os computadores mantêm apenas um número fixo de algarismos significativos durante os cálculos. Números como π , e ou $\sqrt{7}$ não podem ser expressos de forma exata com um número limitado de dígitos, o que introduz discrepâncias chamadas **erros de arredondamento**.

Além disso, como os computadores utilizam a base 2, certos números decimais que são exatos em base 10 não podem ser representados exatamente em binário.

1.6.1 Representação dos Números no Computador

Os erros de arredondamento estão diretamente relacionados à forma como os números são armazenados no computador. A unidade básica de armazenamento é a **palavra**, composta por uma sequência de bits (*binary digits*).

Sistemas Numéricos

O sistema decimal (base 10) é o mais familiar, mas o computador utiliza a base 2. Na notação posicional, cada algarismo indica um múltiplo da base elevada à posição.




Figura 1.3: Representação posicional em base decimal (a) e base binária (b).

1.6.2 Representação Inteira

Uma das formas mais simples de representar inteiros é reservar o primeiro bit para o sinal (0 positivo, 1 negativo), e os demais para a magnitude.

Exemplo

Considere a representação binária mostrada na figura:




Figura 1.4: Representação inteira com bit de sinal.

O primeiro bit novamente indica o sinal:

0 $\Rightarrow$ número positivo.

A magnitude corresponde ao binário:

1101001₂.

Efetuada a conversão para decimal:

$$\begin{aligned} 1101001_2 &= 1 \cdot 2^6 + 1 \cdot 2^5 + 0 \cdot 2^4 + 1 \cdot 2^3 + 0 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0, \\ &= 64 + 32 + 0 + 8 + 0 + 0 + 1 = 105. \end{aligned}$$

Assim, o valor representado é:

105.

Exemplo 2: Conversão de decimal para binário

Considere o número decimal

$$v = 105.$$

Vamos convertê-lo para binário utilizando o método das divisões sucessivas por 2. Em cada etapa, dividimos o número por 2 e anotamos o **resto**. A leitura final é feita de *baixo para cima*.

Divisão	Resto
105 ÷ 2 = 52	1
52 ÷ 2 = 26	0
26 ÷ 2 = 13	0
13 ÷ 2 = 6	1
6 ÷ 2 = 3	0
3 ÷ 2 = 1	1
1 ÷ 2 = 0	1

Sua magnitude em binário é

1101001₂.

Como o valor é positivo, o bit de sinal é

0.

Assim, a representação binária completa é:

105₁₀ = 0 1101001₂.

Limites de Representação de Inteiros

Ao representar inteiros com k bits, um dos bits é reservado para o sinal (0 para valores positivos e 1 para valores negativos), enquanto os demais armazenam a magnitude. Dessa forma, o conjunto de valores que podem ser representados é finito e possui limites bem definidos.

Forma Geral

O intervalo de inteiros representável em k bits é dado por:

$$\boxed{\left[-2^{(k-1)}, 2^{(k-1)} - 1\right]}.$$

Essa expressão permite determinar, de forma imediata, os limites mínimos e máximos da representação inteira para qualquer quantidade de bits.

Exemplos Rápidos

- $k = 8$:

$$[-2^7, 2^7 - 1] = [-128, 127].$$

- $k = 12$:

$$[-2^{11}, 2^{11} - 1] = [-2048, 2047].$$

- $k = 16$:

$$[-2^{15}, 2^{15} - 1] = [-32768, 32767].$$

1.6.3 Representação em Ponto Flutuante

Números fracionários e valores muito grandes ou muito pequenos são armazenados em **ponto flutuante**, no formato geral:

$$x = m \cdot b^e,$$

onde m é a *mantissa*, b é a base e e é o expoente.




Figura 1.5: Representação em ponto flutuante: sinal, expoente e mantissa.

A mantissa é normalmente **normalizada** de modo a aproveitar ao máximo os algarismos significativos, evitando zeros à esquerda. A normalização impõe a condição

$$\frac{1}{b} \leq m < 1.$$

Essa regra varia com a base utilizada:

- Na base 10: $0,1 \leq m < 1$
- Na base 2: $0,5 \leq m < 1$

Por exemplo,

$$\frac{1}{34} = 0,02941176 \dots$$

é normalizado como

$$0,2941 \times 10^{-1}.$$

Permitindo obter maior precisão dentro do número limitado de bits.

Formato Simplificado de Representação em Ponto Flutuante




Figura 1.6: Estrutura simplificada de ponto flutuante: s , t , expoente e e mantissa m .

Considere um formato de **8 bits** composto pelos seguintes campos:

- s : sinal do número (0 para positivo, 1 para negativo);
- t : sinal do expoente (0 para positivo, 1 para negativo);
- e : valor do expoente (em binário);
- m : valor da mantissa normalizada.

O valor decimal representado pelo conjunto de bits é dado por:

$$\text{decimal} = (-1)^s m 2^{(-1)^t e}.$$

No formato utilizado, a mantissa é composta pelos bits d_5, d_6, d_7, d_8 , representando:

$$m = \sum_{i=5}^8 d_i 2^{4-i} = \left(\frac{1}{2}\right) d_5 + \left(\frac{1}{4}\right) d_6 + \left(\frac{1}{8}\right) d_7 + \left(\frac{1}{16}\right) d_8.$$

O expoente é formado pelos bits d_3 e d_4 :

$$e = 2^1 d_3 + 2^0 d_4.$$

Assim, o valor decimal final da representação é:

$$(-1)^s \left[\left(\frac{1}{2}\right) d_5 + \left(\frac{1}{4}\right) d_6 + \left(\frac{1}{8}\right) d_7 + \left(\frac{1}{16}\right) d_8 \right] 2^{(-1)^t (2^1 d_3 + 2^0 d_4)}.$$

Exemplo

Considere agora a representação a seguir:




Figura 1.7: Exemplo de número em ponto flutuante (8 bits).

Os campos são:

$$s = 0, \quad t = 1, \quad e = (d_3 d_4) = (11), \quad m = (d_5 d_6 d_7 d_8) = (1000).$$

$$m = \left(\frac{1}{2}\right) d_5 + \left(\frac{1}{4}\right) d_6 + \left(\frac{1}{8}\right) d_7 + \left(\frac{1}{16}\right) d_8 = \frac{1}{2}.$$

$$e = 2^1 d_3 + 2^0 d_4 = 2^1(1) + 2^0(1) = 2 + 1 = 3.$$

Como $t = 1$, o expoente tem sinal negativo:

$$(-1)^t e = -3.$$

Valor representado:

$$(-1)^s m 2^{(-1)^t e} = (+1) \left(\frac{1}{2}\right) 2^{-3} = \frac{1}{16}.$$

Portanto, o valor decimal da representação é:

$$0,0625.$$

Conversão de Números Reais para Representação Binária

Para representar um número real em ponto flutuante, utilizam-se três etapas:

1. **Converter a parte inteira para binário** por divisões sucessivas por 2.
2. **Converter a parte fracionária** multiplicando por 2 e anotando os bits gerados.
3. **Normalizar a mantissa**, ajustando o expoente para que ela satisfaça

$$0,5 \leq m < 1 \quad (\text{base } 2).$$

Exemplo

Considere o número

$$x = 13,25.$$

Parte inteira:

$$13_{10} = 1101_2.$$

Parte fracionária (passo a passo):

Para converter 0,25 em binário, multiplicamos repetidamente por 2 e observamos a parte inteira gerada em cada etapa:

$$0,25 \times 2 = 0,5 \quad \Rightarrow b_1 = 0$$

$$0,5 \times 2 = 1,0 \quad \Rightarrow b_2 = 1$$

Como a parte fracionária se tornou zero, o processo termina. Logo:

$$0,25 = 0,01_2.$$

Assim,

$$13,25 = 1101,01_2.$$

Normalização:

$$1101,01_2 = 1,10101_2 \times 2^3.$$

Portanto, na forma de ponto flutuante:

$$x = m \cdot 2^e \quad \text{com} \quad m = 1,10101_2, \quad e = 3.$$

Esse procedimento permite representar qualquer número real finito no formato de ponto flutuante.

Observação: Quando pedimos a *forma normalizada*, a mantissa deve ser escrita na forma científica binária, sempre como

$$1, \text{ bits} \times 2^e.$$

Nessa forma, a mantissa pode começar com 1 normalmente. A restrição

$$0,5 \leq m < 1$$

vale apenas para a mantissa *armazenada*, onde o bit inicial 1 é implícito.

Limitações do Ponto Flutuante




Figura 1.8: Aspectos do ponto flutuante: truncamento, arredondamento, underflow e overflow.

1. **Intervalo limitado:** existem números grandes que causam *overflow* e números muito pequenos que causam *underflow* (buraco em torno do zero).
2. **Quantidade finita de representações:** irracionais e muitos racionais não podem ser representados exatamente. Surge o erro de quantização, que pode ser tratado por:
 - **Truncamento:** corta os dígitos excedentes, introduzindo um viés.
 - **Arredondamento:** aproxima para o valor mais próximo, reduzindo o erro máximo pela metade.
3. **Erro proporcional ao módulo:** à medida que os números crescem, o espaçamento Δx entre representações aumenta, tornando o erro relativo proporcional ao tamanho do número.

Exemplo

Considere o número real

$$x = 0,1.$$

No sistema de ponto flutuante binário, esse valor não pode ser representado de forma exata, pois sua expansão em base 2 é infinita:

$$0,1_{10} = 0,0001100110011 \dots_2$$

Como só há um número limitado de bits para a mantissa, o valor armazenado será uma aproximação. Por exemplo, truncando após 8 bits fracionários:

$$0,00011001_2 \quad (\text{truncado})$$

ou arredondando:

$$0,00011010_2 \quad (\text{arredondado})$$

O erro resultante é inevitável e ilustra:

- o **erro de quantização** (pois 0,1 não é representável exatamente);
- a diferença entre **truncamento** e **arredondamento**;
- o fato de que números muito próximos a zero podem sofrer *underflow* se a mantissa não comportar seus dígitos significativos.

1.6.4 Épsilon da Máquina

O **épsilon da máquina** ($\varepsilon_{\text{mach}}$) mede a menor diferença relativa entre 1 e o próximo número representável em ponto flutuante:

$$\varepsilon_{\text{mach}} = b^{1-t}$$

onde b é a base e t o número de dígitos da mantissa.

Exemplo: Considere $b = 10$ e $t = 7$ (sete algarismos significativos). O épsilon da máquina será:

$$\varepsilon_{\text{mach}} = 10^{1-7} = 10^{-6}$$

Isso significa que, nesse sistema, não é possível distinguir entre 1,000000 e 1,000001. No caso da base 2, usada em computadores reais, com $t = 24$ bits de mantissa (padrão IEEE 754 de precisão simples):

$$\varepsilon_{\text{mach}} = 2^{1-24} \approx 1,19 \times 10^{-7}$$

Ou seja, qualquer operação cujo erro seja menor que $\varepsilon_{\text{mach}}$ ficará mascarada pelo arredondamento da máquina.

1.6.5 Aritmética Computacional

Em aritmética computacional, as operações realizadas pelo computador sofrem influência direta da representação finita dos números. Isso faz com que certas operações precisem ser tratadas com cuidado especial:

- operações envolvendo números muito grandes ou muito pequenos;
- adição de valores muito diferentes em magnitude (grande + pequeno);
- cancelamento na subtração, isto é, subtrair números muito próximos;
- divisão por valores muito pequenos;
- somatórios em que um termo é muito maior que o valor parcial acumulado (“borrão”).

Exemplo

Considere os números reais:

$$x = 0,714251, \quad y = \frac{5}{7}, \quad z = 98765,9.$$

Utilizando uma representação com **5 algarismos significativos** (truncamento), temos:

$$fl(x) = 0,71425 \times 10^0,$$

$$fl(y) = 0,71428 \times 10^0,$$

$$fl(z) = 0,98765 \times 10^5.$$

Operações

1) Subtração $x - y$

$$x - y = 0,71425 - 0,71428 = -0,00003 = -0,30000 \times 10^{-4}.$$

2) Multiplicação $(x - y)z$

$$(x - y)z = (-0,30000 \times 10^{-4})(0,98765 \times 10^5) = -0,29629 \times 10^1.$$

3) Soma $x + z$

$$x + z = 0,71425 \times 10^0 + 0,98765 \times 10^5 = 0,98765 \times 10^5.$$

Erros

O erro absoluto é dado por:

$$E_T = fl(\text{op}) - \text{op exata}.$$

O erro relativo é:

$$\varepsilon_T = \frac{E_T}{\text{valor exato}}.$$

Operação	Aproximado	Exato	E_T	ε_T
$x - y$	$-0,30000 \times 10^{-4}$	$-0,347142 \times 10^{-4}$	$0,471 \times 10^{-5}$	13,6%
$(x - y)z$	$-0,29629 \times 10^1$	$-0,34285 \times 10^1$	0,4625	13,6%
$x + z$	$0,98765 \times 10^5$	$0,98766 \times 10^5$	$0,161 \times 10^1$	$0,136 \times 10^{-2}\%$

Tabela 1.1: Resultados aproximados, valores exatos e erros na aritmética com 5 algarismos.

Capítulo 2

Erros de Truncamento e Séries de Taylor

2.1 Introdução

Os **erros de truncamento** são aqueles que resultam do uso de uma aproximação no lugar de um procedimento matemático exato. Por exemplo, ao aproximar a derivada de uma função pela equação de diferenças divididas:

$$\frac{dv}{dt} \approx \frac{v(t_{i+1}) - v(t_i)}{t_{i+1} - t_i}$$

introduz-se um erro de truncamento, pois essa expressão apenas aproxima o valor verdadeiro da derivada.

Para entender melhor como esses erros surgem e como podem ser analisados, usamos uma das ferramentas matemáticas mais importantes da análise numérica: a **série de Taylor**.

2.2 A Série de Taylor

2.2.1 Teorema de Taylor

Se a função f e suas primeiras $n + 1$ derivadas forem contínuas em um intervalo que contenha o ponto a , então para qualquer x nesse intervalo, temos:

$$f(x) = f(a) + f'(a)(x - a) + \frac{f''(a)}{2!}(x - a)^2 + \cdots + \frac{f^{(n)}(a)}{n!}(x - a)^n + R_n$$

onde o resto R_n é dado por:

$$R_n = \int_a^x \frac{(x - t)^n}{n!} f^{(n+1)}(t) dt$$

Esse resultado é conhecido como a **fórmula de Taylor** ou **polinômio de Taylor**. A ideia é aproximar $f(x)$ por um polinômio em torno de a .

2.2.2 Interpretação

- O polinômio de Taylor até ordem n fornece uma aproximação de $f(x)$, cujo erro é representado pelo termo de resto R_n .
- Se R_n tende a zero quando $n \rightarrow \infty$, dizemos que a série de Taylor converge para $f(x)$.
- Quando truncamos a série em uma ordem finita, o erro de truncamento é justamente o termo de resto.

2.2.3 Primeiro Teorema do Valor Médio para Integrais

Se g é contínua em $[a, x]$, então existe ξ entre a e x tal que:

$$\int_a^x g(t) dt = g(\xi)(x - a)$$

Aplicando este resultado a R_n , obtemos que existe ξ entre a e x tal que:

$$R_n = \frac{f^{(n+1)}(\xi)}{(n+1)!}(x-a)^{n+1}$$

Essa forma é conhecida como **forma de Lagrange do resto**.

2.2.4 Segundo Teorema do Valor Médio para Integrais

Se g e h são funções contínuas em $[a, x]$ e h não muda de sinal nesse intervalo, então existe ξ entre a e x tal que:

$$\int_a^x g(t)h(t) dt = g(\xi) \int_a^x h(t) dt$$

Com isso, o termo de resto do Teorema de Taylor pode ser expresso em diferentes formas dependendo da escolha de g e h .

2.2.5 Exemplo simples

A expansão de e^x em torno de $a = 0$ é:

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots$$

Se truncarmos após o termo de ordem 2:

$$e^x \approx 1 + x + \frac{x^2}{2}$$

o erro de truncamento é dado pelo termo de resto:

$$R_2 = \frac{e^\xi}{3!}x^3, \quad \text{para algum } \xi \in [0, x].$$

2.3 Aproximação de um Polinômio por Série de Taylor

2.3.1 Enunciado do Problema

Use expansões em séries de Taylor de ordem zero até ordem quatro para aproximar a função

$$f(x) = -0,1x^4 - 0,15x^3 - 0,5x^2 - 0,25x + 1,2$$

a partir de $x_i = 0$ com $h = 1$. Isto é, estime o valor da função em $x_{i+1} = 1$.

2.3.2 Solução

O valor verdadeiro da função é:

$$f(1) = -0,1(1)^4 - 0,15(1)^3 - 0,5(1)^2 - 0,25(1) + 1,2 = 0,2$$

A Figura 2.1 mostra as aproximações obtidas com ordens crescentes da série de Taylor.




Figura 2.1: Aproximações de Taylor de diferentes ordens para a função $f(x)$.

Ordem Zero ($n = 0$)

A expansão de ordem zero é simplesmente a constante $f(0)$:

$$f(x_{i+1}) \approx f(0) = 1,2$$

Erro de truncamento:

$$E_t = 0,2 - 1,2 = -1,0$$

Ordem Um ($n = 1$)

Primeira derivada em $x = 0$:

$$f'(x) = -0,4x^3 - 0,45x^2 - 1,0x - 0,25 \Rightarrow f'(0) = -0,25$$

Aproximação:

$$f(x_{i+1}) \approx 1,2 - 0,25h = 0,95$$

Erro de truncamento:

$$E_t = 0,2 - 0,95 = -0,75$$

Ordem Dois ($n = 2$)

Segunda derivada em $x = 0$:

$$f''(x) = -1,2x^2 - 0,9x - 1,0 \Rightarrow f''(0) = -1,0$$

Aproximação:

$$f(x_{i+1}) \approx 1,2 - 0,25h - \frac{1}{2}h^2 = 0,45$$

Erro de truncamento:

$$E_t = 0,2 - 0,45 = -0,25$$

Ordem Três e Quatro ($n = 3, 4$)

Terceira e quarta derivadas:

$$f'''(x) = -2,4x - 0,9, \quad f^{(4)}(x) = -2,4$$

Logo:

$$f(x) = 1,2 - 0,25h - 0,5h^2 - 0,15h^3 - 0,1h^4$$

Com $h = 1$, obtemos:

$$f(1) = 0,2$$

que coincide exatamente com o valor verdadeiro, pois a função original é um polinômio de grau 4.

2.4 Erro de Truncamento e Ordem de Aproximação

Em geral, a expansão em série de Taylor de ordem n será **exata** para qualquer polinômio de grau n . Para outras funções diferenciáveis (exponenciais, senoidais, logarítmicas, etc.), um número finito de termos não resultará em uma estimativa exata. Apenas a soma de um número infinito de termos recupera o valor verdadeiro da função.

Na prática, entretanto, a inclusão de apenas alguns termos é suficiente para fornecer aproximações muito próximas do valor real, atendendo às necessidades de cálculo numérico.

2.4.1 O papel do termo de resto

O erro de truncamento está associado ao **resto** da expansão de Taylor, que na forma de Lagrange é dado por:

$$R_n = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x-a)^{n+1}, \quad \xi \in (a, x).$$

Essa expressão tem duas dificuldades práticas:

- ξ não é conhecido exatamente — apenas sabemos que está entre a e x .
- É necessário calcular a derivada de ordem $(n + 1)$ da função $f(x)$, o que exige conhecimento prévio da própria função.

Apesar dessas limitações, o termo de resto é útil para compreender o comportamento do erro de truncamento, especialmente em relação ao tamanho do passo h e à ordem da expansão.

2.4.2 Ordem de Grandeza do Erro

De forma geral, o erro de truncamento de uma expansão de Taylor é expresso na forma assintótica:

$$R_n = O(h^{n+1})$$

onde $O(h^{n+1})$ indica que o erro é proporcional a h^{n+1} .

Interpretação:

- Se o erro é $O(h)$, reduzir o passo h pela metade reduz o erro pela metade.
- Se o erro é $O(h^2)$, reduzir o passo h pela metade reduz o erro em um fator de 4.
- Se o erro é $O(h^3)$, reduzir h pela metade reduz o erro em um fator de 8.

2.4.3 Conclusões práticas

- A inclusão de termos adicionais na série de Taylor tende a reduzir o erro de truncamento.
- Em muitos casos, especialmente com passos h pequenos, apenas os primeiros termos de baixa ordem já capturam a maior parte do comportamento da função.
- Esse princípio fundamenta os métodos numéricos: a qualidade da aproximação é determinada tanto pela ordem da expansão quanto pelo tamanho do passo utilizado.

2.4.4 O Resto na Expansão em Série de Taylor

Antes de ilustrar como a série de Taylor é usada para estimar erros numéricos, é importante entender o motivo da inclusão do argumento ξ no termo de resto da Equação (4.8).

Uma forma de visualizar esse resultado é considerar a expansão truncada após o termo de ordem zero:

$$f(x_{i+1}) \approx f(x_i)$$

A Figura 2.2 mostra graficamente essa previsão de ordem zero e o correspondente resto R_0 , que representa a diferença entre o valor verdadeiro da função e a aproximação de ordem zero.




Figura 2.2: Visualização do resto na expansão de Taylor truncada em ordem zero.

Resto como Série Infinita

Formalmente, o resto pode ser expresso como a soma infinita dos termos truncados:

$$R_0 = f'(x_i)h + \frac{f''(x_i)}{2!}h^2 + \frac{f^{(3)}(x_i)}{3!}h^3 + \dots$$

Lidar diretamente com essa forma é inconveniente, pois envolve infinitos termos. Uma simplificação aproximada consiste em manter apenas o primeiro termo:

$$R_0 \approx f'(x_i)h$$

Mas esse resultado ainda não é exato, pois despreza contribuições das derivadas de ordem superior.

Resto via Teorema do Valor Médio

Uma alternativa elegante é usar o **Teorema do Valor Médio para Derivadas**. Esse teorema afirma que, se f e f' são contínuas em $[x_i, x_{i+1}]$, então existe um ponto $\xi \in (x_i, x_{i+1})$ tal que:

$$f'(\xi) = \frac{f(x_{i+1}) - f(x_i)}{h}$$

Geometricamente, isso significa que existe pelo menos um ponto no qual a inclinação da curva é igual à inclinação da reta secante que liga $f(x_i)$ a $f(x_{i+1})$. Rearranjando, temos:

$$R_0 = f'(\xi)h$$

Generalização

Esse raciocínio pode ser estendido para ordens superiores. Por exemplo:

$$R_1 = \frac{f''(\xi)}{2!}h^2, \quad R_2 = \frac{f^{(3)}(\xi)}{3!}h^3$$

e assim por diante.

Essa é a razão pela qual o termo de resto em Taylor sempre aparece com um parâmetro ξ , representando algum ponto dentro do intervalo considerado.

2.4.5 Usando a Série de Taylor para Fazer uma Estimativa do Erro de Truncamento

Embora a série de Taylor vá ser usada constantemente para estimar erros de truncamento ao longo deste livro, pode não estar ainda claro como a expansão se aplica dentro de um método numérico. Para deixar isso evidente, consideremos o caso de prever a velocidade $v(t)$ como função do tempo.

A expansão em Taylor é dada por:

$$v(t_{i+1}) = v(t_i) + v'(t_i)(t_{i+1} - t_i) + \frac{v''(t_i)}{2!}(t_{i+1} - t_i)^2 + \cdots + R_n$$

Se truncarmos após o termo da primeira derivada, temos:

$$v(t_{i+1}) \approx v(t_i) + v'(t_i)(t_{i+1} - t_i) + R_1 \quad (4.13)$$

Rearranjando para isolar a derivada:

$$v'(t_i) \approx \frac{v(t_{i+1}) - v(t_i)}{t_{i+1} - t_i} - \frac{R_1}{t_{i+1} - t_i} \quad (4.14)$$

A primeira parte da Equação (4.14) é exatamente a mesma fórmula de diferenças progressivas usada para aproximar a derivada (Equação (1.11)). A diferença agora é que a expansão de Taylor fornece também uma estimativa para o erro de truncamento associado.




Figura 2.3: O resto em Taylor interpretado como inclinação em um ponto ξ .

Pelo Teorema do Valor Médio, o termo de resto pode ser escrito como:

$$R_1 = \frac{v''(\xi)}{2!}(t_{i+1} - t_i)^2, \quad \xi \in (t_i, t_{i+1})$$

Substituindo em (4.14), obtemos:

$$\frac{R_1}{t_{i+1} - t_i} = \frac{v''(\xi)}{2!}(t_{i+1} - t_i) \quad (4.15)$$

Portanto, a estimativa da derivada por diferenças progressivas possui um erro de truncamento da ordem de:

$$\frac{R_1}{t_{i+1} - t_i} = O(t_{i+1} - t_i) \quad (4.16)$$

2.5 Propagação de Erros

O objetivo desta seção é entender como os erros nos números se propagam através de funções matemáticas. Por exemplo, se dois números com erro são multiplicados, como podemos estimar o erro do produto resultante?

2.5.1 Funções de uma Única Variável

Seja $f(x)$ uma função que depende de uma única variável independente x , e seja $\tilde{x}$ uma aproximação de x . Queremos estimar o efeito da discrepância entre x e $\tilde{x}$ no valor da função. Formalmente, buscamos:

$$\tilde{f}(x) = |f(x) - f(\tilde{x})|$$

O problema é que $f(x)$ é desconhecida, já que x verdadeiro é desconhecido. Podemos superar essa dificuldade supondo que $\tilde{x}$ esteja próximo de x e que $f(x)$ seja contínua e diferenciável. Nesse caso, podemos expandir $f(x)$ em série de Taylor em torno de $\tilde{x}$:

$$f(x) = f(\tilde{x}) + f'(\tilde{x})(x - \tilde{x}) + \frac{f''(\tilde{x})}{2!}(x - \tilde{x})^2 + \dots$$

Desprezando os termos de ordem 2 ou superior, obtemos:

$$f(x) - f(\tilde{x}) \approx f'(\tilde{x})(x - \tilde{x})$$

Logo, a estimativa do erro em $f(x)$ é:

$$\tilde{f}(x) = |f'(\tilde{x})| \tilde{x} \quad (4.25)$$

onde:

- $\tilde{f}(x)$ é a estimativa do erro em $f(x)$,
- $\tilde{x} = |x - \tilde{x}|$ é a estimativa do erro em x .

2.5.2 Funções de Mais de Uma Variável

A abordagem anterior pode ser generalizada para funções que dependem de múltiplas variáveis independentes. Seja $f(u, v)$ uma função de duas variáveis. A expansão em série de Taylor é:

$$f(u_{i+1}, v_{i+1}) = f(u_i, v_i) + \frac{\partial f}{\partial u}(u_{i+1} - u_i) + \frac{\partial f}{\partial v}(v_{i+1} - v_i) + \dots$$

Desprezando termos de ordem 2 ou superior, temos:

$$\tilde{f}(u, v) \approx \left| \frac{\partial f}{\partial u} \right| \tilde{u} + \left| \frac{\partial f}{\partial v} \right| \tilde{v}$$




Figura 2.4: Propagação de erros em função de uma variável: o erro da função é estimado pela inclinação $f'(\tilde{x})$ vezes o erro em x .

onde $\tilde{u}$ e $\tilde{v}$ representam as estimativas dos erros em u e v , respectivamente.

De forma mais geral, para n variáveis independentes $x_1, x_2, \dots, x_n$, vale:

$$\tilde{f}(x_1, x_2, \dots, x_n) \approx \left| \frac{\partial f}{\partial x_1} \right| \tilde{x}_1 + \left| \frac{\partial f}{\partial x_2} \right| \tilde{x}_2 + \dots + \left| \frac{\partial f}{\partial x_n} \right| \tilde{x}_n \quad (4.27)$$

2.6 Erro Numérico Total

O erro numérico total é a soma dos **erros de truncamento** e dos **erros de arredondamento**.

- O erro de truncamento pode ser reduzido diminuindo o tamanho do passo h .
- O erro de arredondamento pode ser reduzido aumentando o número de algarismos significativos do computador, mas tende a crescer devido a cancelamentos em subtrações e ao aumento do número de operações.

Assim, surge um dilema: diminuir o passo reduz o erro de truncamento, mas pode aumentar o erro de arredondamento. Em alguns casos, o remédio se torna problema: quanto menor o passo, maior o impacto dos arredondamentos, levando a um **crescimento do erro total**.

O ponto em que os erros de truncamento deixam de diminuir e os erros de arredondamento passam a dominar é chamado de **ponto de retorno diminuído**. Esse ponto representa um limite prático de acurácia para um dado método.

2.6.1 Controle dos Erros Numéricos

Na prática, raramente é possível calcular o erro exato de um método numérico. Portanto, é necessário trabalhar com estimativas e aplicar diretrizes de programação para reduzir perdas de precisão. Algumas recomendações são:




Figura 2.5: Erro total como soma dos erros de truncamento e arredondamento.

- Evitar a subtração de números quase iguais (**cancelamento catastrófico**);
- Sempre que possível, reorganizar ou reformular o problema para reduzir cancelamentos;
- Quando inevitável, utilizar aritmética com precisão estendida;
- Ao somar ou subtrair termos, operar primeiro com os números menores, reduzindo perda de significado;
- Usar a série de Taylor como ferramenta para análise teórica dos erros de truncamento e arredondamento.

2.6.2 Estimativas e Estratégias

Como não existe uma abordagem geral e exata para prever o erro numérico total, algumas estratégias comuns incluem:

- Comparar resultados obtidos com diferentes tamanhos de passo;
- Substituir soluções aproximadas de volta na equação original para verificar consistência;
- Realizar **análise de sensibilidade**, variando parâmetros e observando o impacto na solução;
- Utilizar algoritmos numéricos diferentes para o mesmo problema e comparar suas respostas;
- Em situações críticas (como projetos de engenharia de risco elevado), utilizar equipes independentes para resolver o mesmo problema e confrontar os resultados.

Capítulo 3

Raízes da Equação

3.1 Introdução

Anos atrás, você aprendeu a usar a fórmula quadrática:

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} \quad (\text{PT2.1})$$

para resolver

$$f(x) = ax^2 + bx + c = 0 \quad (\text{PT2.2})$$

Os valores obtidos pela Equação (PT2.1) são chamados de **raízes** da equação (PT2.2), pois são os valores de x que tornam $f(x) = 0$. Por isso, as raízes também são denominadas **zeros da equação**.

Embora a fórmula quadrática seja extremamente prática para equações de segundo grau, existem muitas outras funções para as quais as raízes não podem ser determinadas diretamente. Para esses casos, recorreremos aos métodos numéricos apresentados nos Capítulos 5, 6 e 7, que oferecem estratégias sistemáticas para encontrar aproximações eficazes.

3.1.1 Métodos sem o uso do Computador

Antes do advento dos computadores digitais, diversas técnicas foram utilizadas para determinar raízes de equações algébricas e transcendentais. Em alguns casos, métodos diretos como a fórmula quadrática podiam ser aplicados. Mas, em situações mais complexas, como na equação:

$$f(x) = e^{-x} - x$$

não é possível obter uma solução analítica exata.

Nesses casos, alternativas aproximadas eram usadas, como:

- **Método gráfico:** traçar o gráfico de $f(x)$ e identificar onde cruza o eixo x .
- **Tentativa e erro:** testar valores sucessivos de x até que $f(x)$ se aproxime de zero.

Embora úteis para estimativas grosseiras, esses métodos são limitados em termos de precisão e eficiência. As técnicas numéricas modernas oferecem uma abordagem sistemática e confiável, especialmente com o auxílio de computadores.

3.1.2 Fundamentos Matemáticos

Para a maioria dos tópicos discutidos neste livro, alguns pré-requisitos matemáticos são essenciais. Por exemplo, os conceitos de **estimativa do erro** e de **expansão em série de Taylor**, vistos nos Capítulos 3 e 4, têm relevância direta no estudo das raízes de equações.

Além disso, até este ponto já utilizamos os termos **equações algébricas** e **equações transcendentais**. É importante defini-los formalmente para delimitar o escopo desta parte.

Equações Algébricas

Por definição, uma função $y = f(x)$ é **algébrica** se puder ser expressa na forma:

$$f_n y^n + f_{n-1} y^{n-1} + \cdots + f_1 y + f_0 = 0 \quad (\text{PT2.5})$$

onde f_i é um polinômio de grau n em x .

Os polinômios são uma classe particular de funções algébricas, expressos como:

$$f_n(x) = a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n \quad (\text{PT2.6})$$

onde n é o grau do polinômio e os a_i são constantes.

Exemplos:

$$f_2(x) = 1 - 2,37x + 7,5x^2 \quad (\text{PT2.7})$$

$$f_6(x) = 5x^2 - x^3 + 7x^6 \quad (\text{PT2.8})$$

Equações Transcendentais

Uma função é chamada de **transcendental** quando não pode ser expressa como algébrica. Nesse grupo incluem-se:

- Funções trigonométricas,
- Exponenciais,
- Logarítmicas,
- Outras funções especiais.

Exemplos:

$$f(x) = \ln(x^2 - 1) \quad (\text{PT2.9})$$

$$f(x) = e^{-0,2x} (3x - 0,5) \quad (\text{PT2.10})$$

Natureza das Raízes

As raízes das equações, sejam elas algébricas ou transcendentais, podem ser:

- **Reais**, quando pertencem ao conjunto dos números reais;
- **Complexas**, quando envolvem a unidade imaginária $i = \sqrt{-1}$.

3.1.3 Raízes de Equações e a Prática da Engenharia

Na engenharia, as raízes de equações aparecem com frequência em problemas de **projeto**. Modelos matemáticos derivados de princípios fundamentais geralmente se expressam como equações que relacionam variáveis dependentes, independentes, parâmetros e termos forçantes.

Um exemplo é a equação da velocidade de um paraquedista em queda livre, derivada da segunda lei de Newton:

$$v = \frac{gm}{c} \left(1 - e^{-\frac{c}{m}t} \right) \quad (\text{PT2.3})$$

onde:

- v é a variável dependente (velocidade),
- t é a variável independente (tempo),
- g é a aceleração da gravidade (termo forçante),
- c é o coeficiente de arrasto (parâmetro),
- m é a massa (parâmetro).

Se os parâmetros forem conhecidos, podemos calcular diretamente $v(t)$. Mas, se desejamos determinar c de modo que o paraquedista atinja uma velocidade pré-estabelecida em certo tempo, a equação não pode ser reorganizada para isolar c . Nesse caso, c está implícito, e a solução requer métodos numéricos.

Rearranjando a equação:

$$f(c) = \frac{gm}{c} \left(1 - e^{-\frac{c}{m}t} \right) - v \quad (\text{PT2.4})$$

O valor de c que satisfaz $f(c) = 0$ é a raiz procurada, representando o coeficiente de arrasto que resolve o problema.

3.1.4 Classificação dos Problemas de Raízes

As raízes de equações podem ser reais ou complexas. Os métodos numéricos para localização de raízes se dividem em duas categorias:

1. **Determinação de raízes reais** de equações algébricas e transcendentais. Geralmente, busca-se uma única raiz real a partir de uma aproximação inicial.
2. **Determinação de todas as raízes reais e complexas de polinômios**. Esses métodos são específicos para polinômios e encontram sistematicamente todas as raízes.

3.2 Métodos Gráficos

Um método simples para obter uma estimativa da raiz da equação $f(x) = 0$ é **traçar o gráfico da função** e observar onde ela cruza o eixo dos x . Esse ponto representa o valor de x para o qual $f(x) = 0$, fornecendo assim uma aproximação grosseira da raiz.




Figura 3.1: Método gráfico: estimativa da raiz pela interseção de $f(x)$ com o eixo x .

Embora tenham aplicação limitada devido à falta de precisão, os métodos gráficos possuem utilidade prática como etapa preliminar:

- São capazes de indicar aproximadamente onde as raízes estão localizadas;
- Fornecem valores iniciais (chutes) que podem ser usados como ponto de partida para métodos numéricos mais robustos;
- Permitem detectar a existência de múltiplas raízes em um intervalo.

3.2.1 Considerações sobre a Identificação Gráfica de Raízes

Ao traçar o gráfico de uma função $f(x)$, é natural identificar possíveis raízes nos pontos em que ocorre mudança de sinal entre $f(x_l)$ e $f(x_u)$. Pelo **Teorema do Valor Intermediário**, se

$$f(x_l) \cdot f(x_u) < 0,$$

então existe pelo menos uma raiz no intervalo $[x_l, x_u]$.

Essa ideia é ilustrada na Figura 3.2, que mostra diferentes situações possíveis:

Limitações

Embora geralmente válida, essa abordagem pode falhar em alguns casos:

- **Raízes múltiplas ou tangência ao eixo x** (Figura 3.3a). Exemplo: $f(x) = (x - 2)(x - 2)(x - 4)$, em que $x = 2$ é uma raiz múltipla. Nesse caso, a função toca o eixo sem mudar de sinal.




Figura 3.2: Identificação gráfica de raízes pela mudança de sinal: (a) nenhum cruzamento; (b) uma raiz simples; (c) duas raízes; (d) múltiplas raízes no intervalo.

- **Funções descontínuas** (Figura 3.3b). O critério de mudança de sinal pode sugerir falsamente a existência de uma raiz.




Figura 3.3: Exceções: (a) raiz múltipla sem mudança de sinal; (b) descontinuidade da função.

Critério de mudança de sinal (função contínua em $[x_l, x_u]$).

- Se $f(x_l) f(x_u) > 0$, então **não há raiz** no intervalo ou há um **número par de raízes** (contando que raízes de multiplicidade par não mudam o sinal).
- Se $f(x_l) f(x_u) < 0$, então existe **pelo menos uma raiz** em (x_l, x_u) ; no total, há um **número ímpar de raízes** que provocam mudança de sinal.

Atenção: raízes múltiplas (tangência ao eixo x) *não* mudam o sinal e podem invalidar a inferência acima; descontinuidades também podem gerar falsos “cruzamentos”.

3.2.2 Uso de Gráficos Computacionais para Localizar Raízes

Os gráficos computacionais podem tornar mais rápidos e precisos os esforços para localizar raízes de equações. Considere a função

$$f(x) = (10x) \cdot \cos(3x).$$

Ela possui diversas raízes no intervalo $x \in [0, 5]$. Pacotes de software como *Excel*, *MATLAB* ou *Python (Matplotlib)* podem ser utilizados para gerar os gráficos necessários.




Figura 3.4: (a) Gráfico de $f(x)$ em $[0, 5]$, sugerindo múltiplas raízes; (b) ampliação em $[3, 5]$, evidenciando uma possível raiz dupla em torno de $x = 4, 2$; (c) zoom em $[4, 2, 4, 3]$, revelando que há, na verdade, duas raízes distintas próximas de $x = 4, 23$ e $x = 4, 26$.

3.3 O Método da Bisseção

Quando aplicamos a técnica gráfica, observamos que $f(x)$ muda de sinal em lados opostos de uma raiz. Em geral, se $f(x)$ for real e contínua no intervalo $[x_l, x_u]$ e

$$f(x_l) f(x_u) < 0,$$

então existe pelo menos uma raiz real entre x_l e x_u .

3.3.1 Descrição do Método

O **método da bisseção** (também chamado de truncamento binário ou método de Bolzano) é um método incremental que consiste em dividir repetidamente o intervalo pela metade, escolhendo o subintervalo onde ocorre a mudança de sinal.

O procedimento pode ser descrito assim:

1. Escolher aproximações inicial inferior x_l e superior x_u para a raiz, de modo que $f(x_l)f(x_u) < 0$.

2. Calcular o ponto médio:

$$x_r = \frac{x_l + x_u}{2}$$

3. Avaliar $f(x_r)$ e decidir:

- Se $f(x_l)f(x_r) < 0$, a raiz está no subintervalo $[x_l, x_r] \Rightarrow x_u = x_r$.
- Se $f(x_l)f(x_r) > 0$, a raiz está no subintervalo $[x_r, x_u] \Rightarrow x_l = x_r$.
- Se $f(x_r) = 0$, então x_r é a raiz exata e o processo para.

4. Repetir o processo até que o critério de parada seja satisfeito.




Figura 3.5: Esquema gráfico do método da bisseção: a cada iteração, o intervalo é reduzido pela metade.

3.3.2 Critério de Parada e Estimativa do Erro

Na prática, não conhecemos a raiz verdadeira para calcular o erro exato. Por isso, utilizamos o **erro relativo percentual aproximado**, definido por:

$$\varepsilon_a = \left| \frac{x_r^{novo} - x_r^{velho}}{x_r^{novo}} \right| \cdot 100\%$$

onde x_r^{novo} é a estimativa da iteração atual e x_r^{velho} a estimativa da iteração anterior.

O processo é interrompido quando:

$$\varepsilon_a < \varepsilon_s$$

onde ε_s é a tolerância pré-especificada pelo usuário.

A Figura 3.6 ilustra, para um exemplo típico, que o erro verdadeiro ε_t oscila, enquanto ε_a captura a *tendência* decrescente e, importante, **superestima** o erro verdadeiro (isto é, $\varepsilon_a \geq \varepsilon_t$ na bissecção).




Figura 3.6: Erro relativo percentual verdadeiro (cinza) e aproximado (preto) ao longo das iterações.

Por que ε_a é um limitante superior? A cada iteração sabemos que a raiz verdadeira está dentro do subintervalo escolhido. Logo, ela deve estar a no máximo $\Delta x/2$ da estimativa x_r (Figura 3.7), onde $\Delta x = x_u - x_l$ no início da iteração. Assim,

$$|x^* - x_r| \leq \frac{x_u - x_l}{2}.$$

Como, na bissecção,

$$x_r^{novo} - x_r^{velho} = \frac{x_u - x_l}{2},$$

segue que a Eq. (5.2) fornece um **limitante superior exato** para o erro verdadeiro: para excedê-lo, a raiz precisaria estar fora do intervalo corrente, o que não ocorre.




Figura 3.7: Geometria do intervalo na bissecção: a raiz verdadeira está a no máximo $\Delta x/2$ de x_r .

Forma alternativa do erro aproximado. Usando $x_r^{\text{novo}} - x_r^{\text{velho}} = \frac{x_u - x_l}{2}$ e $x_r^{\text{novo}} = \frac{x_l + x_u}{2}$ na Eq. (5.2), obtém-se a forma equivalente

$$\varepsilon_a = \left| \frac{x_u - x_l}{x_u + x_l} \right| 100\%. \quad (5.3)$$

Essa expressão é útil porque permite estimar o erro já na *primeira* iteração a partir do intervalo inicial.

Número de iterações para um erro absoluto desejado. Seja $\Delta x^{(0)} = x_u^{(0)} - x_l^{(0)}$ o comprimento inicial do intervalo. Em cada iteração, o intervalo é reduzido pela metade; portanto, após n iterações,

$$E_a^{(n)} = \frac{\Delta x^{(0)}}{2^n}. \quad (5.4)$$

Dado um erro absoluto desejado $E_{a,d}$,

$$n = \log_2 \left(\frac{\Delta x^{(0)}}{E_{a,d}} \right) = \frac{\log(\Delta x^{(0)} / E_{a,d})}{\log 2}. \quad (5.5)$$




Figura 3.8: Relação entre deslocamento das estimativas consecutivas e a meia-largura do intervalo.

3.3.3 Exemplo

Utilize o método da bisseção para encontrar a raiz da função

$$f(x) = e^{-x} - x,$$

no intervalo inicial $[0, 1]$. O processo deve ser repetido até que o erro relativo aproximado satisfaça $\varepsilon_a < 5\%$.

Estimativa prévia do número de iterações

Para um erro absoluto desejado $E_{a,d}$, o número mínimo de iterações no método da bisseção é dado por

$$n \geq \log_2 \left(\frac{x_u^{(0)} - x_l^{(0)}}{E_{a,d}} \right).$$

Se desejarmos erro absoluto menor que $E_{a,d} = 0,05$ no intervalo inicial $[0, 1]$:

$$n \geq \log_2 \left(\frac{1}{0,05} \right) = \log_2(20) \approx 4,32.$$

Portanto, serão necessárias pelo menos **5 iterações** para garantir esse erro absoluto. A Tabela 3.1 apresenta as iterações do método até atingir o critério de parada.

Tabela 3.1: Iterações do método da bisseção para $f(x) = e^{-x} - x$

i	x_l	x_u	$f(x_l)$	$f(x_u)$	x_i	$f(x_i)$	$\varepsilon_a(\%)$
1	0.00000	1.00000	1.00000	-0.63212	0.50000	0.10653	—
2	0.50000	1.00000	0.10653	-0.63212	0.75000	-0.27763	33.33
3	0.50000	0.75000	0.10653	-0.27763	0.62500	-0.08974	20.00
4	0.50000	0.62500	0.10653	-0.08974	0.56250	0.00728	11.11
5	0.56250	0.62500	0.00728	-0.08974	0.59375	-0.04150	5.26
6	0.56250	0.59375	0.00728	-0.04150	0.57813	-0.01718	2.70

Observe que na iteração 6 o erro relativo aproximado já é

$$\varepsilon_a = 2.70\% < 5\%.$$

Portanto, o processo pode ser interrompido e a raiz aproximada é

$$x \approx 0.57813.$$

Para referência, o valor exato da raiz é aproximadamente

$$x^* \approx 0.56714,$$

de modo que o erro verdadeiro percentual na última iteração é

$$\varepsilon_t = \left| \frac{x^* - x_i}{x^*} \right| \cdot 100\% = 1.93\%.$$

Assim, o método converge monotonicamente reduzindo o intervalo pela metade e produz uma estimativa com erro aceitável após poucas iterações.

3.3.4 Vantagens e Desvantagens do Método da Bissecção

O método da bissecção apresenta características muito atrativas do ponto de vista de segurança e simplicidade, mas também algumas limitações práticas em termos de eficiência. A seguir, listam-se suas principais vantagens e desvantagens.

Desvantagens

- Convergência lenta: o número de iterações pode ser muito grande até que se obtenha uma boa aproximação.
- Em certos casos, pode ocorrer comportamento oscilatório, no qual uma boa aproximação pode ser indevidamente descartada.

Vantagens

- Incondicionalmente convergente: se $f(x_l)f(x_u) < 0$, a bissecção sempre encontrará uma raiz no intervalo.
- Implementação simples e direta, de fácil programação.
- Requer apenas uma avaliação da função $f(x)$ por iteração, o que implica baixo custo computacional.

3.4 O Método da Falsa Posição

A **falsa posição** (ou *regula falsi*) é um método incremental para localizar raízes reais de funções contínuas. Assim como a bisseção, parte de um intervalo $[x_l, x_u]$ que contém uma troca de sinal,

$$f(x_l)f(x_u) < 0,$$

garantindo a existência de ao menos uma raiz nesse intervalo.

A diferença fundamental é que, em vez de dividir o intervalo ao meio, a falsa posição utiliza uma **interpolação linear** entre os pontos $(x_l, f(x_l))$ e $(x_u, f(x_u))$. A reta secante entre esses dois pontos é então prolongada até interceptar o eixo x , produzindo uma estimativa mais próxima da raiz do que a bisseção em muitos casos.

A Figura 3.9 mostra a construção geométrica da secante que define o novo ponto x_r .




Figura 3.9: Interpretação geométrica da falsa posição usando triângulos semelhantes.

Usando a semelhança entre triângulos (Figura 3.9), obtém-se a relação

$$\frac{f(x_l)}{x_r - x_l} = \frac{f(x_u)}{x_r - x_u},$$

que pode ser reorganizada para obter a forma prática da falsa posição:

$$x_r = x_u - \frac{f(x_u)(x_l - x_u)}{f(x_l) - f(x_u)}. \quad (5.7)$$

3.4.1 Comparação com o Método da Bisseção

A falsa posição geralmente converge mais rapidamente do que a bisseção, pois utiliza a inclinação da curva para escolher estimativas mais bem distribuídas no intervalo.

A Figura 3.10 mostra a comparação típica entre o erro relativo percentual verdadeiro ao longo das iterações: observe que a bisseção apresenta oscilações e convergência lenta, enquanto a falsa posição exibe uma queda mais rápida no erro.




Figura 3.10: Comparação do erro verdadeiro entre bissecção e falsa posição.

3.4.2 Exemplo

Utilize o método da falsa posição para encontrar a raiz da função

$$f(x) = e^{-x} - x,$$

no intervalo inicial $[0, 1]$. O processo deve ser repetido até que o erro relativo aproximado satisfaça $\varepsilon_a < 5\%$. A Tabela 3.2 apresenta as iterações obtidas pelo método da falsa posição.

Tabela 3.2: Iterações do método da falsa posição para $f(x) = e^{-x} - x$

i	x_l	x_u	$f(x_l)$	$f(x_u)$	x_r	$f(x_r)$	$\varepsilon_a(\%)$
1	0.00000	1.00000	1.00000	-0.63212	0.61315	-0.06503	—
2	0.00000	0.61315	1.00000	-0.06503	0.56766	-0.00253	8.00
3	0.00000	0.56766	1.00000	-0.00253	0.56716	-0.00002	0.088

Na iteração 3, o erro relativo aproximado já é:

$$\varepsilon_a = 0,088\% < 5\%.$$

Portanto, o processo pode ser interrompido, e a raiz aproximada é:

$$x \approx 0.56716.$$

resultando em um erro verdadeiro percentual:

$$\varepsilon_t = \left| \frac{x^* - x_r}{x^*} \right| 100\% = 0,0035\%.$$

O método da falsa posição atingiu o critério de parada em apenas **3 iterações**, enquanto a bisseção necessitou de **6 iterações**. Isso ocorre porque o método utiliza uma reta secante que aproxima melhor o comportamento da função, gerando avanços maiores na direção da raiz.

3.4.3 Vantagens e Desvantagens

Vantagens

- Converge mais rapidamente que a bisseção na maioria dos casos.
- Mantém a garantia de que a raiz está sempre no intervalo (não abandona a troca de sinal).
- Implementação simples, exigindo poucas operações por iteração.

Desvantagens

- Se $f(x)$ for muito inclinada em apenas um dos extremos, o método pode **prender um dos limites** e avançar lentamente.
- Isso ocorre quando uma das derivadas é muito pequena, como mostrado na Figura 3.11.
- Em tais situações, a convergência pode ser mais lenta até que a bisseção.

A Figura 3.11 evidencia o problema: com uma tangente quase horizontal, a secante intersecta o eixo x muito próximo do mesmo limite várias vezes, o que reduz drasticamente o progresso do método.




Figura 3.11: Convergência lenta da falsa posição quando $f'(x_l)$ ou $f'(x_u)$ é muito pequeno.

3.5 Métodos Abertos

Os métodos intervalares, como a biseção e a falsa posição, garantem que a raiz esteja sempre contida dentro de um intervalo $[x_l, x_u]$. A cada iteração, esse intervalo é reduzido, e o processo é intrinsecamente estável e convergente. A Figura 3.12(a) ilustra esse comportamento: a raiz está confinada entre duas extremidades que se aproximam progressivamente.

Em contraste, os **métodos abertos** utilizam fórmulas iterativas da forma

$$x_{i+1} = g(x_i),$$

que dependem apenas de um valor inicial (ou de valores que não precisam limitar a raiz). Por isso, como mostrado nas Figuras 3.12(b) e (c), o método pode:

- **divergir**, afastando-se da raiz verdadeira, ou
- **convergir rapidamente**, desde que a aproximação inicial seja adequada.

Assim, os métodos abertos apresentam maior velocidade de convergência quando funcionam, mas não possuem a garantia de convergência dos métodos intervalares.




Figura 3.12: Descrição gráfica da diferença fundamental entre os métodos intervalares (a) e os métodos abertos (b) e (c). No método intervalar, a raiz está confinada no interior do intervalo $[x_l, x_u]$. Já nos métodos abertos, usa-se uma fórmula para avançar de x_i para x_{i+1} , podendo ocorrer divergência (b) ou convergência rápida (c), dependendo da aproximação inicial.

3.6 Método do Ponto Fixo

O método do ponto fixo é uma técnica aberta baseada na reescrita da equação

$$f(x) = 0$$

na forma

$$x = g(x).$$

Uma raiz de $f(x)$ corresponde, portanto, a um *ponto fixo* da função $g(x)$.

A Figura 3.13 ilustra esse conceito para o exemplo

$$f(x) = e^{-x} - x.$$

No gráfico (a), a raiz é o ponto onde $f(x)$ cruza o eixo x . No gráfico (b), a equação é separada em duas curvas:

$$f_1(x) = x \quad \text{e} \quad f_2(x) = e^{-x},$$

cujas interseções representam exatamente o ponto em que $x = g(x)$.




Figura 3.13: Ilustração do método do ponto fixo para $f(x) = e^{-x} - x$. (a) A raiz é onde $f(x)$ cruza o eixo x . (b) Reescrevendo $f(x) = 0$ como $x = e^{-x}$, a raiz passa a ser o ponto de interseção entre $f_1(x) = x$ e $f_2(x) = e^{-x}$.

A iteração fundamental do método é dada por:

$$x_{i+1} = g(x_i).$$

Dependendo da curvatura de $g(x)$ e do valor inicial x_0 , o processo pode:

- **convergir**, aproximando-se do ponto fixo;
- **divergir**, afastando-se do ponto fixo (como ilustrado anteriormente na Figura ??b).

3.6.1 Convergência

A convergência depende da forma de $g(x)$, em especial do valor de sua derivada. Situações possíveis estão mostradas na Figura 3.14:




Figura 3.14: Comportamentos típicos da iteração $x_{i+1} = g(x_i)$: (a) convergência suave, (b) convergência lenta, (c) divergência, (d) divergência rápida.

Condição de Convergência

O Teorema do Valor Médio garante que existe um ponto $\xi \in [x_i, x_{i+1}]$ tal que:

$$g'(\xi) = \frac{g(x_{i+1}) - g(x_i)}{x_{i+1} - x_i}.$$

Assim:

$|g'(x)| < 1 \Rightarrow$ O erro diminui a cada iteração e o método converge.

$|g'(x)| > 1 \Rightarrow$ O erro aumenta e o método **poderia** divergir.

Logo, a convergência dos métodos abertos depende fortemente de uma boa escolha de $g(x)$ e de uma aproximação inicial adequada.

3.6.2 Escolha da Função $g(x)$ no Método do Ponto Fixo

Para aplicar o método do ponto fixo na solução de $f(x) = 0$, é necessário reescrever a equação na forma

$$x = g(x),$$

de modo que a sequência iterativa $x_{i+1} = g(x_i)$ seja convergente.

Entretanto, existem diversas formas possíveis de reescrever a mesma equação, e nem todas produzem convergência. Considere o exemplo:

$$f(x) = x^3 + 4x^2 - 10.$$

Três possíveis reescritas são:

$$g_1(x) = x - x^3 - 4x^2 + 10,$$

$$g_2(x) = \left(\frac{10}{x+4} \right)^{1/2},$$

$$g_3(x) = x - \frac{x^3 + 4x^2 - 10}{3x^2 + 8x}.$$

A escolha adequada depende do comportamento da derivada $g'(x)$ na vizinhança da raiz. A condição de convergência do método do ponto fixo exige:

$$|g'(x^*)| < 1,$$

onde x^* é a raiz verdadeira.

A Figura 3.15 mostra os gráficos de $g'_1(x)$, $g'_2(x)$ e $g'_3(x)$ no intervalo de interesse (aproximadamente entre $x = 1$ e $x = 1,5$), permitindo comparar suas inclinações.




Figura 3.15: Comportamento das derivadas $g'_1(x)$, $g'_2(x)$ e $g'_3(x)$ na vizinhança da raiz.

Análise das três opções

1. Função $g_1(x)$

$$g_1'(x) = 1 - 3x^2 - 8x.$$

Para valores próximos da raiz ($x \approx 1,3$), $g_1'(x)$ assume valores negativos e com grande magnitude, tipicamente $|g_1'(x)| > 1$.

$\Rightarrow$ Diverge (não adequada).

2. Função $g_2(x)$

$$g_2'(x) = -\frac{\sqrt{10}}{2}(x+4)^{-3/2}.$$

Nesta região, $g_2'(x)$ é negativo, porém com magnitude menor que 1:

$$|g_2'(x^*)| \approx 0,2 < 1.$$

$\Rightarrow$ Converge, porém lentamente.

3. Função $g_3(x)$ A derivada possui a forma

$$g_3'(x) = 1 - \frac{3x^4 + 16x^3 + 32x^2 + 60x + 80}{9x^4 + 48x^3 + 64x^2}.$$

No intervalo da raiz, observa-se graficamente que

$$|g_3'(x^*)| \ll 1.$$

$\Rightarrow$ Convergência rápida.

A análise gráfica das derivadas permite concluir que:

A melhor escolha é $g_3(x)$.

Ela satisfaz a condição $|g'(x^*)| < 1$ com grande margem e, portanto, apresenta a convergência mais rápida entre as opções avaliadas.

3.6.3 Exemplo

Utilize o método do ponto fixo para calcular a raiz da função

$$f(x) = e^{-x} - x,$$

no intervalo $[0, 1]$. Considere $x_0 = 0$ como aproximação inicial e repita o processo até que o erro relativo aproximado satisfaça $\varepsilon_a < 5\%$.

Primeiro reescrevemos a equação na forma

$$f(x) = 0 \quad \Longrightarrow \quad x = e^{-x},$$

de modo que a função de iteração é

$$g(x) = e^{-x}, \quad x_{i+1} = g(x_i).$$

Como a raiz, pelo gráfico, está em torno de $x \approx 0,5$, analisamos a derivada de g nesse ponto:

$$g'(x) = -e^{-x} \Rightarrow g'(0,5) = -e^{-0,5} \approx -0,606.$$

Assim,

$$|g'(0,5)| \approx 0,606 < 1,$$

o que indica que a iteração de ponto fixo tende a **convergir** para a raiz quando escolhemos aproximações iniciais próximas desse valor.

O erro relativo aproximado em cada iteração é dado por

$$\varepsilon_{a,i} = \left| \frac{x_i - x_{i-1}}{x_i} \right| \cdot 100\%,$$

A Tabela 3.3 apresenta as iterações até que o critério $\varepsilon_a < 5\%$ seja satisfeito.

Tabela 3.3: Iterações do método do ponto fixo para $f(x) = e^{-x} - x$ com $x_0 = 0$.

i	x_i	$g(x_i) = x_{i+1}$	$\varepsilon_{a,i}(\%)$
0	0,00000	1,00000	—
1	1,00000	0,36788	100,00
2	0,36788	0,69220	171,83
3	0,69220	0,50047	46,85
4	0,50047	0,60624	38,31
5	0,60624	0,54540	17,45
6	0,54540	0,57961	11,16
7	0,57961	0,56012	5,90
8	0,56012	0,57114	3,48

Na iteração 8 o erro relativo aproximado já é

$$\varepsilon_{a,8} = 3,48\% < 5\%,$$

de modo que o processo pode ser interrompido e obtemos como aproximação para a raiz

$$x \approx 0,56012.$$

O erro verdadeiro percentual correspondente é

$$\varepsilon_{t,8} \approx 1,24\%.$$

3.6.4 Vantagens e Desvantagens

Vantagens:

- Implementação extremamente simples;
- Baixo custo computacional;
- Requer uma única avaliação de $g(x)$ por iteração;
- Permite critério de convergência baseado em $g'(x)$.

Desvantagens:

- Convergência depende da curvatura da função;
- Escolha ruim de $g(x)$ pode causar divergência;
- Mesmo quando converge, costuma ter **convergência linear**, portanto lenta.

3.7 Método de Newton–Raphson

O método de Newton–Raphson (NR) é um dos métodos numéricos mais utilizados para o cálculo de raízes de equações não lineares do tipo

$$f(x) = 0.$$

Ele é um método aberto: utiliza apenas uma aproximação inicial x_0 (não é necessário um intervalo que contenha a raiz) e, quando converge, costuma fazê-lo muito rapidamente.

Hipóteses e ideias básicas

Suponha que $f(x)$ seja contínua e duas vezes diferenciável em um intervalo contendo a raiz x_r e a aproximação atual x_i , isto é,

$$f \in C^2[a, b].$$

Assume-se ainda que x_i esteja suficientemente próximo de x_r e que

$$f'(x_i) \neq 0.$$

A ideia geométrica do método é usar a **reta tangente** ao gráfico de $f(x)$ no ponto $(x_i, f(x_i))$. O ponto em que essa tangente intercepta o eixo x fornece uma nova aproximação x_{i+1} para a raiz.

Derivação via série de Taylor

Podemos escrever o polinômio de Taylor de primeira ordem de $f(x)$ em torno de x_i :

$$f(x) = f(x_i) + (x - x_i)f'(x_i) + \frac{(x - x_i)^2}{2}f''(\xi),$$

para algum ξ entre x e x_i .

Avaliando em $x = x_r$ (raiz), temos $f(x_r) = 0$, e desprezando o termo de segunda ordem, obtemos a aproximação

$$0 \approx f(x_i) + (x_r - x_i)f'(x_i).$$

Resolvendo para x_r , chega-se a

$$x_r \approx x_i - \frac{f(x_i)}{f'(x_i)}.$$

Fórmula iterativa

Ao interpretar a expressão anterior de forma iterativa, definimos a sequência $\{x_i\}$ pelo esquema:

$$\boxed{x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}}$$

que é chamada de **fórmula de Newton–Raphson**.

O método é repetido enquanto for possível calcular $f'(x_i)$ (ou seja, $f'(x_i) \neq 0$) e até que um critério de parada seja satisfeito. Um critério usual é o **erro relativo percentual aproximado**:

$$\varepsilon_{a,i+1} = \left| \frac{x_{i+1} - x_i}{x_{i+1}} \right| \cdot 100 < \text{TOL},$$

onde TOL é a tolerância especificada.

Quando as hipóteses são atendidas e a aproximação inicial x_0 é escolhida próxima da raiz, o método de Newton–Raphson apresenta convergência rápida, tipicamente quadrática.

3.7.1 Exemplo

Utilize o método de Newton–Raphson para calcular a raiz da função

$$f(x) = e^{-x} - x,$$

considerando $x_0 = 0$ como aproximação inicial. Repita o processo até que o erro relativo percentual aproximado satisfaça $\varepsilon_a < 5\%$.

A derivada é

$$f'(x) = -e^{-x} - 1,$$

de modo que a fórmula iterativa de Newton–Raphson fica

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}.$$

Em cada iteração calculamos

$$\varepsilon_{a,i+1} = \left| \frac{x_{i+1} - x_i}{x_{i+1}} \right| \cdot 100\%.$$

A Tabela 3.4 apresenta as iterações até que o critério $\varepsilon_a < 5\%$ seja satisfeito.

Tabela 3.4: Iterações do método de Newton–Raphson para $f(x) = e^{-x} - x$ com $x_0 = 0$.

i	x_i	$f(x_i)$	$f'(x_i)$	$\varepsilon_{a,i}(\%)$
1	0,00000	1,00000	-2,00000	—
2	0,50000	0,10653	-1,60653	11,71
3	0,56631	0,00130	-1,56762	0,15

Na iteração 3, o erro relativo aproximado já é

$$\varepsilon_{a,3} \approx 0,15\% < 5\%,$$

de modo que o processo pode ser interrompido. Assim, obtemos como aproximação para a raiz

$x \approx 0,56631.$

Comparando com os métodos anteriores, observamos que o Newton–Raphson atinge a mesma ordem de precisão em bem menos iterações, ilustrando sua convergência rápida quando as hipóteses do método são satisfeitas.

3.7.2 Problemas do Método de Newton–Raphson

Embora o método de Newton–Raphson apresente, em condições ideais, uma das formas mais rápidas de convergência entre os métodos de cálculo de raízes, ele também pode falhar ou apresentar comportamento numérico indesejado sob determinadas circunstâncias. A Figura 3.16 ilustra alguns cenários típicos que podem levar a lentidão, oscilação ou divergência.




Figura 3.16: Situações que podem causar lentidão, oscilação ou divergência no método de Newton–Raphson.

- **Inclinação muito pequena** (Figura 3.16a): Quando $f'(x_i)$ é muito próximo de zero, a tangente torna-se quase horizontal, gerando um passo extremamente longo. A iteração pode ser enviada para uma região distante da raiz, causando perda de convergência.
- **Aproximação inicial distante da raiz** (Figura 3.16b): Um ponto inicial mal escolhido pode levar a saltos de um lado para outro da função, produzindo oscilações e instabilidade.
- **Presença de máximos ou mínimos locais** (Figura 3.16c): Se a tangente intercepta o eixo em uma região que leva a um novo ponto onde a inclinação troca de sinal ou diminui muito, a sequência pode divergir ou entrar em ciclos.

- **Ponto de inflexão próximo da raiz** (Figura 3.16d): Quando $f'(x)$ se anula próximo à raiz ou quando o ponto inicial está em uma região quase plana, as iterações podem caminhar horizontalmente, progredindo de forma muito lenta.

3.7.3 Vantagens e Desvantagens

Vantagens

- **Alta velocidade de convergência:** quando a aproximação inicial está suficientemente próxima da raiz e a função atende às hipóteses de suavidade, o método apresenta **convergência quadrática**. Isso significa que o número de casas corretas aproximadamente dobra a cada iteração.
- **Poucas iterações necessárias:** métodos intervalares como bisseção reduzem o erro lentamente; já o método de Newton geralmente alcança grande precisão em poucas iterações.
- **Implementação direta:** a fórmula iterativa

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

é simples e envolve apenas avaliação da função e de sua derivada.

Desvantagens

- **Dependência forte da aproximação inicial:** se o ponto inicial estiver longe da raiz, o método pode divergir, oscilar ou ser direcionado para outra raiz.
- **Necessidade da derivada:** é preciso calcular $f'(x)$ a cada iteração, o que pode ser caro ou impraticável para algumas funções.
- **Sensível à curvatura:** proximidade de pontos onde $f'(x) = 0$ ou mudanças bruscas de concavidade podem causar:
 - aproximações que “pulam” para regiões distantes,
 - oscilações entre pontos,
 - divergência total do processo.
- **Ausência de garantias globais de convergência:** diferente de métodos intervalares, não existe garantia de que a iteração se aproximará da raiz desejada.

3.8 Método da Secante

O método de Newton–Raphson é muito eficiente, porém exige o cálculo de $f'(x)$ em todas as iterações. Para algumas funções, a derivada pode ser difícil de calcular ou envolver um número elevado de operações aritméticas. Por exemplo,

$$f(x) = x^2 3^x \cos(2x),$$

cuja derivada é bem mais trabalhosa:

$$f'(x) = 2x3^x \cos(2x) + x^2 3^x \ln 3 \cos(2x) - 2x^2 3^x \sin(2x).$$

Para contornar essa dificuldade, utiliza-se o **método da secante**, que aproxima a derivada por uma diferença finita e elimina a necessidade de calcular $f'(x)$ a cada iteração.

3.8.1 Derivação da fórmula

Recordando a definição de derivada,

$$f'(x_i) = \lim_{x \rightarrow x_i} \frac{f(x) - f(x_i)}{x - x_i},$$

podemos aproximá-la usando o ponto anterior x_{i-1} :

$$f'(x_i) \approx \frac{f(x_{i-1}) - f(x_i)}{x_{i-1} - x_i}.$$

Substituindo essa aproximação na fórmula do método de Newton–Raphson,

$$x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)},$$

obtemos o esquema iterativo da secante:

$$x_{i+1} = x_i - f(x_i) \frac{x_{i-1} - x_i}{f(x_{i-1}) - f(x_i)}$$

 (Secante)

3.8.2 Características do método

- Não requer o cálculo de derivadas.
- Necessita de **duas aproximações iniciais**: x_0 e x_1 .
- Em geral, converge mais rápido que o ponto fixo e mais devagar que Newton–Raphson.
- Pode divergir se as aproximações iniciais forem mal escolhidas.

3.8.3 Interpretação geométrica

A secante utiliza a reta que passa por $(x_{i-1}, f(x_{i-1}))$ e $(x_i, f(x_i))$ como aproximação da tangente. A interseção dessa reta com o eixo x fornece x_{i+1} .




Figura 3.17: Representação gráfica do método da secante.

3.8.4 Exemplo

Utilize o método da secante para calcular a raiz da função

$$f(x) = e^{-x} - x,$$

considerando as aproximações iniciais $x_0 = 0$ e $x_1 = 1,0$. Repita o processo até que o erro relativo aproximado satisfaça $\varepsilon_a < 5\%$.

A fórmula iterativa da secante é

$$x_{i+1} = x_i - f(x_i) \frac{x_{i-1} - x_i}{f(x_{i-1}) - f(x_i)}, \quad i = 1, 2, \dots$$

Em cada passo calculamos o erro relativo aproximado

$$\varepsilon_{a,i+1} = \left| \frac{x_{i+1} - x_i}{x_{i+1}} \right| \cdot 100\%.$$

A Tabela 3.5 apresenta as iterações até que o critério $\varepsilon_a < 5\%$ seja atendido.

Tabela 3.5: Iterações do método da secante para $f(x) = e^{-x} - x$ com $x_0 = 0$ e $x_1 = 1$.

i	x_{i-1}	x_i	x_{i+1}	$\varepsilon_{a,i+1}(\%)$
1	0,00000	1,00000	0,61270	63,21
2	1,00000	0,61270	0,56384	8,67
3	0,61270	0,56384	0,56717	0,59

Na iteração 3 o erro relativo aproximado já é

$$\varepsilon_{a,3} = 0,59\% < 5\%,$$

de modo que o processo pode ser interrompido. Assim, obtemos como aproximação para a raiz

$$x \approx 0,56717.$$

Vantagens e Desvantagens do Método da Secante

Desvantagens

- **Dependência forte das aproximações iniciais:** escolhas ruins de x_0 e x_1 podem levar à divergência ou a oscilações.
- **Não existe garantia de convergência:** como se trata de um método aberto, não há intervalo contendo a raiz para assegurar o avanço correto.
- **Requer duas aproximações iniciais:** diferentemente do método de Newton, que usa apenas uma. Isso implica maior uso de memória e maior risco de escolhas ruins.

Vantagens

- **Não precisa da derivada:** evita o custo de calcular $f'(x)$ em cada iteração, útil quando $f'(x)$ é complicada ou custosa.
- **Velocidade de convergência média:** normalmente converge mais rápido que o ponto fixo e mais devagar que Newton–Raphson.
- **Convergência superlinear:** a ordem de convergência fica entre 1 (linear) e 2 (quadrática), sendo um bom compromisso entre custo computacional e rapidez.

Capítulo 4

Equações Algébricas Lineares

Os **Sistemas de Equações Lineares e Algébricas** (SELA), aparecem de forma natural em diversos problemas científicos, especialmente em modelagem matemática de fenômenos físicos, químicos, econômicos e de engenharia.

No capítulo anterior, analisamos métodos para determinar o valor de x na equação não linear

$$f(x) = 0.$$

Esse tipo de problema é característico de sistemas *monocomponentes*. Agora, avançamos para sistemas que envolvem *múltiplas variáveis* e várias equações simultâneas.

4.1 Introdução

Em sistemas multicomponentes, diferentes grandezas interagem entre si, de modo que os valores

$$(x_1, x_2, \dots, x_n)$$

devem satisfazer simultaneamente o conjunto de equações

$$\begin{cases} f_1(x_1, x_2, \dots, x_n) = 0, \\ f_2(x_1, x_2, \dots, x_n) = 0, \\ \vdots \\ f_m(x_1, x_2, \dots, x_n) = 0. \end{cases}$$

Quando todas as funções f_i são lineares, obtemos um **SELA** — um sistema extremamente importante, pois grande parte dos métodos numéricos modernos reduz problemas complexos a sistemas lineares.

Exemplo: circuito elétrico

Considere o circuito da Figura 4.1, no qual um potencial elétrico V é aplicado entre os pontos A e G . Usando as Leis de Kirchhoff, é possível modelar o comportamento das correntes nos diferentes ramos do circuito por meio de um SELA.

As correntes i_1, i_2, i_3, i_4, i_5 satisfazem as seguintes equações:

- **Lço 1:** $f_1 : 5i_1 + 5i_2 = V$




Figura 4.1: Circuito elétrico utilizado como exemplo motivador.

- **Laço 2:** $f_2 : 5i_2 - 7i_3 - 2i_4 = 0$
- **Laço 3:** $f_3 : 2i_4 - 3i_5 = 0$
- **Junção B:** $f_4 : i_1 - i_2 - i_3 = 0$
- **Junção C:** $f_5 : i_3 - i_4 - i_5 = 0$

Resolver esse sistema significa determinar todas as correntes que satisfazem simultaneamente as equações físicas. Essa é exatamente a natureza dos SELAs.

Como resolver SELAs?

Existem duas grandes abordagens:

Métodos Analíticos

- Transformações elementares;
- Substituição sucessiva;
- Regra de Cramer.

São adequados para sistemas pequenos ($n \leq 4$). Para n grande, tornam-se inviáveis.

Métodos Numéricos

- Utilizam algoritmos eficientes;
- Funcionam para qualquer tamanho de sistema;
- Fundamentam praticamente toda a computação científica moderna.

4.1.1 Famílias de métodos numéricos para SELAs

Métodos Diretos

- Encontram a solução exata após um número fixo de operações;
- Não utilizam aproximações sucessivas;
- Estão sujeitos apenas a erros de arredondamento.

Métodos Iterativos

- A solução é construída progressivamente;
- O número de iterações não é conhecido a priori;
- Há presença de erros de truncamento e arredondamento.

4.1.2 Representação de SELAs

Notação algébrica

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1m}x_m = b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2m}x_m = b_2, \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nm}x_m = b_n. \end{cases}$$

Notação matricial

$$Ax = b, \quad A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}.$$

Matriz aumentada

$$A^* = [A \mid b] = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2m} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} & b_n \end{bmatrix}.$$

Essa notação é útil porque permite manipular toda a informação do sistema em uma única estrutura.

4.2 Tipos de SELAs

4.2.1 Independência e Dependência Linear

Ao estudar sistemas lineares, dois conceitos são essenciais para compreender a estrutura das equações: **linearmente independentes (LI)** e **linearmente dependentes (LD)**.

Equações Linearmente Independentes (LI)

Um conjunto de equações é dito **linearmente independente** quando nenhuma equação pode ser obtida como combinação linear das outras. Cada equação fornece uma informação nova para o sistema.

Exemplo

$$\begin{cases} x + y = 4, \\ 2x - y = 1 \end{cases}$$

Nenhuma equação pode ser transformada na outra. Portanto, o sistema possui duas equações LI.

Equações Linearmente Dependentes (LD)

Um conjunto de equações é **linearmente dependente** quando pelo menos uma equação é combinação linear das demais. Neste caso, há redundância — uma equação não adiciona nova informação.

Exemplo

$$\begin{cases} x + y + z = 2, \\ 2x + 2y + 2z = 4 \end{cases}$$

A segunda equação é o dobro da primeira; logo, são LD.

4.2.2 Classificação dos Sistemas Lineares

Com base no número de equações linearmente independentes, um SELA pode ser classificado em:

- **Solúvel e Determinado (SSD):** Possui uma única solução. O número de equações LI é igual ao número de incógnitas ($n = m$).

Exemplo (SSD)

$$\begin{cases} x + y = 5, \\ 2x - y = 1 \end{cases} \Rightarrow (x, y) = (2, 3).$$

- **Solúvel e Indeterminado (SSI):** Possui infinitas soluções. O número de equações LI é menor que o número de incógnitas ($n < m$).

Exemplo (SSI)

$$\begin{cases} x + y + z = 4, \\ 2x + 2y + 2z = 8 \end{cases}$$

A segunda equação é LD da primeira. Escolhendo $z = t$, obtemos infinitas soluções.

- **Insolúvel (SI):** Não possui solução. Ocorre quando há contradição ou quando o número de equações LI excede o número de incógnitas ($n > m$).

Exemplo (SI)

$$\begin{cases} x + y = 3, \\ x + y = 5 \end{cases}$$

As equações são incompatíveis — portanto, o sistema é insolúvel.

4.3 Método de Eliminação de Gauss

Seu objetivo é transformar o sistema original em um sistema equivalente cujas equações podem ser resolvidas sucessivamente por **substituição regressiva**. O método é composto por duas fases:

1. **Eliminação progressiva (ou eliminação de variáveis)** Converte a matriz aumentada do sistema em uma matriz triangular superior, anulando os elementos abaixo da diagonal principal.
2. **Substituição regressiva** Após obter uma matriz triangular superior, resolvem-se as incógnitas a partir da última equação até a primeira.

Ideia geral

Considere o sistema linear

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1, \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2, \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n. \end{cases}$$

A eliminação progressiva usa **transformações elementares de linha** para anular os coeficientes abaixo da diagonal. Em cada coluna i , utiliza-se o elemento da diagonal a_{ii} como pivô. Para eliminar o termo na linha j ($j > i$), calcula-se o multiplicador

$$m = \frac{a_{ji}}{a_{ii}}$$

e atualiza-se a linha j segundo

$$f_j \leftarrow f_j - m f_i.$$

Ao final do processo, o sistema assume a forma triangular:

$$\begin{cases} a'_{11}x_1 + a'_{12}x_2 + \cdots + a'_{1n}x_n = b'_1, \\ a'_{22}x_2 + \cdots + a'_{2n}x_n = b'_2, \\ \vdots \\ a'_{nn}x_n = b'_n, \end{cases}$$

o que permite resolver diretamente x_n e, em seguida, $x_{n-1}, x_{n-2}, \dots, x_1$.

Eliminação Progressiva

O objetivo desta etapa é zerar todos os elementos abaixo da diagonal. Para a coluna i , as linhas $j > i$ são modificadas.

O processo geral para cada pivô a_{ii} é:

1. Calcular o multiplicador $m_{ji} = \frac{a_{ji}}{a_{ii}}$.
2. Atualizar a linha:

$$\text{Linha } j \leftarrow \text{Linha } j - m_{ji} \cdot \text{Linha } i.$$

Após aplicar esse procedimento para as colunas $1, 2, \dots, n-1$, obtém-se uma matriz triangular superior.

Substituição Regressiva

Com o sistema triangular, a última equação fornece diretamente

$$x_n = \frac{b'_n}{a'_{nn}}.$$

Para cada linha acima ($i = n-1, n-2, \dots, 1$), calcula-se

$$x_i = \frac{1}{a'_{ii}} \left(b'_i - \sum_{j=i+1}^n a'_{ij} x_j \right).$$

Esse processo determina todas as incógnitas.

Custo computacional

O método de eliminação de Gauss é um algoritmo do tipo *direto* para a resolução de sistemas lineares. Ele transforma a matriz do sistema em uma matriz triangular superior por meio de transformações elementares de linha e, em seguida, aplica a substituição regressiva.

Para uma matriz densa de ordem $n \times n$, pode-se mostrar que o número de operações aritméticas (somas, subtrações, multiplicações e divisões) do processo de eliminação é da ordem de

$$\frac{2}{3}n^3 + O(n^2).$$

Assim, dizemos que o custo do método de Gauss é

$$O(n^3),$$

isto é, o algoritmo é **cúbico em n** .

Exemplo

Resolva o sistema abaixo utilizando o método de eliminação de Gauss:

$$\begin{cases} f_1 : x_1 - x_2 + 2x_3 - x_4 = -8, \\ f_2 : 2x_1 - 2x_2 + 3x_3 - 3x_4 = -20, \\ f_3 : x_1 + x_2 + x_3 = -2, \\ f_4 : x_1 - x_2 + 4x_3 + 3x_4 = 4. \end{cases}$$

Matriz aumentada inicial

$$A^* = \left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 2 & -2 & 3 & -3 & -20 \\ 1 & 1 & 1 & 0 & -2 \\ 1 & -1 & 4 & 3 & 4 \end{array} \right]$$

Etapa 1: Eliminar os elementos abaixo de a_{11}

Operação 1: $L_2 \leftarrow L_2 - 2L_1$

$$m_{21} = \frac{2}{1} = 2$$

$$\left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 0 & 0 & -1 & -1 & -4 \\ 1 & 1 & 1 & 0 & -2 \\ 1 & -1 & 4 & 3 & 4 \end{array} \right]$$

Operação 2: $L_3 \leftarrow L_3 - L_1$

$$m_{31} = 1$$

$$\left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 0 & 0 & -1 & -1 & -4 \\ 0 & 2 & -1 & 1 & 6 \\ 1 & -1 & 4 & 3 & 4 \end{array} \right]$$

Operação 3: $L_4 \leftarrow L_4 - L_1$

$$m_{41} = 1$$

$$\left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 0 & 0 & -1 & -1 & -4 \\ 0 & 2 & -1 & 1 & 6 \\ 0 & 0 & 2 & 4 & 12 \end{array} \right]$$

Troca de linhas para obter pivô não nulo

O elemento a_{22} é zero. Trocam-se então L_2 e L_3 :

$$\left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 0 & 2 & -1 & 1 & 6 \\ 0 & 0 & -1 & -1 & -4 \\ 0 & 0 & 2 & 4 & 12 \end{array} \right]$$

Etapa 2: Eliminar elementos abaixo de a_{22}

Operação 4: $L_4 \leftarrow L_4 - (m_{42})L_2$

$$m_{42} = \frac{0}{2} = 0$$

Nenhuma alteração:

$$\left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 0 & 2 & -1 & 1 & 6 \\ 0 & 0 & -1 & -1 & -4 \\ 0 & 0 & 2 & 4 & 12 \end{array} \right]$$

Etapa 3: Eliminar elementos abaixo de a_{33}

Pivô: $a_{33} = -1$.

Operação 5: $L_4 \leftarrow L_4 - (m_{43})L_3$

$$m_{43} = \frac{2}{-1} = -2$$

$$L_4 \leftarrow L_4 + 2L_3$$

$$\left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 0 & 2 & -1 & 1 & 6 \\ 0 & 0 & -1 & -1 & -4 \\ 0 & 0 & 0 & 2 & 4 \end{array} \right]$$

Sistema triangular superior obtido

$$\left[\begin{array}{cccc|c} 1 & -1 & 2 & -1 & -8 \\ 0 & 2 & -1 & 1 & 6 \\ 0 & 0 & -1 & -1 & -4 \\ 0 & 0 & 0 & 2 & 4 \end{array} \right]$$

Substituição regressiva

Linha 4:

$$2x_4 = 4 \quad \Rightarrow \quad x_4 = 2$$

Linha 3:

$$-x_3 - x_4 = -4$$

$$-x_3 - 2 = -4$$

$$x_3 = 2$$

Linha 2:

$$2x_2 - x_3 + x_4 = 6$$

$$2x_2 - 2 + 2 = 6$$

$$2x_2 = 6 \quad \Rightarrow \quad x_2 = 3$$

Linha 1:

$$x_1 - x_2 + 2x_3 - x_4 = -8$$

$$x_1 - 3 + 4 - 2 = -8$$

$$x_1 - 1 = -8 \quad \Rightarrow \quad x_1 = -7$$

$x_1 = -7,$	$x_2 = 3,$	$x_3 = 2,$	$x_4 = 2$
-------------	------------	------------	-----------

Armadilhas dos Métodos de Eliminação

Embora a eliminação de Gauss seja um método direto extremamente eficiente para resolver sistemas lineares, sua aplicação prática exige cuidado. Diversos problemas numéricos podem surgir durante o processo de eliminação ou na fase de substituição regressiva. Nesta subseção, discutimos as principais armadilhas.

Divisão por Zero

Durante o processo de eliminação, pode ocorrer a necessidade de dividir um elemento da linha por um coeficiente igual a zero. Por exemplo, ao tentar normalizar a linha cuja pivô é $a_{11} = 0$, o procedimento torna-se inválido.

Além disso, mesmo quando o pivô não é exatamente zero, valores muito próximos de zero provocam amplificação de erros e instabilidade. Uma estratégia para minimizar esse problema é o **pivotamento**, que consiste em trocar linhas para garantir que o pivô seja não nulo e preferencialmente de maior magnitude.

Erros de Arredondamento

Em computadores, todas as operações são realizadas com precisão finita. Assim, mesmo que o método esteja correto, erros de arredondamento podem se acumular ao longo das operações elementares.

Quando o sistema é grande, muitos passos de eliminação são realizados, e o erro pode se propagar de forma significativa. Se coeficientes muito pequenos forem utilizados como pivôs, a divisão por números minúsculos pode amplificar erros e degradar a precisão da solução final.

O uso de mais algarismos significativos reduz esse problema, mas não o elimina. Processos como pivotamento parcial ou total também ajudam a mitigar a propagação de erros.

Sistemas Mal Condicionados

Um sistema é dito **bem condicionado** quando pequenas alterações nos coeficientes produzem pequenas alterações nas soluções. Por outro lado, sistemas **mal condicionados** apresentam sensibilidade elevada a pequenas perturbações.

Isso significa que erros de arredondamento, mesmo mínimos, podem gerar grandes variações na solução final. A interpretação geométrica está ligada ao fato de que duas equações podem ser quase paralelas, tornando o sistema pouco estável numericamente.

A análise do condicionamento é essencial na prática computacional.

Sistemas Singulares

Um sistema singular é aquele cujo determinante da matriz é zero, o que implica ausência de solução única. A eliminação de Gauss permite detectar automaticamente a singularidade: durante o processo, se um pivô se torna zero ou se uma linha inteira torna-se nula sem que o termo independente também seja zero, o sistema é reconhecido como dependente ou inconsistente.

4.3.1 Pivotamento parcial

Na eliminação de Gauss ingênua, cada pivô a_{kk} é usado para zerar os elementos abaixo dele na mesma coluna. Quando o pivô é muito pequeno em valor absoluto, dois problemas podem aparecer:

- risco de **divisão por zero** (ou por valor muito próximo de zero);
- **amplificação de erros de arredondamento**, pois o multiplicador

$$m_{ik} = \frac{a_{ik}}{a_{kk}}$$

torna-se muito grande em módulo.

Em sistemas reais, principalmente de ordem elevada, é difícil prever quando esses erros serão significativos. As **técnicas de pivotamento** foram desenvolvidas justamente para reduzir esses efeitos.

No **pivotamento parcial**, em cada coluna k escolhemos como pivô o elemento de maior valor absoluto entre as linhas ainda não tratadas e trocamos a linha do pivô com a linha k :

$$|a_{pk}| = \max_{k \leq i \leq n} |a_{ik}|, \quad \text{troca-se } L_k \leftrightarrow L_p.$$

Depois da troca, a etapa de eliminação segue normalmente.

Exemplo

Considere o sistema:

$$\begin{cases} 0,003000 x_1 + 59,14 x_2 = 59,17, \\ 5,291 x_1 - 6,130 x_2 = 46,78. \end{cases}$$

Matriz aumentada inicial

$$A^* = \left[\begin{array}{cc|c} 0,003000 & 59,14 & 59,17 \\ 5,291 & -6,130 & 46,78 \end{array} \right]$$

Como $|0,003000| \ll |5,291|$, aplicamos **pivotamento parcial** (troca de linhas):

$$L_1 \leftrightarrow L_2$$

$$A^* = \left[\begin{array}{cc|c} 5,291 & -6,130 & 46,78 \\ 0,003000 & 59,14 & 59,17 \end{array} \right]$$

Etapa 1 — Eliminação abaixo de a_{11}

Queremos zerar a_{21} .

$$m_{21} = \frac{0,003000}{5,291} \approx 0,0005670 \quad (4 \text{ algarismos})$$

$$L_2 \leftarrow L_2 - m_{21}L_1$$

Atualizando cada elemento:

$$a'_{21} = 0,003000 - 0,0005670(5,291) \approx 0$$

$$a'_{22} = 59,14 - 0,0005670(-6,130) \approx 59,14 + 0,003476 \approx 59,14$$

$$b'_2 = 59,17 - 0,0005670(46,78) \approx 59,17 - 0,02652 \approx 59,14$$

Matriz após a eliminação

$$A^* \approx \left[\begin{array}{cc|c} 5,291 & -6,130 & 46,78 \\ 0 & 59,14 & 59,14 \end{array} \right]$$

O sistema já está triangular superior.

Substituição regressiva

Linha 2:

$$59,14 x_2 = 59,14 \quad \Rightarrow \quad x_2 \approx 1,000.$$

Linha 1:

$$5,291 x_1 - 6,130(1,000) = 46,78$$

$$5,291 x_1 = 52,91$$

$$x_1 \approx 10,00.$$

$x_1 \approx 10,00, \quad x_2 \approx 1,000.$

Custo computacional do método

O método de eliminação de Gauss exige aproximadamente

$$\frac{2}{3}n^3$$

operações aritméticas para resolver um sistema de ordem n . Por isso, dizemos que seu custo é da ordem

$$O(n^3).$$

Ao introduzir o **pivotamento parcial**, acrescentamos apenas um número quadrático de operações (procurar, em cada coluna, o maior pivô em valor absoluto). Assim, o custo total passa a ser

$$NOP_{GPP} = \frac{2}{3}n^3 + 2n^2 - \frac{5}{3}n.$$

Como o termo cúbico domina os demais, concluímos que:

O método de Gauss com pivotamento parcial **continua sendo cúbico**, isto é, $O(n^3)$;

4.3.2 Pivotamento Parcial com Escala

O pivotamento parcial com escala melhora a estabilidade numérica ao comparar cada candidato a pivô levando em conta seu **valor relativo** na linha.

Para cada linha i , define-se o **fator de escala**

$$s_i = \max_j |a_{ij}|.$$

O pivô escolhido na coluna k é aquele que maximiza

$$\frac{|a_{ik}|}{s_i}.$$

Quando necessário, as linhas são trocadas antes da etapa de eliminação.

Exemplo

Resolver o sistema usando pivotamento parcial com escala (quatro algarismos significativos):

$$\begin{cases} 30,00 x_1 + 591400 x_2 = 591700, \\ 5,291 x_1 - 6,130 x_2 = 46,78. \end{cases}$$

Matriz aumentada inicial

$$A^* = \left[\begin{array}{cc|c} 30,00 & 591400 & 591700 \\ 5,291 & -6,130 & 46,78 \end{array} \right]$$

Cálculo dos fatores de escala

$$s_1 = \max\{30,00, 591400\} = 591400, \quad s_2 = \max\{5,291, 6,130\} = 6,130.$$

Escolha do pivô na coluna 1

$$\frac{|30,00|}{591400} \approx 5,07 \times 10^{-5}, \quad \frac{|5,291|}{6130} \approx 8,64 \times 10^{-4}.$$

Como o maior valor relativo é o da linha 2, trocamos as linhas:

$$L_1 \leftrightarrow L_2, \quad A^* = \left[\begin{array}{cc|c} 5,291 & -6,130 & 46,78 \\ 30,00 & 591400 & 591700 \end{array} \right]$$

Eliminação do elemento a_{21}

$$m_{21} = \frac{30,00}{5,291} \approx 5,67.$$

$$L_2 \leftarrow L_2 - m_{21}L_1.$$

Cálculos (4 algarismos):

$$a'_{21} = 30,00 - 5,67(5,291) \approx 0,$$

$$a'_{22} = 591400 - 5,67(-6,130) \approx 591400 + 34,75 \approx 5,914 \times 10^5,$$

$$b'_2 = 591700 - 5,67(46,78) \approx 591700 - 265,2 \approx 5,915 \times 10^5.$$

$$A^* \approx \left[\begin{array}{cc|c} 5,291 & -6,130 & 46,78 \\ 0 & 5,914 \times 10^5 & 5,915 \times 10^5 \end{array} \right]$$

Substituição regressiva

$$x_2 = \frac{5,915 \times 10^5}{5,914 \times 10^5} \approx 1,000.$$

Primeira linha:

$$5,291x_1 - 6,130(1,000) = 46,78$$

$$5,291x_1 = 52,91 \quad \Rightarrow \quad x_1 \approx 10,00.$$

$x_1 \approx 10,00, \quad x_2 \approx 1,000.$

Custo Computacional O número total de operações do método de Gauss sem pivotamento é

$$NOP_G = \frac{2}{3}n^3 + \mathcal{O}(n^2).$$

Ao incluir o pivotamento parcial com escala, o custo aumenta apenas em um termo quadrático:

$$NOP_{GPPE} = \frac{2}{3}n^3 + 4n^2 - \frac{17}{3}n + 2.$$

- O método continua tendo ordem $\mathcal{O}(n^3)$;
- O acréscimo no custo é desprezível para n grande;
- A estabilidade numérica melhora significativamente.

4.3.3 Pivotamento Total

Em alguns sistemas lineares, as estratégias de pivotamento parcial, com ou sem escala, não são suficientes para evitar erros numéricos. Quando elementos muito pequenos aparecem tanto na coluna quanto na linha do pivô, pode ocorrer amplificação significativa dos erros de arredondamento. Nesse caso, utiliza-se o **pivotamento total** (ou pivotamento completo).

Ideia geral

No pivotamento total, antes de eliminar uma variável, procura-se o elemento de maior módulo no **sub-bloco ainda não processado** da matriz aumentada. Assim, o pivô passa a ser:

$$a_{pq} = \max_{i \leq k \leq n} \max_{j \leq \ell \leq n} |a_{k\ell}|.$$

Ou seja, o pivô é o elemento de maior valor absoluto dentre todos os candidatos possíveis.

Passos do pivotamento total

1. Identificar o elemento de maior módulo entre todas as posições disponíveis para pivô.
2. Realizar troca de linhas, se necessário, para trazer esse elemento para a linha pivô.
3. Realizar troca de colunas, se necessário, para colocá-lo na coluna pivô.
4. Registrar a troca de colunas, pois ela altera a ordem das variáveis.
5. Proceder normalmente com a eliminação de Gauss no elemento pivô.

Características do método

- O método reduz drasticamente o risco de divisão por valores muito pequenos.
- Melhora o condicionamento numérico da etapa de eliminação.
- Introduz troca de colunas, aumentando o custo operacional e exigindo controle da permutação das variáveis.
- Ainda assim, o custo permanece da ordem de $O(n^3)$.

Quando usar?

O pivotamento total é recomendado quando:

- o sistema é mal condicionado;
- há risco de divisões por pivôs muito pequenos;
- o pivotamento parcial não é capaz de estabilizar a eliminação;
- o problema exige alta precisão numérica.

4.3.4 Pivotamento Total

No pivotamento total, a cada etapa escolhe-se como pivô o elemento de maior módulo **em toda a submatriz ainda não processada**. Quando necessário, realizam-se trocas de linhas e colunas, registrando-se a permutação das incógnitas.

Exemplo

Considere o sistema linear

$$\begin{cases} 0x_1 + 2x_2 + x_3 = 4, \\ 1x_1 + 1x_2 - 1x_3 = 1, \\ 2x_1 - 1x_2 + 3x_3 = 9. \end{cases}$$

Matriz aumentada inicial

$$A^* = \left[\begin{array}{ccc|c} 0 & 2 & 1 & 4 \\ 1 & 1 & -1 & 1 \\ 2 & -1 & 3 & 9 \end{array} \right].$$

Etapa 1: Escolha do pivô global O maior valor absoluto da matriz é

$$\max |a_{ij}| = 3,$$

localizado em $(3, 3)$.

Fazemos troca de linha $L_1 \leftrightarrow L_3$ e troca de coluna $C_1 \leftrightarrow C_3$:

$$A^* = \left[\begin{array}{ccc|c} 3 & -1 & 2 & 9 \\ -1 & 1 & 1 & 1 \\ 1 & 2 & 0 & 4 \end{array} \right].$$

Permutação das variáveis:

$$(x_1, x_2, x_3) \longrightarrow (x_3, x_2, x_1).$$

Etapa 2: Eliminação na coluna 1

$$m_{21} = \frac{-1}{3}, \quad m_{31} = \frac{1}{3}.$$

$$L_2 \leftarrow L_2 - m_{21}L_1, \quad L_3 \leftarrow L_3 - m_{31}L_1.$$

$$A^* = \left[\begin{array}{ccc|c} 3 & -1 & 2 & 9 \\ 0 & \frac{2}{3} & \frac{5}{3} & 4 \\ 0 & \frac{7}{3} & -\frac{2}{3} & 1 \end{array} \right].$$

Etapla 3: Escolha do pivô na submatriz 2×2 Na submatriz

$$\begin{bmatrix} \frac{2}{3} & \frac{5}{3} \\ \frac{7}{3} & -\frac{2}{3} \end{bmatrix},$$

o maior valor absoluto é $\frac{7}{3}$ em $(3, 2)$.

Trocamos as linhas 2 e 3:

$$A^* = \left[\begin{array}{ccc|c} 3 & -1 & 2 & 9 \\ 0 & \frac{7}{3} & -\frac{2}{3} & 1 \\ 0 & \frac{2}{3} & \frac{5}{3} & 4 \end{array} \right].$$

Etapla 4: Eliminação na coluna 2

$$m_{32} = \frac{\frac{2}{3}}{\frac{7}{3}} = \frac{2}{7}.$$

$$L_3 \leftarrow L_3 - m_{32}L_2.$$

$$A^* = \left[\begin{array}{ccc|c} 3 & -1 & 2 & 9 \\ 0 & \frac{7}{3} & -\frac{2}{3} & 1 \\ 0 & 0 & \frac{41}{21} & \frac{26}{7} \end{array} \right].$$

Agora a matriz está triangular superior.

Etapla 5: Substituição regressiva Última linha:

$$\frac{41}{21}x'_1 = \frac{26}{7} \implies x'_1 = \frac{26}{7} \cdot \frac{21}{41} = \frac{78}{41}.$$

Segunda linha:

$$\frac{7}{3}x'_2 - \frac{2}{3}x'_1 = 1.$$

$$x'_2 = \frac{1 + \frac{2}{3}x'_1}{\frac{7}{3}} = \frac{3 + 2x'_1}{7}.$$

Substituindo $x'_1 = \frac{78}{41}$:

$$x'_2 = \frac{3 + \frac{156}{41}}{7} = \frac{\frac{279}{41}}{7} = \frac{279}{287}.$$

Primeira linha:

$$3x'_3 - x'_2 + 2x'_1 = 9.$$

$$x'_3 = \frac{9 + x'_2 - 2x'_1}{3}.$$

Substituindo valores:

$$x'_3 = \frac{9 + \frac{279}{287} - \frac{156}{41}}{3} = \frac{9 + \frac{279}{287} - \frac{1092}{287}}{3}$$

$$x'_3 = \frac{9 - \frac{813}{287}}{3} = \frac{\frac{2583}{287} - \frac{813}{287}}{3} = \frac{\frac{1770}{287}}{3} = \frac{590}{287}.$$

Etapa 6: Reverter permutação

$$(x_1, x_2, x_3) \rightarrow (x'_3, x'_2, x'_1).$$

Solução final

$$\boxed{x_1 = \frac{590}{287}, \quad x_2 = \frac{279}{287}, \quad x_3 = \frac{78}{41}.$$

4.4 Inversão de Matrizes

A inversão de matrizes é um processo fundamental em Álgebra Linear e possui diversos usos em Métodos Numéricos, como na solução de sistemas lineares e na análise de estabilidade. Nesta seção, estudamos como calcular a inversa de uma matriz por meio do método da eliminação de Gauss.

Definição

Se A é uma matriz quadrada e não singular, então existe uma matriz A^{-1} tal que:

$$AA^{-1} = A^{-1}A = I.$$

Se escrevermos $A^{-1} = B = [b_{ij}]$, então calcular a inversa equivale a resolver

$$AB = I = [I_1 \ I_2 \ \cdots \ I_n],$$

onde cada I_j é a j -ésima coluna da matriz identidade.

Isso significa que:

$$AB_j = I_j,$$

ou seja, para obter a coluna j da matriz inversa, basta resolver o sistema linear cujo vetor independente é exatamente a coluna j da identidade.

Portanto, para obter A^{-1} devemos resolver n sistemas lineares do tipo:

$$Ax = e_j,$$

onde e_j é o j -ésimo vetor canônico.

Cálculo da inversa por Gauss

Uma maneira eficiente de realizar este processo é montar a matriz aumentada

$$[A \mid I],$$

e aplicar eliminação de Gauss até obter

$$[I \mid A^{-1}].$$

Assim, a eliminação transforma simultaneamente o lado esquerdo em identidade e o lado direito passa a ser a matriz inversa procurada.

Exemplo

Calcule a inversa da matriz

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -2 \end{bmatrix}.$$

Matriz aumentada inicial Para obter A^{-1} via eliminação de Gauss, montamos a matriz aumentada com a identidade à direita:

$$\left[\begin{array}{cc|cc} 1 & 1 & 1 & 0 \\ 1 & -2 & 0 & 1 \end{array} \right].$$

Etapa 1: Eliminação de Gauss Queremos zerar o elemento abaixo de a_{11} .

Subtraímos L_1 de L_2 :

$$L_2 \leftarrow L_2 - L_1$$

$$\left[\begin{array}{cc|cc} 1 & 1 & 1 & 0 \\ 0 & -3 & -1 & 1 \end{array} \right].$$

Agora a parte à esquerda está em forma triangular superior.

Etapa 2: Substituição regressiva Agora resolvemos dois sistemas triangulares, um para cada coluna da inversa. A matriz aumentada deve ser interpretada como dois sistemas:

$$\left[\begin{array}{cc|c} 1 & 1 & 1 \\ 0 & -3 & -1 \end{array} \right] \quad (\text{coluna 1 de } B)$$

$$\left[\begin{array}{cc|c} 1 & 1 & 0 \\ 0 & -3 & 1 \end{array} \right] \quad (\text{coluna 2 de } B)$$

Vamos resolver cada um separadamente.

(a) Coluna 2 da inversa: resolução de $AB_2 = e_2$ Da segunda linha:

$$-3b_{22} = 1 \quad \Rightarrow \quad b_{22} = -\frac{1}{3}.$$

Primeira linha:

$$b_{12} + b_{22} = 0 \quad \Rightarrow \quad b_{12} = -b_{22} = \frac{1}{3}.$$

Portanto, a segunda coluna da inversa é

$$B_2 = \begin{bmatrix} b_{12} \\ b_{22} \end{bmatrix} = \begin{bmatrix} \frac{1}{3} \\ -\frac{1}{3} \end{bmatrix}.$$

(b) Coluna 1 da inversa: resolução de $AB_1 = e_1$ Da segunda linha:

$$-3b_{21} = -1 \quad \Rightarrow \quad b_{21} = \frac{1}{3}.$$

Primeira linha:

$$b_{11} + b_{21} = 1 \quad \Rightarrow \quad b_{11} = 1 - b_{21} = \frac{2}{3}.$$

Portanto, a primeira coluna da inversa é

$$B_1 = \begin{bmatrix} b_{11} \\ b_{21} \end{bmatrix} = \begin{bmatrix} \frac{2}{3} \\ \frac{1}{3} \end{bmatrix}.$$

Matriz inversa Reunindo ambas as colunas:

$$A^{-1} = \begin{bmatrix} \frac{2}{3} & \frac{1}{3} \\ \frac{1}{3} & -\frac{1}{3} \end{bmatrix}.$$

Este procedimento mostra como a eliminação de Gauss, aplicada à matriz aumentada $[A | I]$, permite construir a inversa coluna a coluna.

4.5 Fatoração LU

A fatoração LU é uma forma eficiente de resolver sistemas lineares do tipo

$$Ax = b,$$

escrevendo a matriz A como o produto de duas matrizes mais simples:

$$A = LU,$$

onde:

- L é uma matriz triangular inferior, com 1's na diagonal;
- U é uma matriz triangular superior.

A grande vantagem dessa fatoração é que, depois de escrevermos $A = LU$, resolver $Ax = b$ se reduz a dois passos simples:

$$Ax = b \quad \Rightarrow \quad LUx = b.$$

Fazemos então:

(1) Substituição progressiva: $Ly = b$,

obtendo o vetor intermediário y , e depois:

(2) Substituição regressiva: $Ux = y$,

obtendo a solução final x .

Como obter L e U ? (Ideia básica)

A fatoração LU nada mais é do que o **próprio método de eliminação de Gauss**, mas escrito de forma organizada.

- Os elementos da matriz U são os números que aparecem em A depois de fazer a eliminação de Gauss.
- Os elementos da matriz L são exatamente os multiplicadores usados durante a eliminação.

Por exemplo, ao fazermos

$$L_2 \leftarrow L_2 - m_{21}L_1, \quad m_{21} = \frac{a_{21}}{a_{11}},$$

o número m_{21} passa a ser guardado dentro da matriz L .

Assim, cada vez que “zeramos” um elemento de A usando a eliminação de Gauss, estamos automaticamente construindo uma linha de U e uma coluna de L .

Forma das matrizes

A matriz L sempre tem a forma:

$$L = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ m_{21} & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & 0 \\ m_{n1} & m_{n2} & \cdots & 1 \end{bmatrix},$$

e a matriz U é:

$$U = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{bmatrix}.$$

Quando a fatoração LU funciona?

A fatoração LU “pura” (sem pivotamento) funciona quando a eliminação de Gauss pode ser feita sem precisar trocar linhas. Em muitos casos isso é possível, mas para maior estabilidade numérica normalmente usa-se LU com pivotamento (LUP), tema que pode ser visto posteriormente.

Exemplo: fatoração LU e resolução do sistema

Considere o sistema

$$\begin{cases} x_1 + x_2 + 3x_4 = 4, \\ 2x_1 + x_2 - x_3 + x_4 = 1, \\ 3x_1 - x_2 - x_3 + 2x_4 = -3, \\ -x_1 + 2x_2 + 3x_3 - x_4 = 4. \end{cases}$$

A matriz dos coeficientes é

$$A = \begin{bmatrix} 1 & 1 & 0 & 3 \\ 2 & 1 & -1 & 1 \\ 3 & -1 & -1 & 2 \\ -1 & 2 & 3 & -1 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 1 \\ -3 \\ 4 \end{bmatrix}.$$

Vamos fatorar A na forma $A = LU$, com L triangular inferior (diagonal principal igual a 1) e U triangular superior, usando **apenas** as operações da eliminação de Gauss (sem pivoteamento).

Etapa 0: inicialização Começamos com

$$L = I_4 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad U = A = \begin{bmatrix} 1 & 1 & 0 & 3 \\ 2 & 1 & -1 & 1 \\ 3 & -1 & -1 & 2 \\ -1 & 2 & 3 & -1 \end{bmatrix}.$$

Etapa 1: zerar os elementos abaixo de u_{11} Pivô: $u_{11} = 1$. Calculamos os multiplicadores da **coluna 1**:

$$m_{21} = \frac{u_{21}}{u_{11}} = \frac{2}{1} = 2, \quad m_{31} = \frac{u_{31}}{u_{11}} = \frac{3}{1} = 3, \quad m_{41} = \frac{u_{41}}{u_{11}} = \frac{-1}{1} = -1.$$

Guardamos esses multiplicadores em L (abaixo da diagonal na coluna 1):

$$L = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 0 & 1 & 0 \\ -1 & 0 & 0 & 1 \end{bmatrix}.$$

Agora aplicamos as operações em U :

$$L_2 \leftarrow L_2 - m_{21}L_1, \quad L_3 \leftarrow L_3 - m_{31}L_1, \quad L_4 \leftarrow L_4 - m_{41}L_1.$$

$$\begin{aligned} L_2 &: [2 \ 1 \ -1 \ 1] - 2[1 \ 1 \ 0 \ 3] = [0 \ -1 \ -1 \ -5], \\ L_3 &: [3 \ -1 \ -1 \ 2] - 3[1 \ 1 \ 0 \ 3] = [0 \ -4 \ -1 \ -7], \\ L_4 &: [-1 \ 2 \ 3 \ -1] - (-1)[1 \ 1 \ 0 \ 3] = [0 \ 3 \ 3 \ 2]. \end{aligned}$$

Logo,

$$U = \begin{bmatrix} 1 & 1 & 0 & 3 \\ 0 & -1 & -1 & -5 \\ 0 & -4 & -1 & -7 \\ 0 & 3 & 3 & 2 \end{bmatrix}.$$

Etapa 2: zerar os elementos abaixo de u_{22} Pivô: $u_{22} = -1$. Calculamos os multiplicadores da **coluna 2**:

$$m_{32} = \frac{u_{32}}{u_{22}} = \frac{-4}{-1} = 4, \quad m_{42} = \frac{u_{42}}{u_{22}} = \frac{3}{-1} = -3.$$

Atualizamos L colocando esses valores na coluna 2:

$$L = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 4 & 1 & 0 \\ -1 & -3 & 0 & 1 \end{bmatrix}.$$

Aplicamos as operações em U :

$$L_3 \leftarrow L_3 - m_{32}L_2, \quad L_4 \leftarrow L_4 - m_{42}L_2.$$

$$L_3 : [0 \ -4 \ -1 \ -7] - 4[0 \ -1 \ -1 \ -5] = [0 \ 0 \ 3 \ 13],$$

$$L_4 : [0 \ 3 \ 3 \ 2] - (-3)[0 \ -1 \ -1 \ -5] = [0 \ 0 \ 0 \ -13].$$

Assim,

$$U = \begin{bmatrix} 1 & 1 & 0 & 3 \\ 0 & -1 & -1 & -5 \\ 0 & 0 & 3 & 13 \\ 0 & 0 & 0 & -13 \end{bmatrix}.$$

Etapa 3: coluna 3 O pivô é $u_{33} = 3$. O elemento abaixo dele é $u_{43} = 0$, logo o multiplicador é

$$m_{43} = \frac{0}{3} = 0,$$

e U já é triangular superior. A matriz L não se altera.

Resultado da fatoração Obtivemos

$$L = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & 4 & 1 & 0 \\ -1 & -3 & 0 & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 1 & 1 & 0 & 3 \\ 0 & -1 & -1 & -5 \\ 0 & 0 & 3 & 13 \\ 0 & 0 & 0 & -13 \end{bmatrix},$$

com $A = LU$.

Resolvendo o sistema $Ax = b$ Primeiro resolvemos o sistema *inferior* $Ly = b$ (substituição progressiva):

$$\begin{cases} y_1 = 4, \\ 2y_1 + y_2 = 1, \\ 3y_1 + 4y_2 + y_3 = -3, \\ -y_1 - 3y_2 + y_4 = 4. \end{cases} \Rightarrow \begin{cases} y_1 = 4, \\ y_2 = -7, \\ y_3 = 13, \\ y_4 = -13. \end{cases}$$

Em seguida, resolvemos o sistema *superior* $Ux = y$ (substituição regressiva):

$$\begin{cases} -13x_4 = -13, \\ 3x_3 + 13x_4 = 13, \\ -x_2 - x_3 - 5x_4 = -7, \\ x_1 + x_2 + 3x_4 = 4. \end{cases} \Rightarrow \begin{cases} x_4 = 1, \\ x_3 = 0, \\ x_2 = 2, \\ x_1 = -1. \end{cases}$$

$$\boxed{x_1 = -1, \quad x_2 = 2, \quad x_3 = 0, \quad x_4 = 1.}$$

Este exemplo mostra, passo a passo, como a eliminação de Gauss gera simultaneamente L (com os multiplicadores) e U , permitindo resolver o sistema em duas etapas simples: $Ly = b$ e $Ux = y$.

4.6 Método de Jacobi

O **método de Jacobi** é um método iterativo utilizado para resolver sistemas lineares da forma

$$Ax = b.$$

Ele parte de uma aproximação inicial $x^{(0)}$ e gera uma sequência de vetores

$$\{x^{(k)}\}_{k=0}^{\infty}$$

que, sob certas condições, converge para a solução exata.

Quando usar métodos iterativos?

Métodos iterativos são recomendados quando:

- o sistema é **grande** (com muitas equações);
- a matriz A é **esparsa** (muitos zeros);
- métodos diretos seriam muito custosos em tempo ou memória.

Para sistemas pequenos, métodos diretos como eliminação de Gauss ou fatoração LU costumam ser mais eficientes.

Ideia geral de um método iterativo

Um método iterativo transforma o sistema

$$Ax = b$$

em uma forma equivalente

$$x^{(k+1)} = Tx^{(k)} + c,$$

onde T e c dependem de A e b .

Após escolher uma aproximação inicial $x^{(0)}$, basta aplicar repetidamente a fórmula acima até que a solução pare de variar significativamente.

Elementos de um método iterativo

- **Aproximação inicial** $x^{(0)}$ Imprescindível para iniciar o processo. Muitos autores recomendam

$$x_i^{(0)} = \frac{b_i}{a_{ii}}.$$

- **Fórmula iterativa** É a regra que define como $x^{(k+1)}$ é calculado a partir de $x^{(k)}$.
- **Critério de parada** Deve garantir que a diferença entre duas iterações consecutivas é suficientemente pequena:

$$\left\| \frac{x^{(k+1)} - x^{(k)}}{x^{(k+1)}} \right\| < \varepsilon.$$

A norma mais usada é a **norma máxima**:

$$\left\| \frac{x^{(k+1)} - x^{(k)}}{x^{(k+1)}} \right\|_{\infty} = \max_{1 \leq i \leq n} \left| \frac{x_i^{(k+1)} - x_i^{(k)}}{x_i^{(k+1)}} \right| < \varepsilon.$$

Derivação da fórmula do método de Jacobi

Escrevemos o sistema linear:

$$\begin{aligned}a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1, \\a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2, \\&\vdots \\a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n.\end{aligned}$$

Isolamos x_i em cada equação:

$$x_i = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}x_j \right).$$

No método de Jacobi, **todos os valores do lado direito são tomados da iteração anterior**, resultando na fórmula:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}x_j^{(k)} \right), \quad i = 1, 2, \dots, n.$$

Convergência

Para que o método de Jacobi produza uma sequência de aproximações $x^{(0)}, x^{(1)}, x^{(2)}, \dots$ que converge para a solução exata do sistema $Ax = b$, é necessário que a matriz A satisfaça certas condições estruturais.

Duas condições clássicas (e fáceis de verificar) são:

- **Matriz diagonalmente dominante**

Dizemos que A é diagonalmente dominante por linhas se, para cada linha i ,

$$|a_{ii}| \geq \sum_{j \neq i} |a_{ij}|$$

e estritamente dominante para pelo menos uma delas.

- **Matriz simétrica e definida positiva**

A matriz é *simétrica* se $A = A^\top$, e *definida positiva* se, para qualquer vetor não nulo z ,

$$z^\top Az > 0.$$

Intuição: Uma matriz definida positiva tem um “comportamento geométrico” bem condicionado: não distorce o espaço de forma degenerada, o que garante que as iterações de Jacobi se aproximem da solução em vez de divergir.

Assim, se A satisfaz qualquer uma dessas duas condições, Jacobi é garantidamente convergente.

Exemplo

Considere o sistema linear

$$\begin{cases} 5x_1 - x_2 + x_3 = 10, \\ -2x_1 + 6x_2 + x_3 = 4, \\ x_1 + x_2 + 7x_3 = 5. \end{cases}$$

Passo 1: fórmulas de Jacobi

$$\begin{aligned} x_1^{(k+1)} &= \frac{1}{5} \left(10 + x_2^{(k)} - x_3^{(k)} \right), \\ x_2^{(k+1)} &= \frac{1}{6} \left(4 + 2x_1^{(k)} - x_3^{(k)} \right), \\ x_3^{(k+1)} &= \frac{1}{7} \left(5 - x_1^{(k)} - x_2^{(k)} \right). \end{aligned}$$

Passo 2: aproximação inicial recomendada Usamos o chute sugerido por muitos autores:

$$x_i^{(0)} = \frac{b_i}{a_{ii}}.$$

Portanto:

$$x^{(0)} = \begin{pmatrix} \frac{10}{5} \\ \frac{4}{6} \\ \frac{5}{7} \end{pmatrix} = \begin{pmatrix} 2 \\ \frac{2}{3} \\ \frac{5}{7} \end{pmatrix}.$$

Iteração 1

$$\begin{aligned} x_1^{(1)} &= \frac{1}{5} \left(10 + \frac{2}{3} - \frac{5}{7} \right) = \frac{1}{5} \left(\frac{210 + 14 - 15}{21} \right) = \frac{209}{105} \approx 1.99048, \\ x_2^{(1)} &= \frac{1}{6} \left(4 + 2(2) - \frac{5}{7} \right) = \frac{1}{6} \left(\frac{28 + 28 - 5}{7} \right) = \frac{51}{42} \approx 1.21429, \\ x_3^{(1)} &= \frac{1}{7} \left(5 - 2 - \frac{2}{3} \right) = \frac{1}{7} \left(\frac{15 - 6 - 2}{3} \right) = \frac{7}{21} = \frac{1}{3} \approx 0.33333. \end{aligned}$$

Iteração 2

$$\begin{aligned} x_1^{(2)} &= \frac{1}{5} (10 + 1.21429 - 0.33333) \approx 2.17699, \\ x_2^{(2)} &= \frac{1}{6} (4 + 2(1.99048) - 0.33333) \approx 1.60894, \\ x_3^{(2)} &= \frac{1}{7} (5 - 1.99048 - 1.21429) \approx 0.25646. \end{aligned}$$

Iteração 3

$$\begin{aligned} x_1^{(3)} &= \frac{1}{5} (10 + 1.60894 - 0.25646) \approx 2.27050, \\ x_2^{(3)} &= \frac{1}{6} (4 + 2(2.17699) - 0.25646) \approx 1.68292, \\ x_3^{(3)} &= \frac{1}{7} (5 - 2.17699 - 1.60894) \approx 0.17372. \end{aligned}$$

Erros relativos entre iterações

$$E^{(k)} = \frac{\|x^{(k)} - x^{(k-1)}\|_{\infty}}{\|x^{(k)}\|_{\infty}}.$$

Iteração	$E^{(k)}$
1	$\left\ \frac{(1.99048-2, 1.21429-\frac{2}{3}, 0.33333-\frac{5}{7})}{(1.99048, 1.21429, 0.33333)} \right\ _{\infty} \approx 0.45$
2	$\left\ \frac{(2.17699-1.99048, 1.60894-1.21429, 0.25646-0.33333)}{(2.17699, 1.60894, 0.25646)} \right\ _{\infty} \approx 0.24$
3	$\left\ \frac{(2.27050-2.17699, 1.68292-1.60894, 0.17372-0.25646)}{(2.27050, 1.68292, 0.17372)} \right\ _{\infty} \approx 0.06$

Conclusão O erro relativo diminui a cada iteração, mostrando que o método de Jacobi está convergindo para a solução do sistema.

Custo computacional e quando usar o método de Jacobi

O método de Jacobi, por ser iterativo, possui um custo computacional que depende tanto do tamanho da matriz quanto do número de iterações necessárias para que o critério de parada seja satisfeito.

Custo computacional Em cada iteração, o método calcula um novo vetor $x^{(k+1)}$ a partir de $x^{(k)}$. Cada componente $x_i^{(k+1)}$ exige percorrer aproximadamente uma linha da matriz A , com n operações. Assim:

$$\text{Custo por iteração} = O(n^2).$$

Se forem necessárias k iterações até convergir, então:

$$\text{Custo total} = O(k) O(n^2).$$

Ou seja,

- é **quadrático** no tamanho da matriz (n^2);
- é **linear** no número de iterações (k).

Quando usar Jacobi em vez da eliminação de Gauss? Para sistemas de grande porte ($n > 50$) ou esparsos, o Jacobi tende a ser mais eficiente e mais simples de implementar.

4.7 Método de Gauss–Seidel

O método iterativo de Gauss–Seidel é um aprimoramento do método de Jacobi. A ideia central é utilizar imediatamente os valores mais recentes à medida que são calculados, acelerando a convergência.

Fórmula iterativa

A fórmula de Jacobi utiliza apenas os valores da iteração anterior $x^{(k-1)}$. Já no método de Gauss–Seidel, quando calculamos $x_i^{(k)}$, os valores $x_1^{(k)}, \dots, x_{i-1}^{(k)}$ já foram atualizados e *devem* ser utilizados:

$$x_i^{(k)} = \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k-1)} \right].$$

Isso torna o método, em geral, mais rápido que Jacobi.

Exemplo

Realize três iterações para resolver o sistema:

$$\begin{bmatrix} 6 & -1 & 3 \\ 1 & 3 & 1 \\ 3 & -1 & 5 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 13 \\ 10 \\ 16 \end{bmatrix}.$$

Aproximação inicial sugerida:

$$x_i^{(0)} = \frac{b_i}{a_{ii}} \Rightarrow x^{(0)} = \left(\frac{13}{6}, \frac{10}{3}, \frac{16}{5} \right)^T.$$

$$x^{(0)} = (2.1667, 3.3333, 3.2000)^T.$$

A norma de erro utilizada será a **norma máxima**:

$$\|x^{(k)} - x^{(k-1)}\|_\infty = \max_i |x_i^{(k)} - x_i^{(k-1)}|.$$

Iteração 1

$$x_0^{(1)} = \frac{1}{6} (13 + x_1^{(0)} - 3x_2^{(0)}) = \frac{1}{6} (13 + 3.3333 - 9.6000) = 1.4556,$$

$$x_1^{(1)} = \frac{1}{3} (10 - x_0^{(1)} - x_2^{(0)}) = \frac{1}{3} (10 - 1.4556 - 3.2000) = 1.7815,$$

$$x_2^{(1)} = \frac{1}{5} (16 - 3x_0^{(1)} + x_1^{(1)}) = \frac{1}{5} (16 - 4.3668 + 1.7815) = 2.6829.$$

$$x^{(1)} = (1.4556, 1.7815, 2.6829)^T.$$

Erro:

$$E_1 = \|x^{(1)} - x^{(0)}\|_\infty = \max(0.7111, 1.5518, 0.5171) = 1.5518.$$

Iteração 2

$$x_0^{(2)} = \frac{1}{6}(13 + 1.7815 - 3(2.6829)) = \frac{1}{6}(13 + 1.7815 - 8.0487) = 1.4555,$$

$$x_1^{(2)} = \frac{1}{3}(10 - 1.4555 - 2.6829) = 1.9539,$$

$$x_2^{(2)} = \frac{1}{5}(16 - 3(1.4555) + 1.9539) = 2.9174.$$

$$x^{(2)} = (1.4555, 1.9539, 2.9174)^T.$$

Erro:

$$E_2 = \|x^{(2)} - x^{(1)}\|_\infty = \max(0.0001, 0.1724, 0.2345) = 0.2345.$$

Iteração 3

$$x_0^{(3)} = \frac{1}{6}(13 + 1.9539 - 3(2.9174)) = 1.3678,$$

$$x_1^{(3)} = \frac{1}{3}(10 - 1.3678 - 2.9174) = 1.9049,$$

$$x_2^{(3)} = \frac{1}{5}(16 - 3(1.3678) + 1.9049) = 2.9603.$$

$$x^{(3)} = (1.3678, 1.9049, 2.9603)^T.$$

Erro:

$$E_3 = \|x^{(3)} - x^{(2)}\|_\infty = \max(0.0877, 0.0490, 0.0429) = 0.0877.$$

Resumo das iterações

k	$x^{(k)}$	E_k
0	(2.1667, 3.3333, 3.2000)	—
1	(1.4556, 1.7815, 2.6829)	1.5518
2	(1.4555, 1.9539, 2.9174)	0.2345
3	(1.3678, 1.9049, 2.9603)	0.0877

Observamos que o erro diminui rapidamente, como é típico do método de Gauss–Seidel quando a matriz é bem-comportada.

Condição de Convergência

Se a matriz A é **diagonalmente dominante de maneira estrita**, então, para qualquer escolha de aproximação inicial $x^{(0)}$, tanto o método de Jacobi quanto o de Gauss–Seidel convergem para a solução única do sistema $Ax = b$.

Diagonal dominante Dizemos que A é **diagonalmente dominante por linhas** se

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \quad i = 1, 2, \dots, n.$$

Ou seja, em cada linha, o valor absoluto do elemento da diagonal deve ser estritamente maior que a soma dos valores absolutos dos demais elementos da linha.

Observações importantes

- A condição de diagonal dominante é **suficiente**, mas não **necessária**. Ou seja:
 - se A for diagonalmente dominante, o método *certamente* converge;
 - se não for, *não podemos garantir nem descartar* a convergência.
- Quando a condição não é satisfeita, é preciso **monitorar o erro** para verificar empiricamente o comportamento do método.
- Se o erro relativo entre iterações consecutivas:

$$\frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k+1)}\|}$$

- **decresce**, o método tende a convergir;
 - **aumenta ou oscila**, o método diverge.
- Existe relação com erros de truncamento: métodos iterativos acumulam erros a cada passo, por isso a análise de convergência é crucial para garantir a estabilidade do processo.

4.8 Métodos de Relaxamento

Os métodos de relaxamento são uma alternativa ao método de Gauss–Seidel e têm dois objetivos principais:

- acelerar a convergência;
- obter convergência mesmo em sistemas que divergem ou convergem muito lentamente sob Gauss–Seidel.

A ideia consiste em aplicar uma **correção ponderada** aos valores obtidos pelo método de Gauss–Seidel. Para cada componente $x_i^{(k)}$ da iteração k , define-se:

$$x_{i,\text{REL}}^{(k)} = \omega x_{i,\text{GS}}^{(k)} + (1 - \omega)x_{i,\text{REL}}^{(k-1)},$$

onde ω é um **fator de peso** com $0 < \omega < 2$.

Tipos de relaxamento

- Se $\omega = 1$, obtemos exatamente Gauss–Seidel.
- Se $0 < \omega < 1$, temos **sub-relaxamento**: diminui-se o peso da nova iteração.
 - bom para sistemas que divergem;
 - reduz oscilações;
 - pode acelerar a convergência em sistemas sensíveis.
- Se $1 < \omega < 2$, temos **sobre-relaxamento**: aumenta-se o peso da nova iteração.
 - acelera bastante a convergência em sistemas bem-comportados;
 - o valor ótimo de ω costuma estar entre 1 e 1,2.

Exemplo 4: Sub-relaxamento e sobre-relaxamento

Considere o sistema:

$$\begin{bmatrix} 6 & -1 & 3 \\ 1 & 3 & 1 \\ 3 & -1 & 5 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 13 \\ 10 \\ 16 \end{bmatrix}.$$

O chute inicial será:

$$x^{(0)} = (0, 0, 0)^T.$$

As fórmulas de Gauss–Seidel para o sistema são:

$$x_0^{(k)} = \frac{1}{6} \left(13 + x_1^{(k-1)} - 3x_2^{(k-1)} \right),$$

$$x_1^{(k)} = \frac{1}{3} \left(10 - x_0^{(k)} - x_2^{(k-1)} \right),$$

$$x_2^{(k)} = \frac{1}{5} \left(16 - 3x_0^{(k)} + x_1^{(k)} \right).$$

Caso 1: Sub-relaxamento com $\omega = 0,92$

Aplicamos

$$x_{i,\text{REL}}^{(k)} = 0,92 x_{i,\text{GS}}^{(k)} + 0,08 x_{i,\text{REL}}^{(k-1)}.$$

Iteração 1 Gauss–Seidel puro:

$$x_{\text{GS}}^{(1)} = \left(\frac{13}{6}, \frac{10 - \frac{13}{6}}{3}, \frac{16 - 3\frac{13}{6} + \frac{47}{18}}{5} \right) = (2.1667, 2.0556, 1.2444).$$

Sub-relaxado:

$$x_{\text{REL}}^{(1)} = 0.92 x_{\text{GS}}^{(1)} = (1.993, 1.891, 1.144).$$

Erro relativo (norma máxima):

$$E_1 = \|x^{(1)}\|_{\infty} = 1.993.$$

Iteração 2 Aplicamos as fórmulas usando $x_{\text{REL}}^{(1)}$.

Gauss–Seidel obtém:

$$x_{\text{GS}}^{(2)} = (1.537, 2.187, 1.166).$$

Sub-relaxamento:

$$x_{\text{REL}}^{(2)} = 0.92 x_{\text{GS}}^{(2)} + 0.08 x_{\text{REL}}^{(1)} = (1.549, 2.179, 1.164).$$

Erro relativo:

$$E_2 = \frac{\|x_{\text{REL}}^{(2)} - x_{\text{REL}}^{(1)}\|_{\infty}}{\|x_{\text{REL}}^{(2)}\|_{\infty}} = 0.34.$$

Iteração 3 Procedimento idêntico:

$$x_{\text{GS}}^{(3)} = (1.531, 2.085, 1.184),$$

$$x_{\text{REL}}^{(3)} = (1.540, 2.093, 1.182).$$

Erro:

$$E_3 = 0.04.$$

Caso 2: Sobre-relaxamento com $\omega = 1,08$

$$x_{i,\text{REL}}^{(k)} = 1,08 x_{i,\text{GS}}^{(k)} - 0,08 x_{i,\text{REL}}^{(k-1)}.$$

Iteração 1

$$x_{\text{REL}}^{(1)} = 1,08 x_{\text{GS}}^{(1)} = (2,340, 2,220, 1,344).$$

Erro:

$$E_1 = 2,340.$$

Iteração 2 Gauss–Seidel:

$$x_{\text{GS}}^{(2)} = (1,464, 2,201, 1,192).$$

Sobre-relaxamento:

$$x_{\text{REL}}^{(2)} = 1,08(1,464, 2,201, 1,192) - 0,08(2,340, 2,220, 1,344) = (1,398, 2,194, 1,180).$$

Erro:

$$E_2 = 0,40.$$

Iteração 3 Gauss–Seidel:

$$x_{\text{GS}}^{(3)} = (1,528, 2,095, 1,182).$$

Sobre-relaxamento:

$$x_{\text{REL}}^{(3)} = 1,08(1,528, 2,095, 1,182) - 0,08(1,398, 2,194, 1,180) = (1,540, 2,088, 1,182).$$

Erro:

$$E_3 = 0,04.$$

Conclusões do exemplo

- Ambos os métodos convergem.
- O sobre-relaxamento ($\omega = 1,08$) converge mais rápido.
- Os valores estabilizam após poucas iterações.

Capítulo 5

Interpolação Polinomial

A interpolação polinomial é um dos métodos mais clássicos para estimar valores intermediários entre dados conhecidos. A ideia fundamental é simples: dados $n + 1$ pontos distintos, existe um *único* polinômio de grau n que passa por todos esses pontos.

Recorde que um polinômio de grau n pode ser escrito como

$$f(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n.$$

Quando possuímos $n + 1$ pares (x_i, y_i) , há exatamente um polinômio de grau n que satisfaz

$$p(x_i) = y_i, \quad i = 0, 1, \dots, n.$$

Por exemplo:

- Com dois pontos, existe uma **reta** (polinômio de grau 1) que os liga.
- Com três pontos, existe uma **parábola** (grau 2) que passa por eles.

Assim, o processo de interpolação consiste em determinar esse polinômio único que reconstrói exatamente os valores tabelados. Contudo, há diferentes formas de expressá-lo.

Teorema de Weierstrass. Suponha que $f(x)$ seja contínua em um intervalo fechado $[a, b]$. Então, para qualquer $\varepsilon > 0$, existe um polinômio $P(x)$ tal que

$$|f(x) - P(x)| < \varepsilon, \quad \text{para todo } x \in [a, b].$$




Figura 5.1: Aproximação de uma função contínua por um polinômio interpolador.

A figura ilustra a ideia: o polinômio interpolador $P(x)$ (em vermelho) aproxima a função $f(x)$ (em azul) dentro de uma “faixa” delimitada por $f(x) \pm \varepsilon$.

Assim, a interpolação polinomial não apenas reconstrói exatamente os valores conhecidos, mas também possibilita criar aproximações úteis para valores entre os pontos tabelados.

5.1 Polinômios de Taylor

Os polinômios de Taylor são utilizados para aproximar funções por meio de polinômios que reproduzem não apenas o valor da função em um ponto, mas também suas derivadas. Essa ideia é fundamental em diversas áreas da análise numérica, como integração, derivação numérica e solução aproximada de equações.

Definição

O polinômio de Taylor de grau n da função $f(x)$ em torno de um ponto x_0 é definido por

$$P_n(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{f''(x_0)}{2!}(x - x_0)^2 + \cdots + \frac{f^{(n)}(x_0)}{n!}(x - x_0)^n.$$

Esse polinômio possui as seguintes propriedades:

- $P_n(x_0) = f(x_0)$ (valor coincidente);
- $P'_n(x_0) = f'(x_0)$ (mesma inclinação);
- $P''_n(x_0) = f''(x_0)$ (mesma convexidade);
- Em geral, $P_n^{(k)}(x_0) = f^{(k)}(x_0)$ para $k = 0, 1, \dots, n$.

Erro do polinômio de Taylor

O erro (termo de resto) associado à aproximação é dado por

$$R_n(x) = f(x) - P_n(x) = \frac{f^{(n+1)}(\zeta)}{(n+1)!}(x - x_0)^{n+1}, \quad \zeta \in (x_0, x).$$

Uma cota superior para o erro pode ser obtida estimando-se o máximo da derivada $f^{(n+1)}(x)$ no intervalo de interesse.

Exemplo 1

Considere a função $f(x) = \sqrt{1+x}$ e determine:

1. o polinômio de Taylor de grau 3 em torno de $x_0 = 0$;
2. uma aproximação para $f(0,1)$, o erro absoluto e um limite teórico para o erro;
3. utilize o polinômio para aproximar a integral

$$\int_0^{0.1} \sqrt{1+x} \, dx,$$

e determine o erro relativo.

(a) Cálculo das derivadas

$$f(x) = (1+x)^{1/2}$$

$$f'(x) = \frac{1}{2}(1+x)^{-1/2}, \quad f''(x) = -\frac{1}{4}(1+x)^{-3/2}, \quad f'''(x) = \frac{3}{8}(1+x)^{-5/2}.$$

Avaliando em $x_0 = 0$:

$$f(0) = 1, \quad f'(0) = \frac{1}{2}, \quad f''(0) = -\frac{1}{4}, \quad f'''(0) = \frac{3}{8}.$$

Polinômio de Taylor de grau 3

$$P_3(x) = 1 + \frac{1}{2}x - \frac{1}{8}x^2 + \frac{1}{16}x^3.$$

(b) Aproximação de $f(0,1)$ Valor pelo polinômio:

$$P_3(0.1) = 1 + \frac{1}{2}(0.1) - \frac{1}{8}(0.1)^2 + \frac{1}{16}(0.1)^3.$$

$$P_3(0.1) = 1 + 0.05 - 0.00125 + 0.0000625 = 1.0488125.$$

Valor exato:

$$f(0.1) = \sqrt{1.1} \approx 1.048808848.$$

Erro absoluto:

$$E = |f(0.1) - P_3(0.1)| \approx 3.65 \times 10^{-6}.$$

Limite superior do erro O termo de resto é:

$$R_3(x) = \frac{f^{(4)}(\zeta)}{4!}x^4.$$

Como

$$f^{(4)}(x) = -\frac{15}{16}(1+x)^{-7/2},$$

temos no intervalo $0 \leq x \leq 0.1$:

$$|f^{(4)}(\zeta)| \leq \frac{15}{16}.$$

Logo,

$$|R_3(0.1)| \leq \frac{15}{16} \frac{(0.1)^4}{24} = 3.9 \times 10^{-6}.$$

(c) Aproximação da integral

$$\int_0^{0.1} f(x) dx \approx \int_0^{0.1} P_3(x) dx = \int_0^{0.1} \left(1 + \frac{1}{2}x - \frac{1}{8}x^2 + \frac{1}{16}x^3\right) dx.$$

Calculando:

$$\begin{aligned} \int_0^{0.1} 1 dx &= 0.1, & \int_0^{0.1} \frac{1}{2}x dx &= 0.0025, \\ \int_0^{0.1} -\frac{1}{8}x^2 dx &= -0.000041666, & \int_0^{0.1} \frac{1}{16}x^3 dx &= 0.000000625. \end{aligned}$$

Somando:

$$I_{\text{approx}} = 0.10245896.$$

Valor exato:

$$I_{\text{exato}} = \left[\frac{2}{3}(1+x)^{3/2} \right]_0^{0.1} \approx 0.1025.$$

Erro relativo:

$$\varepsilon_{\text{rel}} = \frac{|I_{\text{exato}} - I_{\text{approx}}|}{I_{\text{exato}}} \approx 4.0 \times 10^{-4}.$$

Limitações dos Polinômios de Taylor

Ao utilizarmos expansões polinomiais, muitas vezes desejamos uma aproximação relativamente precisa ao longo de *todo* um intervalo. No entanto, os polinômios de Taylor apresentam limitações importantes:

- Os polinômios de Taylor geralmente **não fornecem** boas aproximações em intervalos largos.
- A aproximação é construída apenas a partir das informações de um único ponto x_0 .
- Consequentemente, o uso dos polinômios de Taylor é limitado a valores de x próximos de x_0 .
- Outra desvantagem prática: é necessário conhecer várias derivadas da função f no ponto x_0 , o que pode ser difícil ou impraticável.

Quando a aproximação de Taylor é útil?

- Para intervalos pequenos na vizinhança do ponto x_0 .
- Para aproximar funções complexas localmente, com baixo custo computacional.

5.2 Polinômio de Lagrange

A interpolação de Lagrange fornece uma forma explícita e direta de construir o polinômio interpolador que passa por todos os pontos dados. Seja um conjunto de $n + 1$ pontos distintos

$$(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n),$$

onde $y_k = f(x_k)$. Queremos encontrar um polinômio $P_n(x)$ de grau no máximo n tal que

$$P_n(x_k) = y_k, \quad k = 0, 1, \dots, n.$$

Funções básicas de Lagrange

Para cada índice k , definimos a função base $L_{n,k}(x)$ como aquela que vale 1 em x_k e 0 em todos os outros pontos:

$$L_{n,k}(x_i) = \begin{cases} 1, & \text{se } i = k, \\ 0, & \text{se } i \neq k. \end{cases}$$

Uma função com essas propriedades é dada por

$$L_{n,k}(x) = \prod_{\substack{i=0 \\ i \neq k}}^n \frac{x - x_i}{x_k - x_i}.$$

Polinômio interpolador

Com as funções $L_{n,k}(x)$ definidas, o polinômio interpolador de Lagrange é obtido pela combinação linear

$$P_n(x) = \sum_{k=0}^n L_{n,k}(x) y_k.$$

Este polinômio satisfaz automaticamente

$$P_n(x_k) = y_k \quad \text{para todo } k = 0, \dots, n,$$

sendo, portanto, o polinômio que interpola exatamente os pontos dados.

Interpretação

Cada função $L_{n,k}(x)$ atua como um *peso* associado ao valor y_k :

- $L_{n,k}(x)$ é igual a 1 em x_k e zero nos demais pontos;
- perto de x_k , a função $L_{n,k}(x)$ domina o valor de $P_n(x)$;
- o polinômio interpolador é uma combinação ponderada dos valores y_k , em que os pesos variam com x .

Assim, o método de Lagrange constrói o polinômio que passa por todos os pontos sem necessidade de resolver sistemas lineares ou calcular coeficientes intermediários.

Exemplo

Considere a função $f(x) = 1/x$ conhecida nos pontos

$$x_0 = 2, \quad x_1 = 2.5, \quad x_2 = 4.$$

Os valores correspondentes são:

$$f(x_0) = \frac{1}{2}, \quad f(x_1) = \frac{1}{2.5} = 0.4, \quad f(x_2) = \frac{1}{4} = 0.25.$$

O polinômio interpolador de Lagrange de grau 2 é

$$P_2(x) = f(x_0)L_0(x) + f(x_1)L_1(x) + f(x_2)L_2(x),$$

onde cada base é dada por

$$L_k(x) = \prod_{\substack{i=0 \\ i \neq k}}^2 \frac{x - x_i}{x_k - x_i}.$$

Cálculo das bases de Lagrange

$$L_0(x) = \frac{(x - 2.5)(x - 4)}{(2 - 2.5)(2 - 4)}.$$

$$L_1(x) = \frac{(x - 2)(x - 4)}{(2.5 - 2)(2.5 - 4)}.$$

$$L_2(x) = \frac{(x - 2)(x - 2.5)}{(4 - 2)(4 - 2.5)}.$$

Montagem do polinômio

$$P_2(x) = \frac{1}{2} L_0(x) + 0.4 L_1(x) + 0.25 L_2(x).$$

Após simplificação, obtém-se:

$$P_2(x) = -0.0625 x^2 + 0.3875 x - 0.175.$$

Estimativas

Estimativa de $f(2.2)$

$$P_2(2.2) = -0.0625(2.2)^2 + 0.3875(2.2) - 0.175 = 0.454999.$$

Valor real:

$$f(2.2) = \frac{1}{2.2} = 0.454545.$$

Erro absoluto:

$$|f(2.2) - P_2(2.2)| \approx 4.54 \times 10^{-4}.$$

Estimativa de $f(3.5)$

$$P_2(3.5) = -0.0625(3.5)^2 + 0.3875(3.5) - 0.175 = 0.2921875.$$

Valor real:

$$f(3.5) = \frac{1}{3.5} = 0.285714.$$

Erro absoluto:

$$|f(3.5) - P_2(3.5)| \approx 6.47 \times 10^{-3}.$$

- O valor em $x = 2.2$ está **próximo** dos pontos de interpolação, e o erro é muito pequeno.
- O valor em $x = 3.5$ está **mais distante** dos pontos usados, especialmente de $x_1 = 2.5$, aumentando o erro.
- Isso mostra o comportamento típico da interpolação polinomial: quanto mais longe do intervalo central, maior tende a ser o erro.

Pontos de Chebyshev e Pontos Equidistantes

Ao construir um polinômio interpolador, a escolha dos pontos x_i é fundamental para controlar o erro global da interpolação.

Pontos equidistantes

Uma escolha natural é dividir o intervalo $[a, b]$ de forma uniforme:

$$x_i = a + i \frac{b-a}{n}, \quad i = 0, 1, \dots, n.$$

Apesar de simples, essa escolha pode gerar grandes oscilações do polinômio interpolador, especialmente próximo das extremidades do intervalo. Esse fenômeno é conhecido como **Fenômeno de Runge**.

- Fácil de construir.
- Pode produzir erros grandes quando n aumenta.
- Oscilações indesejadas nas bordas do intervalo.

Pontos de Chebyshev

Para reduzir as oscilações, utilizamos os **pontos de Chebyshev**, definidos no intervalo $[-1, 1]$ por:

$$x_i = \cos\left(\frac{2i+1}{2(n+1)}\pi\right), \quad i = 0, 1, \dots, n.$$

No intervalo geral $[a, b]$, fazemos a transformação afim:

$$x_i^* = \frac{b-a}{2}x_i + \frac{a+b}{2}.$$

Os pontos de Chebyshev possuem a propriedade de minimizar o erro máximo da interpolação polinomial. Eles acumulam mais pontos nas extremidades, onde o erro tende a ser maior.

Capítulo 6

Regressão por Mínimos Quadrados

Quando os dados apresentam variabilidade significativa, a interpolação polinomial pode se tornar inadequada. Isso ocorre porque, ao obrigar o polinômio a passar exatamente por todos os pontos, pequenas flutuações nos eleva.

A Figura 6.1 ilustra um conjunto típico de dados experimentais, nos quais existe uma tendência crescente, mas também um erro associado às medições.




Figura 6.1: Dados experimentais apresentando variação significativa.

6.1 Problema da interpolação em dados ruidosos

Se aplicarmos um polinômio interpolador de grau elevado a esses pontos, o resultado será um ajuste que passa exatamente por todas as observações, mas que oscila severamente entre elas. Isso é ilustrado na Figura 6.2.

Apesar de o polinômio reproduzir exatamente todos os pontos disponíveis, a curva resultante não representa adequadamente a tendência geral dos dados. Em particular, as previsões em regiões intermediárias podem se tornar pouco confiáveis, como ocorre, por exemplo, ao estimar valores em $x = 1.5$ ou $x = 6.5$.




Figura 6.2: Interpolação polinomial oscilatória para dados ruidosos.

6.2 Ideia da Regressão por Mínimos Quadrados

Uma alternativa mais apropriada para dados com erro é encontrar uma função que descreva a *tendência geral* dos pontos, sem necessariamente passar por cada um deles.

O objetivo é minimizar a discrepância entre o modelo ajustado e os dados observados. A técnica mais empregada para isso é a **regressão por mínimos quadrados**.

A Figura 6.3 mostra uma reta ajustada pelo método dos mínimos quadrados aos mesmos dados experimentais, produzindo um resultado muito mais suave e coerente.




Figura 6.3: Ajuste por mínimos quadrados para os dados da Figura 6.1.

6.3 Modelo de regressão linear

O caso mais simples é ajustar uma **reta** aos dados:

$$y \approx a_0 + a_1x.$$

Os parâmetros a_0 e a_1 são escolhidos de forma a minimizar a soma dos quadrados dos erros:

$$e_i = y_i - (a_0 + a_1 x_i), \quad i = 1, \dots, n.$$

Assim, o problema consiste em minimizar

$$S(a_0, a_1) = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2.$$

A solução desse sistema fornece os coeficientes da melhor reta no sentido dos mínimos quadrados.

6.4 Critérios para um Melhor Ajuste

Ao buscar a melhor reta que descreva a tendência geral de um conjunto de dados, uma primeira ideia natural seria minimizar a soma dos erros residuais

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (y_i - a_0 - a_1 x_i),$$

onde e_i representa o erro entre o valor observado y_i e o valor previsto pelo modelo linear $a_0 + a_1 x_i$.

No entanto, esse critério é inadequado. Para ilustrar, considere a situação em que uma reta liga dois pontos e qualquer outra reta passando pelo segmento entre eles produz soma de erros nula, já que os erros se cancelam.




Figura 6.4: Minimizar $\sum e_i$ não define uma única reta.

Portanto, uma alternativa seria minimizar a soma dos valores absolutos

$$\sum_{i=1}^n |e_i| = \sum_{i=1}^n |y_i - a_0 - a_1 x_i|.$$

Contudo, este critério também falha, porque qualquer reta que permaneça dentro da região delimitada pelas duas retas tracejadas minimiza essa soma. Assim, o ajuste não é único.

Outra possibilidade seria minimizar o erro máximo, o chamado critério *minimax*. Nesse caso, escolhe-se a reta que reduz ao máximo o maior erro individual. Porém, o método é extremamente sensível a um único ponto discrepante, que passa a dominar completamente o ajuste.




Figura 6.5: Minimizar $\sum |e_i|$ também não garante unicidade do ajuste.




Figura 6.6: Critério minimax: um ponto fora do padrão compromete o ajuste.

Uma abordagem mais robusta é minimizar a soma dos quadrados dos resíduos, definida por

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2.$$

Esse critério possui vantagens importantes:

- elimina o cancelamento entre erros positivos e negativos;
- penaliza mais fortemente erros grandes;
- conduz sempre a uma única solução;
- permite derivar equações normais simples e resolvíveis.

Por essas razões, a **regressão por mínimos quadrados** é o método padrão para ajustar modelos lineares aos dados.

6.5 Ajuste por Mínimos Quadrados por uma Reta

Considere um conjunto de dados experimentais (x_i, y_i) , $i = 1, \dots, n$. Nosso objetivo é ajustar a esses dados uma função linear

$$y = a_0 + a_1x,$$

de forma que a curva represente da melhor maneira possível a tendência geral dos pontos. A qualidade do ajuste é medida pelos *resíduos*

$$e_i = y_i - (a_0 + a_1x_i).$$

No método dos mínimos quadrados, escolhemos a_0 e a_1 que minimizam a soma dos quadrados dos resíduos:

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1x_i)^2.$$

Para encontrar os coeficientes que minimizam S_r , derivamos a expressão acima com relação a a_0 e a_1 e igualamos a zero:

$$\frac{\partial S_r}{\partial a_0} = -2 \sum_{i=1}^n (y_i - a_0 - a_1x_i) = 0,$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum_{i=1}^n (y_i - a_0 - a_1x_i) x_i = 0.$$

Eliminando o fator -2 e reorganizando os termos, obtemos o seguinte sistema:

$$\begin{cases} n a_0 + (\sum x_i) a_1 = \sum y_i, \\ (\sum x_i) a_0 + (\sum x_i^2) a_1 = \sum x_i y_i. \end{cases}$$

Estas são chamadas **equações normais**. A solução explícita para a_1 é:

$$a_1 = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2},$$

e, usando esse valor em uma das equações normais, obtemos

$$a_0 = \bar{y} - a_1 \bar{x},$$

onde

$$\bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i.$$

Assim, a reta ajustada por mínimos quadrados é dada por

$$y = a_0 + a_1x.$$




Figura 6.7: Ilustração geométrica: resíduos verticais entre os pontos e a reta ajustada.

6.5.1 Exemplo Numérico: Ajuste por Mínimos Quadrados por uma Reta

Considere o seguinte conjunto de dados experimentais:

x_i	1	2	3	4
y_i	2	3	5	4

Nosso objetivo é ajustar aos dados a função linear

$$y = a_0 + a_1 x,$$

determinando os coeficientes a_0 e a_1 pelo método dos mínimos quadrados.

Cálculo dos somatórios

Montamos a tabela auxiliar:

x_i	1	2	3	4	$\sum x_i = 10$
y_i	2	3	5	4	$\sum y_i = 14$
x_i^2	1	4	9	16	$\sum x_i^2 = 30$
$x_i y_i$	2	6	15	16	$\sum x_i y_i = 39$

Com $n = 4$, os coeficientes da reta de mínimos quadrados são dados pelas fórmulas:

$$a_1 = \frac{n \sum x_i y_i - (\sum x_i)(\sum y_i)}{n \sum x_i^2 - (\sum x_i)^2},$$

$$a_0 = \bar{y} - a_1 \bar{x}, \quad \bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i.$$

Aplicação das fórmulas

Cálculo de a_1 :

$$a_1 = \frac{4(39) - (10)(14)}{4(30) - (10)^2} = \frac{156 - 140}{120 - 100} = \frac{16}{20} = 0.8.$$

Cálculo de a_0 :

$$\bar{x} = \frac{10}{4} = 2.5, \quad \bar{y} = \frac{14}{4} = 3.5,$$

$$a_0 = 3.5 - 0.8 \cdot 2.5 = 1.5.$$

Portanto, a reta ajustada é:

$$\boxed{\hat{y} = 1.5 + 0.8x}.$$

Cálculo do coeficiente de determinação R^2

O coeficiente de determinação é definido por:

$$R^2 = 1 - \frac{S_r}{S_t},$$

onde

$$S_r = \sum (y_i - \hat{y}_i)^2, \quad S_t = \sum (y_i - \bar{y})^2.$$

Cálculo de S_r :

x_i	y_i	$\hat{y}_i = 1.5 + 0.8x_i$	$(y_i - \hat{y}_i)^2$
1	2	2.3	0.09
2	3	3.1	0.01
3	5	3.9	1.21
4	4	4.7	0.49
			$S_r = 1.80$

Cálculo de S_t com $\bar{y} = 3.5$:

y_i	$y_i - \bar{y}$	$(y_i - \bar{y})^2$
2	-1.5	2.25
3	-0.5	0.25
5	1.5	2.25
4	0.5	0.25
		$S_t = 5.00$

Assim:

$$R^2 = 1 - \frac{1.80}{5.00} = 1 - 0.36 = 0.64.$$

Conclusão

O modelo ajustado por mínimos quadrados é:

$$\hat{y} = 1.5 + 0.8x, \quad R^2 = 0.64.$$

Isso significa que aproximadamente 64% da variação total observada em y é explicada pela reta ajustada.

6.6 Linearização de Relações Não-Lineares

Em muitos problemas de engenharia e ciências aplicadas, a relação entre as variáveis não é linear. Nessas situações, a regressão linear direta não produz um bom ajuste. Entretanto, vários modelos não-lineares podem ser transformados em formas lineares, permitindo o uso da regressão linear clássica.

Nesta subseção, focaremos nos dois modelos mais utilizados: o **modelo exponencial** e o **modelo de potência**. A ideia é aplicar transformações adequadas para obter uma equação do tipo

$$Y = A + B X,$$

de modo que os parâmetros possam ser estimados pelos mínimos quadrados.

Modelo Exponencial

Considere o modelo

$$y = \alpha_1 e^{\beta_1 x},$$

onde α_1 e β_1 são constantes positivas ou negativas. Aplicando logaritmo natural em ambos os lados, obtemos:

$$\ln y = \ln(\alpha_1 e^{\beta_1 x}) = \ln \alpha_1 + \beta_1 x.$$

Definindo

$$Y = \ln y, \quad A = \ln \alpha_1, \quad B = \beta_1,$$

a equação torna-se linear:

$$Y = A + Bx.$$

Assim, basta ajustar uma regressão linear entre $Y = \ln y$ e x . Após estimar A e B :

$$\alpha_1 = e^A, \quad \beta_1 = B.$$

Exemplo Numérico: Modelo Exponencial

Considere os seguintes dados experimentais:

x_i	0	1	2	3
y_i	2.0	2.7	3.6	4.8

Desejamos ajustar o modelo exponencial

$$y = \alpha_1 e^{\beta_1 x}.$$

Aplicando logaritmo natural em ambos os lados, obtemos a relação linear

$$Y = A + Bx, \quad Y = \ln y, \quad A = \ln \alpha_1, \quad B = \beta_1.$$

Linearização dos dados

Calculamos $Y_i = \ln(y_i)$:

x_i	0	1	2	3	$\sum x_i = 6$
y_i	2.0	2.7	3.6	4.8	$\sum y_i = 13.1$
$Y_i = \ln y_i$	0.6931	0.9933	1.2809	1.5686	$\sum Y_i = 4.5359$
x_i^2	0	1	4	9	$\sum x_i^2 = 14$
$x_i Y_i$	0	0.9933	2.5618	4.7058	$\sum x_i Y_i = 8.2609$

Com $n = 4$, os coeficientes A e B da regressão linear são dados por:

$$B = \frac{n \sum x_i Y_i - \sum x_i \sum Y_i}{n \sum x_i^2 - (\sum x_i)^2}, \quad A = \bar{Y} - B\bar{x}.$$

Cálculo de B

$$B = \frac{4(8.2609) - (6)(4.5359)}{4(14) - 6^2} = \frac{33.0436 - 27.2154}{56 - 36} = \frac{5.8282}{20} = 0.29141.$$

Cálculo de A

$$\bar{x} = \frac{6}{4} = 1.5, \quad \bar{Y} = \frac{4.5359}{4} = 1.1340,$$

$$A = 1.1340 - 0.29141(1.5) = 1.1340 - 0.4371 = 0.6969.$$

Portanto,

$$A = 0.6969, \quad B = 0.29141.$$

Voltando às constantes do modelo exponencial:

$$\alpha_1 = e^A = e^{0.6969} = 2.007, \quad \beta_1 = B = 0.29141.$$

Logo, o modelo ajustado é:

$$\hat{y} = 2.007 e^{0.29141x}.$$

Cálculo do coeficiente de determinação R^2

O cálculo é feito no plano transformado $(x, Y = \ln y)$:

$$R^2 = 1 - \frac{S_r}{S_t}, \quad S_r = \sum (Y_i - \hat{Y}_i)^2, \quad S_t = \sum (Y_i - \bar{Y})^2.$$

Primeiro, os valores ajustados:

$$\hat{Y}_i = A + Bx_i = 0.6969 + 0.29141x_i.$$

x_i	Y_i	$\hat{Y}_i$	$(Y_i - \hat{Y}_i)^2$
0	0.6931	0.6969	1.44×10^{-5}
1	0.9933	0.9883	2.50×10^{-5}
2	1.2809	1.2797	1.44×10^{-6}
3	1.5686	1.5711	6.25×10^{-6}
			$S_r = 4.81 \times 10^{-5}$

Agora S_t com $\bar{Y} = 1.1340$:

$$S_t = (0.6931 - 1.1340)^2 + (0.9933 - 1.1340)^2 + (1.2809 - 1.1340)^2 + (1.5686 - 1.1340)^2.$$

$$S_t = 0.1945.$$

Assim:

$$R^2 = 1 - \frac{4.81 \times 10^{-5}}{0.1945} = 1 - 2.47 \times 10^{-4} = 0.99975.$$

Conclusão

O modelo exponencial ajustado aos dados é

$$\hat{y} = 2.007 e^{0.29141x}, \quad R^2 = 0.99975.$$

Esse valor de R^2 indica excelente aderência dos dados ao modelo exponencial.

Modelo de Potência

Agora considere o modelo

$$y = \alpha_2 x^{\beta_2},$$

com $\alpha_2 > 0$ e $x > 0$. Aplicando logaritmo base 10 ou natural:

$$\ln y = \ln \alpha_2 + \beta_2 \ln x.$$

Definindo

$$Y = \ln y, \quad X = \ln x, \quad A = \ln \alpha_2, \quad B = \beta_2,$$

a equação toma a forma linear:

$$Y = A + BX.$$

Assim, realizamos uma regressão linear simples entre $Y = \ln y$ e $X = \ln x$. Ao final:

$$\alpha_2 = e^A, \quad \beta_2 = B.$$

Exemplo Numérico: Modelo de Potência

Considere os seguintes dados experimentais, todos com $x > 0$:

x_i	1	2	3	4
y_i	3.0	4.8	6.7	8.2

Desejamos ajustar o modelo de potência:

$$y = \alpha_2 x^{\beta_2}.$$

Aplicando logaritmo natural:

$$Y = \ln y, \quad X = \ln x, \quad A = \ln \alpha_2, \quad B = \beta_2,$$

a equação torna-se linear:

$$Y = A + BX.$$

Transformação dos dados

Construímos a tabela:

x_i	1	2	3	4	$\sum x_i = 10$
y_i	3.0	4.8	6.7	8.2	$\sum y_i = 22.7$
$X_i = \ln x_i$	0	0.6931	1.0986	1.3863	$\sum X_i = 3.1780$
$Y_i = \ln y_i$	1.0986	1.5686	1.9021	2.1041	$\sum Y_i = 6.6734$
X_i^2	0	0.4804	1.2069	1.9217	$\sum X_i^2 = 3.6090$
$X_i Y_i$	0	1.0870	2.0890	2.9165	$\sum X_i Y_i = 6.0925$

Com $n = 4$, usamos as fórmulas:

$$B = \frac{n \sum X_i Y_i - (\sum X_i)(\sum Y_i)}{n \sum X_i^2 - (\sum X_i)^2}, \quad A = \bar{Y} - B\bar{X}.$$

Cálculo de B

$$B = \frac{4(6.0925) - (3.1780)(6.6734)}{4(3.6090) - (3.1780)^2}.$$

$$B = \frac{24.3700 - 21.2090}{14.4360 - 10.0960} = \frac{3.1610}{4.3400} = 0.7287.$$

Cálculo de A

$$\bar{X} = \frac{3.1780}{4} = 0.7945, \quad \bar{Y} = \frac{6.6734}{4} = 1.6683,$$

$$A = 1.6683 - 0.7287(0.7945) = 1.6683 - 0.5787 = 1.0896.$$

Portanto,

$$A = 1.0896, \quad B = 0.7287.$$

Voltando aos parâmetros do modelo:

$$\alpha_2 = e^A = e^{1.0896} = 2.973, \quad \beta_2 = B = 0.7287.$$

Assim, o modelo ajustado é:

$$\hat{y} = 2.973 x^{0.7287}.$$

Cálculo do coeficiente de determinação R^2

O cálculo é feito no plano transformado (X, Y) :

$$R^2 = 1 - \frac{S_r}{S_t}, \quad S_r = \sum (Y_i - \hat{Y}_i)^2, \quad S_t = \sum (Y_i - \bar{Y})^2.$$

Os valores ajustados são:

$$\hat{Y}_i = A + BX_i.$$

X_i	Y_i	$\hat{Y}_i = 1.0896 + 0.7287X_i$	$(Y_i - \hat{Y}_i)^2$
0	1.0986	1.0896	8.10×10^{-5}
0.6931	1.5686	1.5945	0.00067
1.0986	1.9021	1.8894	0.00016
1.3863	2.1041	2.1039	4.00×10^{-8}
			$S_r = 0.00099$

Agora, com $\bar{Y} = 1.6683$:

$$S_t = 0.3240.$$

Assim:

$$R^2 = 1 - \frac{0.00099}{0.3240} = 1 - 0.00306 = 0.9969.$$

Conclusão

O modelo de potência ajustado aos dados é:

$$\hat{y} = 2.973 x^{0.7287}, \quad R^2 = 0.9969.$$

O elevado valor de R^2 indica que o modelo de potência explica mais de 99% da variação observada nos dados.

6.7 Regressão Polinomial

Em muitos problemas de engenharia os dados exibem um comportamento claramente curvilíneo, tornando a regressão linear inadequada. Nesses casos, uma alternativa natural consiste em ajustar um polinômio aos dados, processo conhecido como **regressão polinomial**.

A ideia é substituir o modelo linear

$$y = a_0 + a_1x$$

por um polinômio de grau superior. Por exemplo, para um ajuste quadrático, adota-se o modelo

$$y = a_0 + a_1x + a_2x^2.$$

Função objetivo

Assim como no caso linear, os coeficientes desconhecidos a_0, a_1, a_2 são determinados minimizando a soma dos quadrados dos resíduos:

$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1 x_i - a_2 x_i^2)^2.$$

Para encontrar o mínimo, deriva-se S_r em relação a cada coeficiente:

$$\frac{\partial S_r}{\partial a_0} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i - a_2 x_i^2),$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum_{i=1}^n x_i (y_i - a_0 - a_1 x_i - a_2 x_i^2),$$

$$\frac{\partial S_r}{\partial a_2} = -2 \sum_{i=1}^n x_i^2 (y_i - a_0 - a_1 x_i - a_2 x_i^2).$$

Igualando as derivadas a zero, obtém-se o sistema de equações normais:

$$\begin{cases} na_0 + (\sum x_i) a_1 + (\sum x_i^2) a_2 = \sum y_i, \\ (\sum x_i) a_0 + (\sum x_i^2) a_1 + (\sum x_i^3) a_2 = \sum x_i y_i, \\ (\sum x_i^2) a_0 + (\sum x_i^3) a_1 + (\sum x_i^4) a_2 = \sum x_i^2 y_i. \end{cases}$$

Esse sistema linear determina unicamente os coeficientes do polinômio ajustado.

Generalização

O procedimento se estende naturalmente para polinômios de grau m :

$$y = a_0 + a_1 x + a_2 x^2 + \cdots + a_m x^m + e.$$

Nesse caso, o cálculo dos coeficientes envolve resolver um sistema com $(m+1)$ equações normais. O processo é completamente análogo ao caso quadrático.

Erro padrão do ajuste polinomial

Após determinados os coeficientes, o erro associado ao ajuste é medido por

$$s_{y/x} = \sqrt{\frac{S_r}{n - (m + 1)}},$$

onde $n - (m + 1)$ corresponde ao número de graus de liberdade, já que $m + 1$ coeficientes foram estimados a partir dos dados.

Esse erro quantifica a dispersão dos pontos em torno da curva ajustada: quanto menor o valor de $s_{y/x}$, melhor o ajuste.

6.8 Regressão Linear Múltipla

A regressão linear múltipla é uma extensão natural da regressão linear simples para o caso em que a variável dependente y relaciona-se linearmente com duas ou mais variáveis independentes. Por exemplo, para duas variáveis x_1 e x_2 , podemos escrever o modelo linear como

$$y = a_0 + a_1x_1 + a_2x_2 + e,$$

onde a_0, a_1, a_2 são coeficientes desconhecidos e e representa o erro associado ao ajuste.

Esse tipo de equação é extremamente útil no estudo de dados experimentais em que duas variáveis independentes influenciam simultaneamente a variável dependente. Nesse caso, a “reta” de regressão torna-se um plano de regressão.

Os coeficientes que produzem o melhor ajuste são obtidos minimizando-se a soma dos quadrados dos resíduos,

$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1x_{1i} - a_2x_{2i})^2.$$

Derivando S_r em relação a cada coeficiente,

$$\frac{\partial S_r}{\partial a_0} = -2 \sum (y_i - a_0 - a_1x_{1i} - a_2x_{2i}),$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum x_{1i}(y_i - a_0 - a_1x_{1i} - a_2x_{2i}),$$

$$\frac{\partial S_r}{\partial a_2} = -2 \sum x_{2i}(y_i - a_0 - a_1x_{1i} - a_2x_{2i}).$$

Igualando essas expressões a zero, obtém-se o sistema linear matricial:

$$\begin{bmatrix} n & \sum x_{1i} & \sum x_{2i} \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i}x_{2i} \\ \sum x_{2i} & \sum x_{1i}x_{2i} & \sum x_{2i}^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum x_{1i}y_i \\ \sum x_{2i}y_i \end{bmatrix}.$$

Esse conjunto de equações normais pode ser resolvido usando qualquer método de álgebra linear estudado anteriormente.

Extensão para m variáveis

De forma geral, para m variáveis independentes,

$$y = a_0 + a_1x_1 + a_2x_2 + \cdots + a_mx_m + e,$$

onde o erro padrão do ajuste é dado por

$$s_{y/x} = \sqrt{\frac{S_r}{n - (m + 1)}},$$

já que $m + 1$ coeficientes foram estimados a partir dos dados, reduzindo os graus de liberdade.

O coeficiente de determinação r^2 é calculado da mesma forma apresentada anteriormente para regressão linear simples.

Exemplo Numérico: Regressão Linear Múltipla

Considere o seguinte conjunto de dados experimentais, com duas variáveis independentes x_1 e x_2 :

x_{1i}	1	2	3	4
x_{2i}	2	1	3	2
y_i	4	5	7	10

Desejamos ajustar o modelo linear múltiplo:

$$y = a_0 + a_1x_1 + a_2x_2.$$

Cálculo dos somatórios

Construímos a tabela auxiliar:

x_{1i}	1	2	3	4	$\sum x_{1i} = 10$
x_{2i}	2	1	3	2	$\sum x_{2i} = 8$
y_i	4	5	7	10	$\sum y_i = 26$
x_{1i}^2	1	4	9	16	$\sum x_{1i}^2 = 30$
x_{2i}^2	4	1	9	4	$\sum x_{2i}^2 = 18$
$x_{1i}x_{2i}$	2	2	9	8	$\sum x_{1i}x_{2i} = 21$
$x_{1i}y_i$	4	10	21	40	$\sum x_{1i}y_i = 75$
$x_{2i}y_i$	8	5	21	20	$\sum x_{2i}y_i = 54$

Com $n = 4$, montamos as equações normais:

$$\begin{bmatrix} 4 & 10 & 8 \\ 10 & 30 & 21 \\ 8 & 21 & 18 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 26 \\ 75 \\ 54 \end{bmatrix}.$$

Resolução do sistema

Escrevendo a matriz aumentada:

$$\left[\begin{array}{ccc|c} 4 & 10 & 8 & 26 \\ 10 & 30 & 21 & 75 \\ 8 & 21 & 18 & 54 \end{array} \right].$$

Aplicando eliminação de Gauss (passos resumidos):

$$1) L_2 \leftarrow L_2 - \frac{10}{4}L_1 \quad 2) L_3 \leftarrow L_3 - \frac{8}{4}L_1$$

$$\left[\begin{array}{ccc|c} 4 & 10 & 8 & 26 \\ 0 & 5 & 1 & 10 \\ 0 & 1 & 2 & 2 \end{array} \right].$$

Eliminando o termo abaixo de L_2 :

$$L_3 \leftarrow L_3 - \frac{1}{5}L_2,$$

$$\left[\begin{array}{ccc|c} 4 & 10 & 8 & 26 \\ 0 & 5 & 1 & 10 \\ 0 & 0 & 1.8 & 0 \end{array} \right].$$

Por retro-substituição:

$$a_2 = 0,$$

$$5a_1 + 1(0) = 10 \Rightarrow a_1 = 2,$$

$$4a_0 + 10(2) + 8(0) = 26 \Rightarrow 4a_0 = 6 \Rightarrow a_0 = 1.5.$$

Portanto:

$$\boxed{a_0 = 1.5, \quad a_1 = 2.0, \quad a_2 = 0.}$$

O modelo ajustado é:

$$\boxed{\hat{y} = 1.5 + 2x_1}.$$

Observe que o ajuste indicou $a_2 = 0$: a variável x_2 não contribuiu significativamente para o modelo com estes dados.

Cálculo do coeficiente de determinação R^2

Primeiro calculamos os valores ajustados:

$$\hat{y}_i = 1.5 + 2x_{1i}.$$

x_{1i}	y_i	$\hat{y}_i$	$(y_i - \hat{y}_i)^2$
1	4	3.5	0.25
2	5	5.5	0.25
3	7	7.5	0.25
4	10	9.5	0.25
			$S_r = 1.00$

Agora, com $\bar{y} = 26/4 = 6.5$:

$$S_t = (4 - 6.5)^2 + (5 - 6.5)^2 + (7 - 6.5)^2 + (10 - 6.5)^2 = 21.0.$$

Assim:

$$R^2 = 1 - \frac{1.00}{21.0} = 1 - 0.0476 = 0.9524.$$

Conclusão

O modelo de regressão linear múltipla obtido é:

$$\hat{y} = 1.5 + 2x_1, \quad R^2 = 0.9524.$$

Isso indica que cerca de 95% da variação observada em y é explicada pelo modelo linear com duas variáveis independentes.

Relação com Modelos de Potência

A regressão linear múltipla também é útil quando modelos de potência envolvendo múltiplas variáveis são transformados para uma forma linear. Para uma equação de potência geral,

$$y = a_0 x_1^{a_2} x_2^{a_3} \cdots x_m^{a_{m+1}},$$

aplicando logaritmo obtém-se

$$\log y = \log a_0 + a_2 \log x_1 + a_3 \log x_2 + \cdots + a_{m+1} \log x_m.$$

Assim, a equação original não linear torna-se um modelo linear multiplicativo, permitindo o uso direto de regressão linear múltipla na determinação dos coeficientes.

6.9 Formulação Matricial Geral dos Mínimos Quadrados Linear

Embora pareçam métodos distintos, todos pertencem a um mesmo modelo geral de mínimos quadrados linear, dado por

$$y = a_0 + a_1 z_1 + a_2 z_2 + \cdots + a_m z_m + e,$$

onde $z_1, z_2, \dots, z_m$ são as funções base (preditores) e $a_0, a_1, \dots, a_m$ são coeficientes desconhecidos.

Esse modelo é bastante geral: cada tipo de regressão é obtido escolhendo-se funções base diferentes. Por exemplo:

- Na regressão linear simples, $z_1 = x$.
- Na regressão polinomial, $z_1 = x, z_2 = x^2, \dots$.
- Na regressão múltipla, cada z_j representa uma variável explicativa x_j .
- Em modelos mais avançados, z_j pode ser uma função não linear, como $\cos(\omega t)$ ou e^{kx} .

Observando essa estrutura geral, podemos expressar o modelo em forma matricial como

$$\{Y\} = [Z]\{A\} + \{E\},$$

onde:

- $\{Y\}$ é o vetor coluna com os valores observados,

$$\{Y\} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix},$$

- $[Z]$ é a matriz das funções base avaliadas ponto a ponto,

$$[Z] = \begin{bmatrix} 1 & z_{11} & z_{12} & \cdots & z_{1m} \\ 1 & z_{21} & z_{22} & \cdots & z_{2m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & z_{n2} & \cdots & z_{nm} \end{bmatrix},$$

- $\{A\}$ contém os coeficientes desconhecidos,

$$\{A\} = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix},$$

- $\{E\}$ é o vetor dos erros (resíduos).

Como em todo método de mínimos quadrados, buscamos minimizar a soma dos quadrados dos resíduos:

$$S_r = \sum_{i=1}^n \left(y_i - \sum_{j=0}^m a_j z_{ij} \right)^2.$$

Derivando S_r em relação a cada coeficiente e igualando as derivadas a zero, chegamos ao sistema matricial das **equações normais**:

$$[Z]^T [Z] \{A\} = [Z]^T \{Y\}.$$

Essa é a forma compacta e unificada das equações de mínimos quadrados para todas as regressões lineares discutidas anteriormente.

Note que essa expressão é totalmente equivalente às equações normais obtidas nos casos:

- regressão linear simples;
- regressão polinomial;
- regressão linear múltipla.

A formulação matricial destaca a unidade entre essas abordagens e prepara o terreno para métodos numéricos eficientes para resolver o sistema

$$[Z]^T [Z] \{A\} = [Z]^T \{Y\},$$

Exemplo Numérico: Formulação Matricial Geral

Considere os seguintes dados experimentais:

x_i	1	2	3
y_i	2.2	2.8	3.6

Suponha que desejamos ajustar aos dados um modelo linear do tipo

$$y = a_0 + a_1 z_1 + a_2 z_2,$$

onde as funções base são escolhidas como:

$$z_1 = x, \quad z_2 = x^2.$$

Trata-se, portanto, de um **ajuste polinomial de segundo grau**, visto como um caso particular da formulação geral.

Construção da matriz $[Z]$

Para cada ponto experimental, avaliamos as funções base:

$$\begin{array}{l|lll} x_i & 1 & 2 & 3 \\ z_{i1} = x_i & 1 & 2 & 3 \\ z_{i2} = x_i^2 & 1 & 4 & 9 \end{array}$$

A matriz $[Z]$ é:

$$[Z] = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix}.$$

O vetor de observações é:

$$\{Y\} = \begin{bmatrix} 2.2 \\ 2.8 \\ 3.6 \end{bmatrix}.$$

Queremos determinar

$$\{A\} = \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix}$$

que minimiza os resíduos.

Equações normais em forma matricial

O sistema geral de mínimos quadrados é:

$$[Z]^T [Z] \{A\} = [Z]^T \{Y\}.$$

Primeiro, calculamos:

$$[Z]^T = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 4 & 9 \end{bmatrix}.$$

$$[Z]^T [Z] = \begin{bmatrix} 3 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix}.$$

$$[Z]^T \{Y\} = \begin{bmatrix} 2.2 + 2.8 + 3.6 \\ 2.2(1) + 2.8(2) + 3.6(3) \\ 2.2(1) + 2.8(4) + 3.6(9) \end{bmatrix} = \begin{bmatrix} 8.6 \\ 18.0 \\ 47.6 \end{bmatrix}.$$

Assim, as equações normais ficam:

$$\begin{bmatrix} 3 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 8.6 \\ 18.0 \\ 47.6 \end{bmatrix}.$$

Resolução do sistema

Resolvendo (por eliminação de Gauss ou qualquer método de álgebra linear):

$$a_2 = 0.1000, \quad a_1 = 0.5000, \quad a_0 = 1.6000.$$

Portanto,

$$\{A\} = \begin{bmatrix} 1.6 \\ 0.5 \\ 0.1 \end{bmatrix}.$$

Modelo ajustado

Substituindo os coeficientes:

$$\hat{y} = 1.6 + 0.5x + 0.1x^2.$$

Esse resultado mostra que a regressão polinomial de ordem 2 surge naturalmente como um caso particular do modelo matricial geral:

$$Y = [Z]A.$$

Comentário Final

Este exemplo evidencia como a formulação

$$[Z]^T [Z] \{A\} = [Z]^T \{Y\}$$

unifica todos os problemas de mínimos quadrados: basta escolher as funções base $z_1, z_2, \dots, z_m$. O procedimento de cálculo permanece idêntico para regressão linear simples, múltipla, polinomial ou qualquer outra regressão linear em parâmetros.